

VISION LAB

计算机视觉 **140** 算法学习文档

原理详解 · 模型架构 · 实验方法 · 840 道配套练习

140 个算法实验 · 13 个模块 · 每算法 6 题

依据当前项目代码与模型配置编写

编写日期：2026 年 9 月 30 日

目录

学习方法与共同基础.....	9
读公式前先明确量的含义.....	9
先分清图像、标签与可视化.....	9
从滤波到分割：信号与决策是两步.....	9
神经网络的五段数据流.....	10
卷积、残差与尺寸变化.....	10
注意力、token 与恢复网络.....	10
训练、推理与实验边界.....	11
怎样使用两册进行学习练习.....	11
模型架构专题：22 套本地模型.....	12
M01 ResNet18 残差卷积分类骨干.....	13
M02 YOLOv8n 单阶段多尺度检测.....	14
M03 YOLOv8n-OBB 旋转目标框.....	15
M04 YOLOv8n-Seg 原型式实例分割.....	16
M05 YOLOv8n-Pose 人体检测与关键点.....	17
M06 DeepLabV3-MobileNetV3-Large 轻量语义分割.....	18
M07 DETR-ResNet50-Panoptic 集合预测与像素分配.....	19
M08 SAM2 Hierarchical 提示分割与视频记忆.....	20
M09 MediaPipe Face Landmarker 检测、ROI 与密集脸部点.....	21
M10 MediaPipe Hand Landmarker 手掌定位与 21 点回归.....	22
M11 PP-OCRv4 / RapidOCR 文字检测、方向与序列识别.....	23
M12 DocLayout-YOLO YOLOv10 文档区域检测架构.....	24
M13 CLIP ViT-B/32 视觉与语言双编码器.....	25
M14 OWL-ViT Base Patch32 文本条件区域检测.....	26
M15 BLIP Base Caption 视觉条件自回归描述.....	27
M16 BLIP VQA 图像、问题与答案三段通路.....	28
M17 Depth Anything V2 Small DINOv2 与 DPT 稠密解码.....	29

M18 Swin2SR ×2 窗口 Transformer 超分辨率.....	30
M19 Restormer 真实去噪 多尺度通道注意力恢复.....	31
M20 Restormer 运动去模糊 相同家族、不同任务权重.....	32
M21 U2NetP 嵌套 U 形显著前景网络.....	33
M22 R3D18 三维残差视频分类.....	34
第 01 模块 图像基础.....	35
001 像素与取色 (pixels)	35
002 灰度化 (gray)	36
003 颜色空间转换 (color)	37
004 通道分离 (channel)	38
005 通道合并 (merge)	40
006 加法 (add)	41
007 减法 (subtract)	42
008 加权融合 (blend)	43
009 按位与 (bit_and)	44
010 按位或 (bit_or)	46
011 按位异或 (bit_xor)	47
012 按位非 (bit_not)	48
013 直方图 (histogram)	49
014 亮度与对比度 (brightness)	50
015 伽马校正 (gamma)	51
016 直方图均衡 (equalize)	53
017 CLAHE 局部均衡 (clahe)	54
018 RGB 颜色空间 (rgb)	55
019 HSV 颜色空间 (hsv)	56
020 Lab 颜色空间 (lab)	58
021 YCrCb 颜色空间 (ycrcb)	59
第 02 模块 滤波与增强.....	60

022 均值滤波 (mean)	60
023 高斯滤波 (gaussian)	61
024 中值滤波 (median)	62
025 双边滤波 (bilateral)	64
026 非局部均值去噪 (nlm)	65
027 自定义卷积核 (convolution)	66
028 锐化 (sharpen)	67
029 傅里叶频谱 (fft)	68
030 频域低通 (lowpass)	70
031 频域高通 (highpass)	71
第 03 模块 阈值与形态学	72
032 固定阈值 (threshold)	72
033 自适应阈值 (adaptive)	73
034 Otsu 自动阈值 (otsu)	74
035 腐蚀 (erode)	76
036 膨胀 (dilate)	77
037 开运算 (open)	78
038 闭运算 (close)	79
039 形态学梯度 (morph_gradient)	80
040 顶帽 (tophat)	81
041 黑帽 (blackhat)	83
042 骨架提取 (skeleton)	84
043 距离变换 (distance)	85
第 04 模块 边缘与形状	86
044 Sobel (sobel)	86
045 Scharr (scharr)	87
046 Laplacian (laplacian)	89
047 Canny (canny)	90

048 轮廓、面积与周长 (contours)	91
049 连通域与质心 (components)	92
050 凸包 (hull)	93
051 形状匹配 (shape_match)	95
052 霍夫直线 (hough_lines)	96
053 霍夫圆 (hough_circles)	97
054 轮廓面积 (contour_area)	98
055 轮廓周长 (contour_perimeter)	99
056 图像矩与质心 (centroid)	100
057 外接框 (bounding_box)	102
第 05 模块 几何与传统分割.....	103
058 ROI 裁剪 (crop)	103
059 缩放与插值 (resize)	104
060 旋转 (rotate)	105
061 仿射变换 (affine)	106
062 透视变换 (perspective)	108
063 图像配准 (register)	109
064 区域生长 (region_grow)	110
065 分水岭 (watershed)	111
066 GrabCut 前景分割 (grabcut)	112
067 颜色聚类分割 (kmeans_segment)	113
第 06 模块 特征与匹配.....	115
068 Harris 角点 (harris)	115
069 Shi-Tomasi 角点 (shi)	116
070 SIFT 特征 (sift)	117
071 ORB 特征 (orb)	118
072 HOG 方向梯度 (hog)	119
073 LBP 局部纹理 (lbp)	121

074 特征匹配 (matching)	122
075 RANSAC 鲁棒匹配 (ransac)	123
076 图像拼接 (stitch)	124
077 模板匹配 (template)	125
078 KNN 小型学习 (knn)	127
079 SVM 小型学习 (svm)	128
080 K-means 小型学习 (kmeans_demo)	129
第 07 模块 工业视觉	130
081 零件计数 (count)	130
082 尺寸、角度与间隙 (measure)	131
083 颜色一致性 (color_check)	133
084 参考图差异 (difference)	134
085 表面缺陷规则 (defects)	135
086 缺件与错装规则 (assembly)	136
087 工业异常热力图 (anomaly)	137
088 字符校验 (char_check)	139
089 工业模板定位 (industrial_template)	140
090 角度测量 (angle_measure)	141
091 间隙测量 (gap_measure)	142
第 08 模块 文字与图文理解	144
092 二维码识别 (qr)	144
093 条码识别 (barcode)	145
094 文字检测与识别 (ocr)	146
095 版面分析 (layout)	147
096 图像相似度检索 (similarity)	149
097 图文检索 (text_retrieval)	150
098 文字提示目标检测 (grounding)	151
099 图像描述 (caption)	152

100 视觉问答 (vqa)	154
第 09 模块 深度学习识别.....	155
101 图像分类 (classify)	155
102 目标检测 (detect)	156
103 旋转框检测 (obb)	158
104 实例分割 (instance)	159
105 人体姿态 (pose)	160
106 语义分割 (semantic)	161
107 全景分割 (panoptic)	163
108 交互式分割 (sam)	164
109 人脸关键点 (face)	165
110 手部关键点 (hand)	167
第 10 模块 标定与三维.....	168
111 单目相对深度 (depth)	168
112 相机标定 (calibrate)	169
113 畸变校正 (undistort)	170
114 双目视差与深度 (stereo)	171
115 双目校正 (stereo_rectify)	173
116 双视图基础重建 (reconstruct)	174
117 点云查看、滤波与配准 (pointcloud)	175
第 11 模块 图像恢复.....	176
118 深度学习超分辨率 (superres)	176
119 深度学习去噪 (denoise_dl)	178
120 深度学习去模糊 (deblur)	179
121 前景抠图与背景替换 (matting)	180
122 低光增强 Retinex (lowlight)	181
123 图像修复 (inpaint)	182
第 12 模块 视频与时序.....	184

124 视频动作识别 (action)	184
125 帧差 (frame_diff)	185
126 背景建模 MOG2 (mog2)	186
127 稀疏光流 (flow_sparse)	187
128 稠密光流 (flow_dense)	188
129 单目标跟踪 (single_track)	190
130 多目标跟踪与轨迹 (multi_track)	191
131 计数、越线、区域与停留 (events)	192
132 事件顺序规则 (sequence)	193
133 视频分割 (video_segment)	195
第 13 模块 模型学习与评估.....	196
134 Grad-CAM 类激活图 (gradcam)	196
135 特征图可视化 (feature_maps)	197
136 推理后端对比 (benchmark)	198
137 预处理与数据增强 (augmentation)	200
138 分类指标 (eval_classification)	201
139 检测 AP / mAP (eval_detection)	202
140 分割 IoU / Dice (eval_segmentation)	203
资料来源与核对说明.....	205

学习方法与共同基础

阅读范围：当前 Vision Lab 的 140 个算法实验入口，而非 140 篇互不相关的论文。有些入口共享底层算法，例如角度、间隙与综合测量，但本书仍逐项说明它们的不同测量对象和易错点。

读公式前先明确量的含义

本书 I 表示图像强度或颜色向量， M 表示掩膜， $H/W/C$ 表示高、宽、通道数；卷积核中的 k 与聚类数 K 依章节另作解释。 Σ 表示求和， $\|\cdot\|_2$ 是欧氏范数， $1[\text{条件}]$ 在条件成立时取 1， ϵ 是避免除零的小量。公式是理论或教学表达；凡项目存在截断、归一化、简化或不同配置，正文另行说明。

一条公式要回答四件事：输入是什么、输出是什么、变量单位是什么、什么条件下成立。例如 $Z=fB/d$ 要求校正双目、像素焦距与有效视差；仅背公式而忽略这些条件，计算结果可能没有物理意义。

先分清图像、标签与可视化

普通图像数值描述编码颜色，类别标签数值只是类别编号，深度与距离数组则有自己的量纲。彩色热图通常经过归一化和色表映射，同一个红色在不同图片中可能代表不同原始值。实验应同时记录输入、参数、原始数组和显示图，不从显示颜色直接推导测量结论。

`uint8` 只能表示 0–255，算术前先决定是否需要有符号或浮点类型。裁剪、取绝对值、阈值和整数转换都可能不可逆。图像坐标以左上角为原点，数组使用先行后列，所有 ROI、提示点和检测结果都要确认处于哪张图的坐标系。

从滤波到分割：信号与决策是两步

滤波估计局部信号，梯度量化变化，阈值才把连续数值转为离散决策。增强后的噪点更明显不等于出现新缺陷，平滑后边缘更完整也不等于尺寸更准确。选择参数要参照噪声尺度、目标最小结构和允许测量误差。

建立小型对照实验：固定素材，只改一个参数，记录目标保留、误检、边界位置与耗时。需要比较算法时保持分辨率、预处理及评价口径一致；不要为每个方法挑选不同的最有利输入。

神经网络的五段数据流

预处理定义模型实际看到的输入；backbone 提取视觉特征；neck 或 decoder 融合尺度与恢复空间；head 将特征映射为任务输出；后处理把输出变成可用结果。不同架构可以省略某段或让其职责重叠，但这五个问题始终有助于阅读模型。

分类头输出整图 logits；检测头增加框；语义头保留每像素类别竞争；实例头区分同类对象；语言解码头逐 token 生成文本。网络训练损失、推理分数、用户阈值是三个不同概念，不能把任何输出都称为经过校准的概率。

卷积、残差与尺寸变化

卷积输出尺寸可写为 $\text{floor}((H+2p-d(k-1)-1)/s+1)$ ，其中 p 为 padding、 d 为 dilation、 k 为核宽、 s 为 stride。参数量与输入输出通道、核面积有关；逐通道卷积先独立处理通道，再用 1×1 混合，可减少计算。

残差连接直接相加，要求张量尺寸相容；拼接则增加通道维，需要后续投影。下采样扩大感受野并节省计算，但细小对象可能丢失。U 形跳接把浅层空间细节送回解码器，特征金字塔则在多个尺度交换语义与位置。

注意力、token 与恢复网络

标准注意力可写为 $\text{softmax}(QK^T/\sqrt{d})V$ 。Q 指定查询，K 用于匹配，V 提供聚合内容；多头让不同子空间学习不同关系。图像切为 patch token 后仍需位置编码，否则仅集合式比较无法充分表达位置。

全局空间注意力的矩阵随 token 数平方增长。Swin 类在窗口内计算并移动窗口建立跨区联系；Restormer 的 MDTA 主要建立通道间注意力，计算对象不同。CLIP 独立编码两种模态后比较向量，BLIP 则在交叉注意力中让文本读取图像，两者不能只因都含 Transformer 就视为同一架构。

训练、推理与实验边界

本项目的深度学习入口主要运行已训练权重，本书讨论训练目标是为解释架构，不表示平台在每次实验中重新训练网络。`eval()` 改变 BatchNorm、Dropout 等行为；`no_grad()/inference_mode()` 控制梯度记录；Grad-CAM 需要梯度，但网络仍可处于 eval 模式。

训练集拟合、独立验证和上线分布是不同层次。正常样本库、阈值或超参数若使用测试集调过，就不能再把该测试集结果当完全独立证据。模型 ID 只是资源名称，以本地加载代码和配置确定真正架构。

怎样使用两册进行学习练习

先阅读一项原理，用自己的话画出输入到输出流程，再手算公式中的一个小例子，并在平台运行建议实验。合上学习册，按题号作答，最后到答案册对照。答案给出关键结论和理由，不要求逐字背诵；若采用不同但成立的假设，应说明前提。

每题可自评 0–3 分：0 分无法回答，1 分只记住结论，2 分说明机制，3 分同时说明边界或项目实现差异。每算法满分 18 分。算法 ID 与题号在两册保持一致，即使排版页码不同也可直接定位。

模型架构专题：22 套本地模型

本专题覆盖所有使用预训练模型的算法，包括工业异常、图文理解、图像恢复、视频动作和模型解释。先按数据流认识组件，再到对应算法理解任务损失、输出语义和使用边界。模型编号 M01–M22 是架构定位键。

按输出形态建立阅读路线

先读 M01，掌握卷积、残差 stage 与分类头。接着读 M02–M05，比较同一检测家族如何增加旋转角、掩膜原型和关键点分支。M06–M08 则比较语义类别图、全景集合预测和提示式区域选择，理解“输出都是掩膜”并不意味着网络结构和监督目标相同。

M09–M12 关注流水线：人脸和手部先定位 ROI 再回归，OCR 先检测文字再识别，版面检测先划分页面区域。分析误差时，要判断出错来自哪一级，以及前一级的裁剪、缩放误差如何传给后一级。

M13–M16 依次比较向量检索、文本条件检测、图像描述和视觉问答。重点观察文字在哪里进入网络：独立编码后比较、与局部视觉特征匹配，还是通过交叉注意力参与逐 token 生成。

M17–M22 面向深度、清晰图像、显著前景与视频动作。比较稠密解码、窗口注意力、通道注意力、嵌套 U 形结构和三维卷积，说明它们分别怎样恢复空间细节或引入时间信息。

从框图走到可解释的架构

每读一套模型，至少标注输入与输出形状、空间下采样位置、特征合并方式、任务头的预测量，以及后处理的坐标变换。再选择一个组件，说明移除它会失去什么能力。例如去掉时间卷积会削弱运动建模，去掉提示编码器会失去用户指定区域的输入通道。

同一家族的训练目标和权重也需区分：真实去噪与运动去模糊都使用 Restormer，但不能因此任意交换检查点；分类用到 ResNet18，异常记忆库和 Grad-CAM 则复用它的不同中间特征或梯度。下面的架构专题与后面的实验原理应结合阅读。

M01 ResNet18 | 残差卷积分类骨干

资源 ID: resnet18



图 M01 模块数据流（教学示意）

输入与 stem：常规分类使用权重配套缩放、中心裁剪和标准化。224×224 输入经 7×7、步长 2 卷积得到 64×112×112，再经最大池化得到 64×56×56。

残差 stage：layer1–4 分别含两个 BasicBlock，典型输出依次为 64×56×56、128×28×28、256×14×14、512×7×7。每块主支路是两次 3×3 卷积及归一化、激活；降采样时捷径用投影匹配尺寸。

分类输出：全局平均池化把每个通道压成一个数，512 维向量经全连接得到 1000 个 logits。训练常用交叉熵，推理 softmax 后选 top5；softmax 不改变最大类别排序。

项目任务分支：anomaly 取 layer2 和 layer3，将后者上采样到 28×28，再拼为 384 通道并局部平均池化；gradcam/feature_maps 取 layer4。它们使用同一骨干，但后处理与预处理不等于分类入口。

架构取舍：残差连接改善优化和特征复用，深层下采样增强语义却降低空间精度；因此不能直接把最后一层格点当原图精确轮廓。

来源：backend/app/models.py、backend/app/inference.py；R02。

M02 YOLOv8n | 单阶段多尺度检测

资源 ID: yolov8n



图 M02 模块数据流（教学示意）

输入与骨干：项目图像检测 `imgsz=640`。按比例缩放并填充后，步长卷积逐级下采样，C2f 将特征分支经过瓶颈再拼接，SPPF 在深层以串联池化汇聚不同感受野。

颈部：上采样与横向拼接把深层语义传给高分辨率层，再以下采样路径融合定位信息，形成典型 P3/P4/P5 检测特征。640 的方形输入对应约 80×80 、 40×40 、 20×20 网格。

解耦头：每个尺度有类别与框回归通路。anchor-free 使用特征网格参考点，框距离采用分布式回归表达；它不应被讲成旧 YOLO 的固定 anchor 加独立 objectness 五参数格式。

训练与推理：训练使用任务分配、分类损失、IoU 类定位损失和 DFL 等；推理解码候选，做置信度过滤与 NMS，再将坐标反映射到原图。NMS 阈值与展示 confidence 是不同参数。

项目扩展：`multi_track` 在框后增加关联器，`events` 再增加事件状态，`sequence` 再增加顺序状态机；这些规则层不属于 YOLO 神经网络内部。

来源：backend/app/inference.py、backend/app/video.py；R03、R04。

M03 YOLOv8n-OBB | 旋转目标框

资源 ID: yolov8n-obb




图 M03 模块数据流（教学示意）

共享特征：继承 Conv、C2f、SPPF 和多尺度融合，让不同大小目标获得合适分辨率的表示；这部分作用与水平检测相同。

任务头：在分类和边界几何之外增加角度预测，得到带方向的矩形。参数表示存在宽高交换和角度周期，不应把某个角度数字与物体头尾方向直接等同。

几何后处理：旋转框可转为四顶点，重叠和筛选需考虑旋转形状，不能只用水平外包框代替完整几何。

项目权重：yolov8n-obb.pt 面向 DOTA 15 类航拍对象。架构支持旋转检测与权重已学工业类别是两个不同命题。

学习重点：能够画出共享骨干到三个任务输出的分支，解释为何对称目标的方向难监督，以及框 IoU 与角度表示之间的关系。

来源：backend/app/inference.py、docs/MODELS.md；R03。

M04 YOLOv8n-Seg | 原型式实例分割

资源 ID: yolov8n-seg




图 M04 模块数据流（教学示意）

检测通路：共享骨干与颈部仍输出实例框、类别及分数，用于确定哪些对象需要掩膜。

原型通路：从较高分辨率特征预测 K 张共享原型，官方常见配置为 32 个；原型不对应 32 个语义类别，而是可组合的空间基底。

系数通路：每个实例输出 K 个系数，与原型线性组合形成该实例的掩膜 logits，再进行 sigmoid、框裁剪和阈值处理。具体处理次序需遵循当前适配器。

输出恢复：letterbox 的填充必须正确去除，掩膜按原图宽高恢复。项目保存像素实例标签，单张标签图遇到重叠时无法同时表达同一像素的多个实例归属。

学习重点：理解原型共享为何省计算、掩膜损失与框损失为何并存，以及类别 ID 和实例 ID 的区别。

来源：backend/app/inference.py；R03。

M05 YOLOv8n-Pose | 人体检测与关键点

资源 ID: yolov8n-pose




图 M05 模块数据流（教学示意）

共享主干：多尺度卷积特征同时承载人体位置和局部关节线索，避免为每个点单独跑一套网络。

姿态分支：对每个人预测固定索引的关键点坐标和可见性/置信信息。COCO 配置为 17 点、每点三个相关输出；它并非输出 17 张互不关联的人体类别图。

监督：训练需要人体框与具名关键点标注，通常以位置误差和可见性等目标共同优化；遮挡点的监督规则影响模型能否推断隐藏点。

后处理：关键点经输入坐标变换恢复到原图，平台对低于阈值的点和连线不显示。骨架连接是预定义图，不是网络又预测了一遍人体骨骼拓扑。

学习重点：区分人体实例、关键点语义与时序动作；二维姿态只能描述投影几何。

来源：backend/app/inference.py；R03。

M06 DeepLabV3-MobileNetV3-Large | 轻量语义分割

资源 ID: deeplab



图 M06 模块数据流（教学示意）

骨干组成：MobileNetV3 的倒残差块先用 1×1 扩展通道，再做逐通道卷积，最后投影回较窄通道；部分块包含 SE 通道权重及 h-swish 等激活。深度可分离结构降低计算量。

空间尺度：分割版本在后部使用适当的空洞卷积保留较高分辨率，同时扩大有效感受野。它不是把普通分类输出直接放大。

ASPP：并行 1×1 、不同膨胀率的 3×3 卷积及全局池化分支，统一空间尺寸后拼接、投影，汇集局部与全局上下文。

输出头：卷积输出 21 类（含背景）的 logits。模型带辅助训练分支，项目读取主 out，先上采样 logits 再 argmax；相邻同类对象仍共享类别值。

项目证据：加载函数明确为 `deeplabv3_mobilenet_v3_large`，不能把常见 ResNet 版本架构套进本项目。

来源：backend/app/models.py、backend/app/inference.py；R05。

M07 DETR-ResNet50-Panoptic | 集合预测与像素分配

资源 ID: detr-panoptic



图 M07 模块数据流（教学示意）

卷积与编码：ResNet50 提取图像特征，经 1×1 投影到 Transformer 的 256 维表示，加入二维位置信息后由自注意力编码上下文。局部卷积与全局关系各有分工。

查询解码：可学习 object queries 通过自注意力协调预测槽位，通过交叉注意力读取编码图像。它们是学习参数，不是文字提示或人工标注框。

预测分支：每个查询产生类别和框；掩膜分支结合查询相关空间注意力与多尺度卷积特征恢复区域。分割头保留空间细节，区别于只输出全局分类。

训练与后处理：匈牙利二分图匹配进行集合一对一监督。全景后处理处理掩膜竞争和低分区域，并按类别规则融合同类 stuff，形成 segment ID 与语义类别映射。

本地配置：backbone=resnet50, encoder_layers=6, decoder_layers=6, d_model=256。
区域编号不等于语义编号。

来源：models/detr-panoptic/config.json、backend/app/inference.py；R06。

M08 SAM2 Hiera Tiny | 提示分割与视频记忆

资源 ID: sam2



图 M08 模块数据流（教学示意）

图像编码器：Hiera 逐级提取层级特征，配合特征金字塔式融合，在单图上生成可重复使用的视觉表示；细尺度特征帮助边界，深层特征帮助目标选择。

提示编码器：点坐标和正负标签、框角等生成稀疏提示嵌入，已有掩膜可作为稠密条件。位置编码让“在哪里”与视觉语义一起参与解码。

掩膜解码器：提示 token 与图像特征通过注意力交互，预测候选掩膜及质量估计。多候选用于处理提示歧义，不等于多个固定语义类别。

视频记忆：记忆编码器将历史帧特征与掩膜压缩为目标相关信息；记忆注意力让当前帧读取过去状态，对象指针帮助目标关联。再将本帧结果写入记忆形成循环。

项目使用：sam 为单图交互，video_segment 使用首帧 ROI 和短视频传播。点提示与框并存时优先点，视频限制 150 帧；不能把单图能力与完整视频生命周期混为一谈。

来源：backend/app/inference.py、docs/EXPERIMENTS.md；R07、R08。

M09 MediaPipe Face Landmarker | 检测、ROI 与密集脸部点

资源 ID: face_landmarker



图 M09 模块数据流（教学示意）

检测网络：先在全图中定位脸部，为密集回归提供稳定目标区域，避免每个关键点都在全图搜索。

ROI 归一化：根据检测区域进行裁剪、缩放及必要的方向处理，减弱人脸大小、位置和姿态变化，回归后使用逆变换还原坐标。

关键点网络：利用局部脸部外观与整体形状先验预测稠密点，当前任务包返回 478 个面部点。密集点属于固定语义拓扑，不是身份向量。

任务流水线：MediaPipe 可提供表情或变换等其他输出能力，但本项目主要读取 landmarks。任务包内部卷积层数没有在项目逐层声明，本书不凭模型名称臆造其层数。

边界：归一化 x/y 、相对 z 与真实三维长度不同；严重侧脸或遮挡下，网络可能依赖先验补点。

来源：backend/app/algorithms/teaching.py、docs/MODELS.md；R09。

M10 MediaPipe Hand Landmarker | 手掌定位与 21 点回归

资源 ID: hand_landmarker



图 M10 模块数据流（教学示意）

手掌检测：以较稳定的手掌区域作为定位目标，降低张手、握拳等手指形态变化对初始检测的影响。

关键点回归：在归一化裁图内提取手部特征，预测手腕和每指四点，共 21 点；手性判断用于左右手解释，依赖输入镜像约定。

坐标支路：归一化图像坐标用于绘制，其他世界坐标输出与任务配置相关，不能把任意 z 字段都解释为毫米。项目主要展示图像 landmarks。

视频机制与项目边界：MediaPipe 任务可利用检测与跟踪调度减少重复定位，但当前单图入口不应描述成完整手势识别或跨帧身份跟踪系统。

学习重点：会解释两阶段定位为何更高效、21 点固定拓扑的意义，以及后续手势分类需要额外模块。

来源：docs/MODELS.md、frontend/src/learning/lessons.ts；R10。

M11 PP-OCRv4 / RapidOCR | 文字检测、方向与序列识别

资源 ID: rapidocr



图 M11 模块数据流（教学示意）

检测器：PP-OCRv4 的轻量检测采用卷积特征、多尺度融合与 DB 系列分割检测思路，输出文字概率区域并通过后处理转成四边形。可微二值化主要是训练设计，推理仍需阈值、轮廓等步骤。

方向与裁剪：根据四点透视裁出文字行，方向分类器处理适用的正倒方向。它不等于任意弯曲文字矫正，也不能替代版面分析。

识别器：轻量视觉骨干生成宽度方向的序列表示，SVTR_LCNet 家族融合局部特征与序列上下文，再通过字符分类头给出各步概率；CTC 去除 blank 与路径重复形成字符串。

本地资产：检测和识别文件为 `ch_PP-OCRv4_det_infer.onnx`、`ch_PP-OCRv4_rec_infer.onnx`，方向模型是 `ch_ppocr_mobile_v2.0_cls_infer.onnx`。三个阶段并非同一个大模型。

下游校验：`char_check` 在识别文本之后加入正则 `fullmatch`，是确定性规则层；不能把格式验证说成 OCR 网络内的语义校验。

来源：models/rapidocr/、docs/MODELS.md、backend/app/inference.py；R11。

M12 DocLayout-YOLO | YOLOv10 文档区域检测架构

资源 ID: layout



图 M12 模块数据流（教学示意）

骨干组成：本地权重记录为 `YOLOv10DetectionModel`，对应 `yolov10m-doclayout.yaml`。前段 Conv 与 C2f 提取局部特征，G2L_CRM 在不同层整合上下文，SCDwn 分解通道调整与空间下采样；高层接 SPPF 空间池化和 PSA 部分自注意力。

全局到局部模块：G2L_CRM 先投影并分支，串接若干瓶颈后拼接输出。浅中层的空洞分支使用同一卷积权重、不同 dilation 获得不同感受野，再以门控融合；既覆盖较大版面范围，也保留文字块局部线索。此处“全局”不意味着每层都做全页 Transformer 注意力。

多尺度融合：上采样后的高层特征与骨干较浅层拼接，经过 C2f 细化；再向下采样，用 C2fCIB 等模块融合，形成步长约 8、16、32 的三组特征。小字号区域依赖高分辨率分支，大图片、表格依赖语义较强的低分辨率分支。

任务头与输入：三尺度特征进入 v10Detect，预测区域类别与框；其中 DFL 将边界距离分布转为连续回归值。项目使用 DocStructBench 权重、`imgsz=1024`。多样化合成页面属于训练数据策略，并不是推理网络中的额外输入模块。

输出边界：标题、正文、表格等区域类别不直接提供单元格结构和阅读顺序，后续还需 OCR 与文档结构推断。

来源： `models/layout/doclayout.pt` 的架构元数据、本地 `doclayout_yolo` 配置与 `g2l_crm.py`、`backend/app/inference.py`；R12。

M13 CLIP ViT-B/32 | 视觉与语言双编码器

资源 ID: clip




图 M13 模块数据流（教学示意）

视觉分支：本地图像尺寸 224、patch_size=32，形成 $7 \times 7 = 49$ 个图像 patch，加全局 token 后经 12 层、隐藏维 768、12 头的视觉 Transformer，投影为 512 维。

文本分支：tokenizer 把文本转成 token 并加位置表示，经过 12 层、隐藏维 512、8 头的文本 Transformer。使用序列聚合表示再投影到与图像一致的 512 维空间。

训练目标：对比学习提高正确图文对的相似度、降低错误配对的相似度。温度控制 logits 尺度，归一化使方向关系更突出。

两种实验：similarity 只用图像分支比较图像向量；text_retrieval 使用两个分支。有图库时可先离线缓存视觉向量，文本查询无需重新编码全库。

架构边界：两分支在编码时独立，没有像 VQA 那样逐 token 的图文交叉注意力；也没有框回归或语言生成头。

来源：models/clip/config.json、backend/app/inference.py；R13。

M14 OWL-ViT Base Patch32 | 文本条件区域检测

资源 ID: owlvit




图 M14 模块数据流（教学示意）

视觉分支：本地配置 `image_size=768`、`patch_size=32`、`hidden_size=768`，12 层 12 头 Transformer。保留空间 token，不能像全局检索一样只取一个整图向量。

文本分支：12 层、隐藏维 512 的文本编码器将类别词转成查询向量。当前配置文本最大位置长度较短，长句可能被截断，提示应清楚且紧凑。

任务预测：每个图像区域 token 经分类投影进入文本空间，同时由框头回归位置。分类分数来自区域与文字的匹配，而非预先固定的每类线性权重。

学习过程：图文预训练提供开放词汇表示，检测训练让空间 token 和框头获得定位能力。开放类别形式不意味着所有对象都在训练分布内。

后处理：将相对框恢复为原图尺寸并按阈值筛选；项目输出文本标签与候选框，不产生文字解释。

来源：models/owlvit/config.json、backend/app/inference.py；R14。

M15 BLIP Base Caption | 视觉条件自回归描述

资源 ID: blip




图 M15 模块数据流（教学示意）

视觉编码器：本地为 384 输入、16 像素 patch，隐藏维 768、12 层 12 头，形成带空间关系的图像 token 表示。

文本解码器：隐藏维 768 的 Transformer 使用因果自注意力读取已生成词，用交叉注意力读取图像特征，再经词表头预测下一 token。

预训练与当前任务：BLIP 家族还使用图文对比和匹配目标建立跨模态表示；当前描述权重执行的是条件生成通路，不能说推理每次都运行全部训练目标。

生成阶段：从起始 token 开始，重复预测、选词、追加到上下文，遇结束符或最大长度停止。项目限制 `max_new_tokens=70`。

架构边界：它与 CLIP 的双向量检索不同，能生成新句子但逐步生成更贵；流畅性不代表事实有保证。

来源：models/blip/config.json、backend/app/inference.py；R15。

M16 BLIP VQA | 图像、问题与答案三段通路

资源 ID: blip-vqa




图 M16 模块数据流（教学示意）

图像分支：本地视觉配置为 384 输入、patch16、隐藏维 768、12 层，与描述模型同属 ViT base 家族，但权重任务不同。

问题编码：先获得问题 token 表示，借助视觉交叉注意力把图像证据融入文本状态。问题决定需要从图像中提取哪些信息。

答案解码：答案 Transformer 在融合问题表示的条件下自回归生成 token，其输出词表和语言先验都参与答案形成。

训练与推理：使用图像、问题、答案关系学习，推理必须同时提供图像和问题。不能只把问题拼到一个与图像无交互的文本分类器中。

模型边界：没有显式逐对象计数约束或 OCR 校验模块，精确数量、小字和不可见信息容易误答；需用视觉证据复核。

来源：models/blip-vqa/config.json、backend/app/inference.py；R15。

M17 Depth Anything V2 Small | DINOv2 与 DPT 稠密解码

资源 ID: depth-anything




图 M17 模块数据流（教学示意）

编码器：本地 `backbone_config` 为 DINOv2，隐藏维 384、6 头、patch14，从索引 3、6、9、12 等中间阶段取特征。patch 大小决定 token 网格，不等于最终深度分辨率。

重组层：将序列 token 重新排列成二维特征，通过通道投影与空间重采样构建多尺度特征，供稠密预测使用。

融合解码：DPT 风格解码将深层语义与较浅空间结构自粗向细融合，再经卷积预测一通道结果，并恢复到输入显示尺度。

训练知识与尺度：模型从大量图像及深度监督/伪标签学习相对几何先验；本项目权重输出相对逆深度，架构没有输入双目基线。

学习重点：能说明全局语义为何帮助理解远近，及为何网络输出密集数值仍不自动具有米制尺度。

来源：models/depth-anything/config.json、backend/app/inference.py；R16。

M18 Swin2SR ×2 | 窗口 Transformer 超分辨率

资源 ID: edsr



图 M18 模块数据流（教学示意）

本地配置：model_type=swin2sr、embed_dim=180、depths=[6,6,6,6,6,6]、每组 6 头、window_size=8、upscale=2。配置里的 patch_size=1 不应理解为 ViT 大块切图。

浅层与深层：卷积保留局部低级特征，残差组内交替使用窗口与移位窗口注意力，结合 MLP、归一化和残差连接；组外卷积进一步融合图像特征。

SwinV2 要点：注意力采用更稳定的相似度与位置偏置设计，窗口限制交互范围，移位使相邻窗口连通。不是每层对所有图像像素做全局注意力。

重建头：把特征转换为可上采样的通道，再通过像素重排等重建操作生成宽高两倍的 RGB。其任务是从退化图恢复细节，不含目标分类头。

项目分块：以 128 尺寸块、112 步长处理并重叠平均，最终宽高严格 ×2；同一模型整图和分块上下文不完全相同。

来源：models/edsr/config.json、backend/app/inference.py；R17、R18。

M19 Restormer 真实去噪 | 多尺度通道注意力恢复

资源 ID: swin-denoise



图 M19 模块数据流（教学示意）

配置与尺度：基础通道 48，编码/潜层块数 [4,6,6,8]，头数 [1,2,4,8]；下采样通过卷积和 PixelUnshuffle，空间减半、通道增大，解码通过 PixelShuffle 逐级恢复并拼接编码特征。

MDTA：1×1 卷积产生 Q/K/V，3×3 深度卷积引入局部空间信息；将空间展平后，注意力矩阵建立在每头通道维上。空间信息仍用于相关性估计，并非完全忽略空间。

GDFN：1×1 投影扩展通道，深度卷积后分成两路，一路经 GELU 与另一路逐元素相乘，再投影回原通道。门控选择特征，扩展系数 2.66。

残差块：每个块依次执行归一化+MDTA 的残差更新、归一化+GDFN 的残差更新；末端四个细化块与 RGB 输出卷积完成恢复。

去噪特有配置：BiasFree 归一化按本地实现除以标准差并乘权重，不等同于只删掉常规 LayerNorm 偏置；真实去噪权重与运动去模糊权重不能互换。

来源：models/swin-denoise/config.yml、models/swin-denoise/restormer_arch.py；R19、R20。

M20 Restormer 运动去模糊 | 相同家族、不同任务权重

资源 ID: restormer



图 M20 模块数据流（教学示意）

层级配置：dim=48、num_blocks=[4,6,6,8]、heads=[1,2,4,8]，包含编码、潜层、对称恢复与细化阶段。深层大感受野有助建模较宽运动拖影，浅层跳接保留细节。

核心模块：MDTA 计算通道相关性，GDFN 以门控和深度卷积处理非线性局部信息；两者都处于残差块中，区别于普通空间全局 Transformer。

输出：通过 RGB 卷积预测相对输入的恢复修正，再与输入组合。训练使用模糊/清晰成对数据，学习的逆退化先验不同于去噪。

配置差异：该权重使用 WithBias 归一化，包含减均值、标准差归一化与仿射偏置；即使大部分结构相同，也必须保持与权重匹配。

项目推理：256 分块、224 步长及边缘填充/重叠平均控制内存。模型不显式输出可解释的物理模糊核，也不能保证恢复被完全抹除的信息。

来源：models/restormer/config.yml、models/restormer/restormer_arch.py、backend/app/inference.py；R19、R20。

M21 U2NetP | 嵌套 U 形显著前景网络

资源 ID: rmbg



图 M21 模块数据流（教学示意）

RSU 内部：先进行局部卷积，再在块内部执行小型编码解码路径，汇集不同感受野，最后与块输入特征作残差融合；深层可借助空洞卷积减少继续下采样。

外层 U 形结构：编码器降低空间分辨率、提取语义，解码器逐级上采样并与对应编码特征拼接，恢复前景边界。P 版本是轻量通道配置。

侧输出：不同解码层产生显著性预测，上采样到共同尺寸后融合，训练可通过深监督约束多个尺度。

项目合成：ONNX 输出经 min-max 归一化、恢复原图大小，转换为 alpha，再与新背景混合；这一步不等于网络已求解真实前景颜色 F 。

能力边界：显著主体与物理透明度是不同目标，发丝、玻璃和旧背景混色需要更专门抠图方法。

来源：backend/app/inference.py、docs/MODELS.md；R21。

M22 R3D18 | 三维残差视频分类

资源 ID: r3d



图 M22 模块数据流（教学示意）

输入：张量为 $B \times 3 \times T \times H \times W$ ，时间维保持帧次序。统一空间裁剪和标准化后，同一像素位置在不同帧形成可学习的时序局部结构。

骨干：stem 采用时间与空间卷积，后续 BasicBlock 用 $3 \times 3 \times 3$ 卷积联合提取短时运动和外观；四个 stage 通道通常为 64、128、256、512，每组两个残差块。

下采样与池化：随层级减少空间和适用时间分辨率以扩大感受野，最后对时空维平均，得到片段级向量，而不是每帧或每人独立输出。

分类头：全连接输出 Kinetics-400 动作 logits，softmax 形成候选排名。训练需要视频片段标签，不等于只用单张姿态图监督。

项目限制：连续 16 帧窗口是实际输入单位，至少需满足片段长度。片段时长取决于 fps，通用动作类别不能直接替代工业事件规则。

来源：backend/app/models.py、docs/EXPERIMENTS.md；R22。

第 01 模块 图像基础

001 像素与取色 (pixels)

实验输入：image。用途：取色、曝光检查、定位数据错误。

学习目标与直观理解

把图片放大后，可以把它想成一张由彩色小格子组成的表。这个实验读取你选中那一格的颜色，帮助你把“看起来是什么颜色”和具体数值对应起来。

每个像素有红、绿、蓝三个分量。横坐标 x 从左向右增加，纵坐标 y 从上向下增加；程序取数组时先写行 y ，再写列 x 。

核心机制与推导

图像不是连续平面，而是在空间网格上采样、在数值轴上量化的信号。 $H \times W \times C$ 中 H 是行数， W 是列数， C 是通道数；坐标写作 (x,y) ，数组访问却是 $I[y,x,c]$ 。8 位量化只有 256 个等级，显示器插值放大的中间颜色不一定是原始像素。读取之前还要统一 EXIF 方向、通道顺序和数据类型，否则同一个数字会被解释成不同颜色。单像素容易受噪声影响，工程取色宜同时看邻域均值、方差和饱和像素比例。

$I[y,x]=[B,G,R]$ ； $0 \leq x < W$ ， $0 \leq y < H$ ；邻域均值 $\mu = (\sum I)/N$ ，方差 $\sigma^2 = \sum (I - \mu)^2 / N$ 。

参数、实验与结果解读

项目默认参数： $x=0$ ； $y=0$ 。

建议实验：在平坦区、物体边缘和高光各取一点，记录 RGB 与邻域波动；放大画面后在同一原图坐标复测。

结果解读：十字标记是采样位置。到“结果数据”查看 RGB、HSV 和 gray：RGB 分量通常在 0-255 之间，值越大表示该颜色分量越强。

边界与误区：在亮部、阴影和边界各取一个点比较。一个点只能说明局部颜色；缩放图片不会改变它在原图中的坐标。

学习练习（答案见独立答案册）

Q001-1 图像坐标 (30,20) 如何访问数组？

Q001-2 BGR=[10,20,200] 对应哪个 RGB？

Q001-3 图片放大两倍后点击坐标怎样换算？

Q001-4 为什么一个像素不适合判断产品颜色？

Q001-5 8 位图转浮点后信息会增加吗？

Q001-6 EXIF 旋转会影响取色坐标吗？

002 灰度化 (gray)

实验输入：image。用途：边缘、阈值和形状分析的前处理。

学习目标与直观理解

把彩色照片变成一张只有明暗的图片，让后续算法专心判断轮廓和亮度。例如，检测纸上的黑字时，往往先做灰度化。

不是简单地去掉颜色，而是把红、绿、蓝按不同权重合成一个亮度值。人眼对绿色更敏感，所以绿色通常占更大权重。每个像素最终只剩一个数。

核心机制与推导

灰度化把三维颜色向量投影到一条亮度轴，属于多对一映射，因此一般不可逆。常用加权体现人眼对不同颜色的敏感程度，而不是三个通道等权。工程中的 BGR2GRAY 通常直接对编码后的通道加权，得到便于处理的亮度近似；它不等于经过线性化和光度标定的物理亮度。降到单通道可减少后续存储和计算，但不同颜色落到相同灰度后，任何仅依赖灰度的算法都无法恢复原来的色差。

$Y \approx 0.299R + 0.587G + 0.114B$ ；纯红 [255,0,0] 的灰度约为 76，纯绿约为 150。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：对纯红、纯绿、纯蓝色块灰度化，再找两块不同颜色但接近灰度的色块，比较阈值分割结果。

结果解读：白色表示亮度高，黑色表示亮度低。对照原图，观察不同颜色变成了哪一种灰色。

边界与误区：红色和绿色也可能变成相近的灰色。如果目标只靠颜色区分，转灰度后可能再也分不开，应考虑颜色空间或通道分离。

学习练习（答案见独立答案册）

Q002-1 为什么绿色权重最大？

Q002-2 灰度化与通道分离有什么区别？

Q002-3 能由灰度图唯一恢复 RGB 吗？

Q002-4 灰度化后目标消失怎么排查？

Q002-5 三通道相同的图与单通道灰度等价吗？

Q002-6 灰度值翻倍代表光能翻倍吗？

003 颜色空间转换 (color)

实验输入：image。用途：颜色分割、白平衡、光照分析。

学习目标与直观理解

同一种颜色可以用不同“坐标系”描述。这个实验把彩色图转换为 RGB、HSV、Lab 或 YCrCb，帮助你找到更适合分割或分析的通道。

RGB 描述三种颜色的强度；HSV 拆成色相、鲜艳程度和明暗；Lab、YCrCb 则分别用亮度和颜色差异描述像素。转换改变的是表达方式，不是识别物体。

核心机制与推导

颜色空间转换是重参数化：RGB 适合设备通道，HSV 便于按色相筛选，Lab 用非线性变换近似分离明度与对立色，YCrCb 则将亮度与色差分量分开。转换选择取决于任务希望保留或弱化哪种变化；没有空间能完全消除照明影响。浮点和整数编

码范围并不相同，例如 Lab 的 8 位结果含缩放和偏移。平台把三个通道横向拼成灰度面板，它是数值诊断图，不是将编码数组直接作为正常 RGB 显示。

转换可写作 $z=f(R,G,B)$ ；解释 z 必须同时注明空间、通道顺序、数据类型和范围。

参数、实验与结果解读

项目默认参数：space=HSV。

建议实验：对同一物体的亮面与阴影分别记录 RGB、HSV、Lab、YCrCb，比较哪个分量对照明变化更稳定。

结果解读：结果从左到右是三个通道的灰度图，不是一张正常彩照。结合“结果数据”的 space 和 ranges 确认通道及数值范围。

边界与误区：在阴影和亮区观察哪个通道变化小，那个通道可能更适合按颜色找目标。不同空间的通道不能直接按 RGB 数值解释。

学习练习（答案见独立答案册）

Q003-1 颜色转换与通道重排有什么不同？

Q003-2 为什么 HSV 图直接显示会颜色怪异？

Q003-3 浮点转换前为什么要检查范围？

Q003-4 哪种空间适合固定颜色阈值？

Q003-5 换颜色空间能恢复过曝细节吗？

Q003-6 判断转换是否正确可以做什么实验？

004 通道分离 (channel)

实验输入：image。用途：颜色缺陷分析和单波段检测。

学习目标与直观理解

只看红、绿、蓝中的一个分量，找出哪个通道最能突出目标。例如红色印刷图案与背景在某个通道上可能差别更明显。

彩色图像的每个位置存着三个数，通道分离就是取出同一位置的某一个数，排列成灰度图。

核心机制与推导

通道分离是在保留空间坐标的前提下选择某个分量，没有邻域运算，也不改变几何结构。选通道的依据是目标和背景的可分性，而非目标本身是否很亮。若两者在红通道都很亮，该通道仍难以分割。可比较两类的均值差与类内噪声；某个通道信噪比较低时，亮度对比虽大也未必稳定。通道切片可能共享原数组内存，后续原地写入时应区分视图与副本。

$C_R(y,x)=I(y,x,2)$ (BGR)；可分性示意 $J=(\mu_{\text{目标}}-\mu_{\text{背景}})^2/(\sigma_{\text{目标}}^2+\sigma_{\text{背景}}^2+\epsilon)$ 。

参数、实验与结果解读

项目默认参数：channel=R。

建议实验：对红色印刷标记依次查看 R/G/B，记录目标和背景均值、波动，选一个稳定阈值验证。

结果解读：亮表示所选通道的数值大。依次切换 R、G、B，比较目标与背景的明暗差。

边界与误区：最亮的通道不一定最好；目标和背景差异最大、内部较均匀的通道才更方便分割。

学习练习（答案见独立答案册）

Q004-1 红色目标应该总选红通道吗？

Q004-2 分离后的亮区就是该颜色区域吗？

Q004-3 为什么切片修改可能改变原图？

Q004-4 如何定量选择通道？

Q004-5 单通道比 RGB 一定信息更好吗？

Q004-6 BGR 数据取索引 0 得到什么？

005 通道合并 (merge)

实验输入：image。用途：白平衡、颜色一致性调整。

学习目标与直观理解

分别调节红、绿、蓝的强度，观察图像怎样偏红、偏绿或偏蓝，可用来理解白平衡。

每个通道乘以自己的增益后重新组合。增益 1 保持原样，0 去掉该通道，大于 1 增强该通道；超过 255 的部分会截断。

核心机制与推导

标准通道合并把多个同尺寸平面组合成多通道图；本平台的入口进一步对原图三个通道分别乘增益。数学上这是颜色向量的对角线性变换，常用于模拟白平衡。应先转浮点再乘，最后限幅并转换为 uint8，防止整数计算产生回绕。通道增益能补偿简单色偏，却不能替代完整色彩标定；一旦某通道超过上限被截断，多个不同输入都变成 255，反向降低增益也恢复不了细节。

$[B', G', R'] = \text{clip}([gB \cdot B, gG \cdot G, gR \cdot R], 0, 255)$ ；增益 1 保持，0 置零。

参数、实验与结果解读

项目默认参数：R=1；G=1；B=1。

建议实验：用包含灰卡和高光的图，单独增大 R 增益；同时观察灰卡色偏和高光截断。

结果解读：从一块原本应为白色或灰色的区域观察色偏。一次只改一个通道，更容易看出它的作用。

边界与误区：某个通道过强会出现大片纯色，细节可能已被截断。把增益调回去也无法从已保存的截断图片恢复细节。

学习练习（答案见独立答案册）

Q005-1 本项目的通道合并实际做什么？

Q005-2 三个增益相同会怎样？

Q005-3 为什么先转浮点？

Q005-4 某通道变成 255 后降增益能恢复吗？

Q005-5 白平衡和通道合并等价吗？

Q005-6 三张单通道图合并需满足什么？

006 加法 (add)

实验输入：image、reference。用途：参考差异、合成和掩膜运算。

学习目标与直观理解

把两张图同一位置的颜色值相加，观察叠加后如何变亮，可用于理解图像算术。

每个像素逐通道相加，结果最多为 255。比如 180 加 100 得到 255，而不是绕回较小的数，这叫饱和加法。

核心机制与推导

饱和加法把两张对齐图同位置、同通道的数相加，再将超过表示范围的值压到上限。OpenCV 的 uint8 加法与普通 NumPy uint8 相加不同：后者常按模 256 回绕。饱和处理符合常见图像显示需求，但不满足普通实数加法的可逆性。用于叠加亮度时应检查饱和比例；若希望物理合成光信号，需要在线性光域处理并保留足够动态范围，而不能把编码图片直接相加视为真实曝光叠加。

$C = \min(A+B, 255)$ ；例如 $180+100 \rightarrow 255$ ，而 uint8 模运算结果为 24。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：选择两个重合亮块，分别用饱和加法、浮点相加和平均融合，比较直方图最右端的堆积。

结果解读：重合的亮区会更亮，接近白色的区域可能失去纹理。两张输入必须尺寸相同。

边界与误区：加法不等于平均融合。如果想保留两张图的层次，比较“加权融合”的结果。

学习练习（答案见独立答案册）

Q006-1 OpenCV 与 NumPy 的 uint8 加法为何不同？

Q006-2 200 与 100 饱和相加是多少？

Q006-3 相加后为何纹理消失？

Q006-4 两图尺寸相同就能合理相加吗？

Q006-5 饱和加法后减去第二张能还原吗？

Q006-6 相加与平均融合适合什么场景？

007 减法 (subtract)

实验输入：image、reference。用途：参考差异、合成和掩膜运算。

学习目标与直观理解

从原图中减去参考图，突出原图比参考图更亮的部分。

同一位置逐通道相减，小于 0 的结果截为 0。因此 A 减 B 和 B 减 A 通常不同。

核心机制与推导

有向差 $A-B$ 表示变化方向，但 uint8 饱和减法把负值变成零，因此平台只显示主图比参考更亮的分量。若要同时研究变亮与变暗，应先转换成有符号整数或浮点，分别统计正负残差；若只关心差异幅度，再取绝对值。因为图像减法高度依赖像素对应，轻微平移就会在边缘形成大残差，光照整体变化也会被解释为内容变化。

$C=\max(A-B,0)$ ； $A=50$ 、 $B=80$ 时 $C=0$ ；有符号残差为 -30 ，绝对差为 30。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：让参考图中的一块变亮、另一块变暗，交换主图与参考，比较饱和差和绝对差的检测范围。

结果解读：亮区代表原图在对应位置较亮。交换两张输入，看哪些差异消失、哪些差异出现。

边界与误区：变暗的差异可能全变成黑色。需要同时找变亮和变暗的位置时，使用“参考图差异”的绝对差。

学习练习（答案见独立答案册）

Q007-1 A-B 和 B-A 相同吗？

Q007-2 如何保留负差值？

Q007-3 为什么不能用 uint8 直接做绝对差？

Q007-4 差图出现双边缘意味着什么？

Q007-5 减法能消除不均匀光照吗？

Q007-6 只想找到变暗缺陷应怎么做？

008 加权融合 (blend)

实验输入：image、reference。用途：参考差异、合成和掩膜运算。

学习目标与直观理解

把两张等尺寸图片按比例混在一起，例如把检测图层半透明地叠在原图上。

输出是 $\alpha \times \text{原图}$ 加上 $(1-\alpha) \times \text{参考图}$ 。 α 为 1 时只剩原图，为 0 时只剩参考图，0.5 时各占一半。

核心机制与推导

线性加权融合对相同位置做凸组合。权重和为 1 且权重非负时，结果落在两输入之间，一般不会仅因融合产生更大的动态范围。它与几何对齐是两件事：错位图

像融合会产生双影。彩色图层应按透明度合成，且透明度可能逐像素变化；平台的 α 是全图固定混合系数。若追求正确的光能混合，应先将 sRGB 等非线性编码解码到线性光域，混合后再编码。

$C = \alpha A + (1 - \alpha)B$, $0 \leq \alpha \leq 1$; $A=100$ 、 $B=200$ 、 $\alpha=0.25$, 则 $C=175$ 。

参数、实验与结果解读

项目默认参数： $\alpha=0.5$ 。

建议实验：先融合一对对齐图，再将参考图横移 3 px，观察透明度变化能否消除重影。

结果解读：移动权重，观察同一位置的两种内容怎样交替显现。如果边缘出现双影，先检查图片是否对齐。

边界与误区：混合后的颜色是计算出来的，不代表现场真的出现了这种颜色；它适合显示对比，不适合直接做颜色测量。

学习练习（答案见独立答案册）

Q008-1 $\alpha=0$ 和 $\alpha=1$ 分别显示什么？

Q008-2 为什么两个权重常相加为 1？

Q008-3 融合出现重影应先调什么？

Q008-4 全局 α 与 α 通道有什么不同？

Q008-5 黑白各一半为何未必等于物理中灰？

Q008-6 可以用融合图做精确颜色判定吗？

009 按位与 (bit_and)

实验输入：image、reference。用途：参考差异、合成和掩膜运算。

学习目标与直观理解

学习二值掩膜怎样保留两个区域的共同部分，例如同时满足“亮度合适”和“颜色合适”的位置。

按位与对每个二进制位做比较：两边都是 1 才输出 1。对于只含 0 和 255 的掩膜，可以直接理解为集合的交集。

核心机制与推导

按位与操作每个整数的二进制位，只有两个对应位均为 1 才保留。对 0/255 掩膜，所有位一致开关，因此与运算恰好等价于前景集合交集。对一般灰度数值，它不是取最小值，例如 128 与 127 的位完全不重合，结果为 0。用掩膜截取彩色图时，应使用正确的掩膜参数或扩展维度，避免把 0/1 掩膜当成 0/255 逐位相与而破坏原值。

12 AND 10: $1100_2 \text{ AND } 1010_2 = 1000_2 = 8$ ；二值区域 $A \cap B$ 对应 $M_A \text{ AND } M_B$ 。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：构造圆形与矩形的 0/255 掩膜，观察交集；再把掩膜换成 0/1 并比较逐位运算差异。

结果解读：输入两张二值图时，只有双方都白的位置保留为白色。可以对照检查共同区域。

边界与误区：对普通彩照执行的是数值的二进制运算，不是取较暗颜色，也不是自动抠图。

学习练习（答案见独立答案册）

Q009-1 按位与是否等价于 min？

Q009-2 如何表达同时满足两个分割条件？

Q009-3 0/1 掩膜为何不能直接与 uint8 图像相与？

Q009-4 掩膜尺寸正确但结果错位为什么？

Q009-5 与运算满足交换律吗？

Q009-6 连续叠加更多 AND 条件会怎样？

010 按位或 (bit_or)

实验输入：image、reference。用途：参考差异、合成和掩膜运算。

学习目标与直观理解

把两张二值掩膜中的目标区域合在一起，例如合并两个不同阈值找到的区域。

按位或只要某一位在任一输入中是 1，就输出 1。对 0/255 掩膜来说，这就是区域的并集。

核心机制与推导

按位或将任一输入为 1 的位保留，二值掩膜中对应并集。它适合合并同一语义的多个候选区域，例如红色色相跨越 H 轴两端时合并两段阈值结果。并集不会重复计数交叠像素，但可能把原本分离目标连接起来，导致后续连通域数量下降。对普通照片按位或会合成新的数值，不能理解为自然的图像融合。

$$12 \text{ OR } 10 = 1110_2 = 14; |A \cup B| = |A| + |B| - |A \cap B|。$$

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：合并红色色相的两段掩膜，检查边界处是否遗漏；再合并两个有细桥的区域观察连通域变化。

结果解读：只要任一输入在某处为白，结果该处也为白。两张图共有的区域只会保留一份。

边界与误区：彩色图上的异常颜色来自按位组合；要按区域理解，先把输入变为二值掩膜。

学习练习（答案见独立答案册）

Q010-1 按位或与加法有什么区别？

Q010-2 为什么红色检测常用 OR？

Q010-3 两掩膜重叠部分会变成 510 吗？

Q010-4 并集后物体计数可能减少吗？

Q010-5 OR 会让召回必然提高吗？

Q010-6 OR 适合融合自然彩照吗？

011 按位异或 (bit_xor)

实验输入：image、reference。用途：参考差异、合成和掩膜运算。

学习目标与直观理解

找出两张二值图中不一致的部分，便于比较两次分割的变化。

异或在两边不同的时候输出 1，相同时输出 0。对掩膜而言，只保留恰好属于其中一个区域的像素。

核心机制与推导

异或保留两个输入不同的位。在二值集合中，它是对称差：只属于其中一个集合的像素为前景。它能显示两次分割的分歧，却无法区分哪个是漏检、哪个是误检，必须结合真值方向或分别求差集。分歧面积同时受边界位移和区域大小影响，大目标轻微错位也可产生大量不同像素，因此常需按并集或真值面积归一化。

$$A \oplus B = (A \setminus B) \cup (B \setminus A); |A \Delta B| = |A| + |B| - 2|A \cap B|; A \oplus A = 0.$$

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：将一个矩形掩膜平移 1 px 后求 XOR，观察两侧条带，而不是误认为整块物体变化。

结果解读：白色表示两张掩膜不一致，黑色表示一致。边缘一圈白线可能说明两次分割只相差几个像素。

边界与误区：位置偏移也会产生大量白色差异。先对齐输入，再判断是否真的发生形状变化。

学习练习（答案见独立答案册）

Q011-1 两张相同掩膜 XOR 的结果是什么？

Q011-2 XOR 能直接区分漏检与误检吗？

Q011-3 为什么轻微平移产生两条亮边？

Q011-4 XOR 可逆吗？

Q011-5 用 XOR 比较彩色照片合理吗？

Q011-6 如何比较不同尺寸物体的分割分歧？

012 按位非 (**bit_not**)

实验输入：image。用途：掩膜反选和负片观察。

学习目标与直观理解

将二值掩膜中的前景和背景互换，也可以观察彩照的负片效果。

8 位像素共有 0–255 个取值，逐位取反等价于 255 减原值。因此黑变白，白变黑。

核心机制与推导

对固定 8 位无符号数逐位取反，就是用 255 减去原值。二值掩膜因此交换前景和背景，常用于适配“亮前景”的算法。它没有识别能力，也不改变空间结构。运算含义依赖位宽和类型：16 位无符号数围绕 65535 取反，有符号整数涉及补码；布尔逻辑非则直接翻转 True/False。工程中应先统一掩膜类型，尤其不能把普通灰度负片误当作二值区域补集。

$\text{NOT_uint8}(x)=255-x$ ； $\text{NOT}(100)=155$ ； $\text{NOT}(\text{NOT}(x))=x$ 。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：将黑字白底阈值图取反后做连通域，比较前景极性改变对文字区域数量的影响。

结果解读：二值图中原先被选中的白区会变黑，原背景会变白；反转两次应恢复原图。

边界与误区：取反不会改善曝光，也不会找出新的物体；它只改变已知区域或颜色值的表达。

学习练习（答案见独立答案册）

Q012-1 8 位 100 取反是多少？

Q012-2 逻辑非与按位非是否相同？

Q012-3 取反两次能恢复吗？

Q012-4 什么时候需要先反转掩膜？

Q012-5 负片能补救过曝吗？

Q012-6 uint16 的取反能用 $255-x$ 吗？

013 直方图 (histogram)

实验输入：image。用途：判断曝光、对比度和阈值。

学习目标与直观理解

查看照片中暗像素、中等亮度像素和亮像素各有多少，帮助判断曝光与对比度。

把像素按数值分到 256 个小桶里，每个桶统计次数。图中分别画出 B、G、R 三个通道的分布。

核心机制与推导

直方图把像素分配到数值桶中，只统计出现次数而丢弃位置。归一化后可视作经验概率分布，并通过累积和得到 CDF，为均衡化和阈值选择提供基础。桶数越少越平滑但损失细节，越多越敏感。平台对 B/G/R 各统计 256 桶，绘图高度各自缩放，因此不能从曲线相对高度直接判断哪个通道的绝对像素更多。判断曝光时需结合图像内容，黑背景本来就会在低值处形成峰。

$h(k)=\sum 1[I(x,y)=k]$; $p(k)=h(k)/N$; $CDF(k)=\sum_{j \leq k} p(j)$, $\sum p=1$ 。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：打乱图片的像素位置再比较直方图，验证直方图相同不等于场景相同。

结果解读：横轴越向右数值越大。某条曲线靠左说明该通道暗像素多；贴近两端的堆积可能提示暗部或高光截断。

边界与误区：这里各通道曲线分别缩放高度，精确次数请看结果数据。直方图不记录位置，两张完全不同的照片也可能分布相似。

学习练习（答案见独立答案册）

Q013-1 直方图相同的图像一定相似吗？

Q013-2 怎样判断高光可能截断？

Q013-3 概率直方图与计数直方图有何不同？

Q013-4 为什么平台三条曲线高度不能直接横比？

Q013-5 直方图均值如何计算？

Q013-6 为什么只看全局直方图会漏掉局部问题？

014 亮度与对比度 (brightness)

实验输入：image。用途：光照补偿、预处理。

学习目标与直观理解

分别改变整张图的明暗和亮暗差距，理解曝光补偿与对比度调整。

每个像素先乘 α ，再加 β 。 α 改变像素之间的差距， β 将数值整体上移或下移，最终限制在 0–255。

核心机制与推导

线性亮度变换先缩放再平移， α 控制灰度差的倍率， β 改变整体基线。若希望围绕中灰调整对比度，可以写成 $\alpha(I-m)+m$ ，而平台 $\alpha I+\beta$ 默认围绕零缩放。截断使高低端变成平坦区，也会让“对比更强”与“细节更多”分离。计算必须在浮点域进行；例如 `convertScaleAbs` 包含取绝对值步骤，不能直接代替允许负亮度偏移的 `clip` 实现。

$O=\text{clip}(\alpha I+\beta, 0, 255)$ ；未截断时两像素差 $\Delta O=\alpha \Delta I$ ；围绕 m 调整时 $\beta=(1-\alpha)m$ 。

参数、实验与结果解读

项目默认参数：`alpha=1`；`beta=0`。

建议实验：固定 $\beta=0$ 调 α ，再固定 $\alpha=1$ 调 β ，比较直方图宽度、整体位移与饱和比例。

结果解读：先只改亮度偏移，看整张图是否整体变亮；再只改对比度，看暗区和亮区的差距是否扩大。

边界与误区：大片纯黑、纯白通常表示发生截断。它们看起来对比强，但原有细节可能已经丢失。

学习练习（答案见独立答案册）

Q014-1 α 和 β 分别改变什么？

Q014-2 $\alpha=2$ 、 $\beta=-128$ 有什么含义？

Q014-3 为什么不能直接用 `uint8` 算 $\alpha I+\beta$ ？

Q014-4 提高对比度一定有利于检测吗？

Q014-5 `convertScaleAbs` 与 `clip` 完全等价吗？

Q014-6 曝光补偿与数字加亮有什么区别？

015 伽马校正 (gamma)

实验输入：image。用途：低照度显示、曝光调整。

学习目标与直观理解

主要调整中间亮度，让偏暗照片更容易观察，同时了解非线性亮度变换。

先把数值缩到 0–1，再做 γ 次幂，最后放回 0–255。本实验 γ 小于 1 提亮，大于 1 压暗，1 保持不变。

核心机制与推导

伽马校正先把输入归一化到 0–1，再进行幂变换。它改变不同亮度区间的局部斜率： $\gamma < 1$ 时暗部被拉开， $\gamma > 1$ 时暗部被压缩。平台使用指数 γ ，而有些库用 $1/\gamma$ ，必须通过公式确认方向。对于 8 位图可预先计算 256 个输出值形成查找表，将每像素昂贵的幂运算替换为索引。该操作是通用幂律增强，不应与完整的分段 sRGB 编码曲线混为一谈。

$O = 255 \cdot (I/255)^\gamma$ ；当 $I/255 = 0.25$ 时， $\gamma = 0.5$ 得 0.5， $\gamma = 2$ 得 0.0625。

参数、实验与结果解读

项目默认参数：gamma=0.7。

建议实验：用灰度渐变观察 $\gamma = 0.5$ 、1、2；重点比较暗部噪声和中间调，确认本平台参数方向。

结果解读：对比阴影和中间调的细节，同时留意最黑、最白处变化较小。可以与“亮度偏移”比较。

边界与误区：如果原图某处已经全黑或全白，伽马无法凭空恢复信息；提亮还可能让暗部噪声更明显。

学习练习（答案见独立答案册）

Q015-1 为什么 $\gamma < 1$ 会提亮？

Q015-2 伽马与加亮 β 有何差别？

Q015-3 为什么有的程序 $\gamma > 1$ 反而提亮？

Q015-4 查找表为何适合 8 位图？

Q015-5 γ 校正能恢复纯黑中的细节吗？

Q015-6 多次 γ 变换能合成一次吗？

016 直方图均衡 (equalize)

实验输入：image。用途：雾化、低对比度表面增强。

学习目标与直观理解

让亮度挤在很窄范围里的照片展开层次，例如灰蒙蒙、对比度低的表面。

统计亮度分布后重新分配数值：挤在一起的常见亮度被拉开。本平台只均衡 Lab 的亮度通道，再转回彩色。

核心机制与推导

均衡化利用累积分布函数建立单调映射：出现频繁的亮度段获得更大的输出跨度，从而展开常见灰度之间的差异。离散图像不一定得到完全平坦的直方图，因为相同输入值必须映射到同一输出，且存在量化。平台只对 Lab 的 L 通道做处理，避免分别均衡 RGB 导致明显色相漂移。全局映射无法同时兼顾所有局部区域，低对比噪声也会被放大；均衡不是曝光恢复，也不会创造新的独立信息。

示意映射 $T(k) \approx 255 \cdot \text{CDF}(k)$ ；实现常减去首个非零 CDF 再归一化，以充分使用输出范围。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：对低对比图及含大面积暗背景的图分别均衡，比较目标细节、背景噪声和颜色变化。

结果解读：比较原来难分辨的明暗区域是否更清楚，尤其注意弱对比的轮廓。

边界与误区：全图使用同一映射，噪声可能一起增强。如果局部光照差很大，可与 CLAHE 对比。

学习练习（答案见独立答案册）

Q016-1 为什么采用 CDF 而非直方图高度直接映射？

Q016-2 均衡后直方图为什么不完全平坦？

Q016-3 分别均衡 RGB 有何风险？

Q016-4 对比度很低的噪声为什么变明显？

Q016-5 均衡能用于跨样本定量亮度比较吗？

Q016-6 与 CLAHE 的核心区别是什么？

017 CLAHE 局部均衡 (clahe)

实验输入：image。用途：雾化、低对比度表面增强。

学习目标与直观理解

改善局部对比度，让一张图中偏亮和偏暗的区域都更容易看清。

先把图片分成网格，在每个小区域内调整亮度分布，再平滑连接。对比度上限限制增强力度，避免少量像素被放大得过头。

核心机制与推导

CLAHE 把图像分成网格，在每个网格内统计直方图；将过高的桶裁剪，把溢出的计数再分配，然后构造局部 CDF。限制单桶高度相当于限制局部映射的斜率，抑制平坦区域噪声被无限增强。相邻网格映射经插值作用于像素，降低块边界。平台 grid 表示每个方向的网格数量，不是每块的像素宽度；同一 grid 在不同分辨率下对应不同物理尺度，clip 的数值也要按库的归一化约定理解。

局部变换 $O(x,y)=\sum_j w_j(x,y) \cdot T_j(I(x,y))$ ； $\sum w_j=1$ ， T_j 来自裁剪并重分配后的局部 CDF。

参数、实验与结果解读

项目默认参数：clip=2；grid=8。

建议实验：固定 clip 改 grid，再固定 grid 改 clip；观察阴影纹理、块状感及噪点是否被误增强。

结果解读：观察阴影里的纹理是否更明显，再检查明亮区域有没有变得过硬。网格数和对比度上限影响局部变化。

边界与误区：增强后的细小点可能是噪声，不一定是缺陷。应同时看原图，避免把“更明显”当成“更真实”。

学习练习（答案见独立答案册）

Q017-1 CLAHE 比 AHE 多了哪一步？

Q017-2 grid=8 指 8 像素的块吗？

Q017-3 为什么需要网格间插值？

Q017-4 clip 增大通常怎样影响结果？

Q017-5 CLAHE 后细小亮点都是缺陷吗？

Q017-6 更换分辨率为什么需要重调网格？

018 RGB 颜色空间 (rgb)

实验输入：image。用途：颜色分割、白平衡、光照分析。

学习目标与直观理解

了解一张彩照如何由红、绿、蓝三张强度图合成，适合观察物体主要反射哪种颜色。

OpenCV 读图默认按 B、G、R 排列；转换到 RGB 后，数组顺序才是 R、G、B。通道分离只是取出其中一层，并不识别颜色名称。

核心机制与推导

RGB 用三个基色通道表示颜色，其数值意义还依赖色域、白点与传递函数。存储顺序 RGB/BGR 与具体色彩标准是不同层面的概念。白色区域三个通道都高，红色区域通常 R 相对更高，因此颜色判断应考虑相对关系而非只看 R 是否亮。普通照

片多处于非线性编码空间，在这里直接做均值、混合或距离计算只是工程近似。平台的 RGB 入口展示三个灰度平面，适合检查通道和色偏。

$RGB=(R,G,B)$ ；归一化色度示意 $r=R/(R+G+B+\epsilon)$ ， $g=G/(R+G+B+\epsilon)$ ，低亮度时易受噪声影响。

参数、实验与结果解读

项目默认参数：space=RGB。

建议实验：比较红块、白块、灰块三个通道的响应，再改变曝光观察绝对值与通道比例的差异。

结果解读：左、中、右分别显示 R、G、B。红色物体通常在 R 图中更亮，但白色物体可能在三张图里都很亮。

边界与误区：显示灰度通道是为了比较强度；不要把某张通道图的亮区直接当成该颜色的分割结果。

学习练习（答案见独立答案册）

Q018-1 RGB 与 BGR 是两种不同物理颜色吗？

Q018-2 R 大能断定像素是红色吗？

Q018-3 RGB 欧氏距离等于人眼色差吗？

Q018-4 为什么纯灰三个通道通常接近？

Q018-5 归一化色度能完全消除光照吗？

Q018-6 交换通道后保存时应注意什么？

019 HSV 颜色空间 (hsv)

实验输入：image。用途：颜色分割、白平衡、光照分析。

学习目标与直观理解

想找某种颜色，同时减少明暗变化的干扰时，可以先把颜色拆成色相 H、饱和度 S 和亮度 V。

把颜色想成色环：H 表示在色环上的位置，S 表示颜色有多鲜艳，V 表示有多亮。OpenCV 的 8 位 H 是 0–179，S、V 是 0–255。

核心机制与推导

HSV 由 RGB 的最大分量、最小分量和差值构造。V 取最大值，S 反映最大最小分量的相对差，H 描述哪种分量占主导及其比例。色相是圆周变量， 0° 与 360° 相邻，不能直接用普通减法判断远近。当 S 接近零时，RGB 三通道接近，H 对极小噪声非常敏感，因此颜色阈值通常联合 H、S、V。OpenCV 常用 8 位 H 范围 0–179，浮点编码有不同范围约定。

$M=\max(R,G,B)$, $m=\min(R,G,B)$, $\Delta=M-m$; $V=M$; $M>0$ 时 $S=\Delta/M$; $\Delta=0$ 时色相无稳定意义。

参数、实验与结果解读

项目默认参数：space=HSV。

建议实验：在饱和红色与灰白区加少量噪声，比较 H 波动；用两段 H 联合 S/V 下限分割红色。

结果解读：左图 H 看色相，中图 S 看鲜艳程度，右图 V 看明暗。先比较同一物体在亮处和阴影里的三个通道。

边界与误区：灰白区域的饱和度低，色相不可靠。红色还跨越色环起点，做阈值分割时常需要两段 H 范围。

学习练习（答案见独立答案册）

Q019-1 红色为什么常需要两段阈值？

Q019-2 灰色区域的 H 为什么乱跳？

Q019-3 H=179 与 H=1 差很远吗？

Q019-4 V 等于物理亮度吗？

Q019-5 只限制 H 不限制 S/V 会怎样？

Q019-6 阴影中的同色物体 H 必定不变吗？

020 Lab 颜色空间 (lab)

实验输入：image。用途：颜色分割、白平衡、光照分析。

学习目标与直观理解

把亮度和颜色倾向分开，便于只调整明暗或比较两块表面的颜色。

L 描述亮暗，a 描述绿色到红色的方向，b 描述蓝色到黄色的方向。这里显示的是 OpenCV 的 8 位编码，a、b 的中性位置在 128 附近。

核心机制与推导

CIELAB 从经颜色管理的 RGB 转到 XYZ，再相对参考白点做分段非线性变换，得到明度 L^* 和对立色 a^* 、 b^* 。其目标是让坐标距离更接近感知差异，但并非完美均匀。标准 L^* 通常在 0–100， a^* 、 b^* 以零为中性；OpenCV 8 位编码将 L 缩放至 0–255，并给 a、b 加偏移。计算色差应先恢复正确浮点 Lab 语义，而不能直接把编码字节相减当成标准 ΔE 。

$\Delta E_{76} = \sqrt{[(\Delta L^*)^2 + (\Delta a^*)^2 + (\Delta b^*)^2]}$ ；8 位近似 $L^* = 100L_8/255$ ， $a^* = a_8 - 128$ ， $b^* = b_8 - 128$ 。

参数、实验与结果解读

项目默认参数：space=Lab。

建议实验：对中性灰检查 a、b 是否在 128 附近，再对一对色块用浮点 Lab 计算 ΔE_{76} 。

结果解读：三个面板依次是 L、a、b。L 中的变化主要反映明暗，a、b 中的变化帮助定位不同颜色区域。

边界与误区：编码值不能直接当成真实色差。平台“颜色一致性”实验会先转换为浮点 Lab，再计算色差。

学习练习（答案见独立答案册）

Q020-1 a^* 、 b^* 正负各表示什么？

Q020-2 为什么 8 位 Lab 中性值是 128?

Q020-3 两图 $\Delta L^*=3$ 、 $\Delta a^*=4$ 、 $\Delta b^*=0$ ， ΔE_{76} 是多少?

Q020-4 为什么要固定白平衡再比较色差?

Q020-5 ΔE_{76} 是否能完美预测感知差异?

Q020-6 只改 L^* 完全不会改变最终颜色吗?

021 YCrCb 颜色空间 (yccrb)

实验输入: image。用途: 颜色分割、白平衡、光照分析。

学习目标与直观理解

把亮度与颜色差异拆开，适合学习视频编码中的颜色表达，也可用于部分肤色或颜色区域分析。

Y 表示亮度，Cr 表示红色相对亮度的差异，Cb 表示蓝色相对亮度的差异。这里的顺序是 Y、Cr、Cb。

核心机制与推导

YCrCb 把 RGB 线性组合成亮度近似 Y 与两个色差分量。Cr 衡量红分量相对 Y 的偏离，Cb 衡量蓝分量相对 Y 的偏离；剩余绿色信息可由这三个量反推。亮度与色度分离便于独立处理与压缩，但并不代表对光照完全不变。不同视频标准可能使用不同系数、有限范围和色度采样方式，平台的 OpenCV 图像转换不能直接当作所有视频码流的原始 YUV 布局。

$Y \approx 0.299R + 0.587G + 0.114B$ ；8 位示意 $Cr \approx 0.713(R - Y) + 128$ ， $Cb \approx 0.564(B - Y) + 128$ 。

参数、实验与结果解读

项目默认参数: space=YCrCb。

建议实验: 对红色、蓝色和中性灰分别查看 Y/Cr/Cb，验证中性灰的色差分量在中点附近。

结果解读：左图 Y 通常最像灰度照片；中、右图让亮度相近、颜色不同的区域产生差别。

边界与误区：Cr 或 Cb 亮并不等于目标一定存在。阈值会受相机白平衡和场景光线影响，需要用实际样本确认。

学习练习（答案见独立答案册）

Q021-1 YCrCb 的通道顺序是什么？

Q021-2 为什么 Cr/Cb 要加 128？

Q021-3 Y 与灰度有什么关系？

Q021-4 为什么视频常降低色度分辨率？

Q021-5 固定 Cr/Cb 肤色阈值能适用所有人吗？

Q021-6 YCrCb 与 YUV420 能直接互换吗？

第 02 模块 滤波与增强

022 均值滤波 (mean)

实验输入：image。用途：相机噪声预处理。

学习目标与直观理解

用最简单的邻域平均去掉细小波动，直观认识“平滑”和“变模糊”是一体两面。

把一个像素周围方块内的所有数取平均，替代中心值。核尺寸是这个方块的边长，越大就混入越远的邻居。

核心机制与推导

均值滤波用邻域等权平均替代中心像素，是线性、平移不变的低通滤波。独立零均值噪声平均后方差约降为原来的 $1/N$ ，但边缘两侧也被一起平均，造成边界展宽。核越大，降噪越强，空间细节损失越多。边界填充决定图像四周如何计算；直

接补零会压暗边缘，反射填充通常更自然。可分离实现或积分图能降低大窗口计算量，但输出仍受同样的模糊机制约束。

$O(x,y)=\Sigma \text{ 邻域 } I/N$ ； $k\times k$ 核的每个系数为 $1/k^2$ ；独立同方差噪声平均后 $\text{Var}\approx\sigma^2/k^2$ 。

参数、实验与结果解读

项目默认参数：kernel=5。

建议实验：对带随机噪声的阶跃边缘用 3、7、15 的核，比较平坦区方差和边缘宽度。

结果解读：比较平坦区域的颗粒是否减少，再看文字边缘是否变宽。核为 1 时基本不变。

边界与误区：小瑕疵和噪声都可能被平均掉；不能只看画面是否干净，还要看待检测细节有没有保留。

学习练习（答案见独立答案册）

Q022-1 均值为什么能降噪？

Q022-2 为什么也会损失边缘？

Q022-3 3×3 常量归一核的系数是多少？

Q022-4 补零边界会造成什么？

Q022-5 均值适合椒盐噪声吗？

Q022-6 大核一定需要 $O(Nk^2)$ 计算吗？

023 高斯滤波 (gaussian)

实验输入：image。用途：相机噪声预处理。

学习目标与直观理解

柔和地抑制图像中的小幅噪声，常用于边缘检测前的预处理。

仍然是邻域平均，但离中心越近的像素权重越大。这个“近处更重要”的权重形状叫高斯分布。

核心机制与推导

高斯滤波按空间距离衰减权重，相比均值核具有更平滑的频率响应。二维各向同性高斯可分解为两个一维高斯，先横向后纵向处理能减少运算。 σ 决定真正的平滑尺度，核大小决定截断范围，两者不能混为一谈；平台传 $\sigma=0$ ，让 OpenCV 根据核尺寸推定。连续理论中多次高斯卷积仍为高斯，方差相加，这也是尺度空间的基础。实际离散、截断和边界会使等价关系近似成立。

$G(x,y)=\exp[-(x^2+y^2)/(2\sigma^2)]/(2\pi\sigma^2)$ ； $\sigma_{合成}^2=\sigma_1^2+\sigma_2^2$ ；离散核需归一化。

参数、实验与结果解读

项目默认参数：kernel=5。

建议实验：观察同一细线经不同核尺寸后是否消失，再比较两次小尺度平滑与一次较大尺度平滑。

结果解读：逐渐增大核尺寸，观察平坦处变平滑、细纹理减少以及边缘变软的过程。

边界与误区：大核可能让两条靠得很近的边缘合在一起。如果后面要测窄缝，应检查缝隙是否还存在。

学习练习（答案见独立答案册）

Q023-1 高斯与均值权重有何差别？

Q023-2 σ 和核大小谁控制模糊？

Q023-3 为什么可以分离计算？

Q023-4 两次 $\sigma=1$ 等于一次 $\sigma=2$ 吗？

Q023-5 Canny 前为什么常做高斯？

Q023-6 本平台是否直接暴露 σ ？

024 中值滤波 (median)

实验输入：image。用途：相机噪声预处理。

学习目标与直观理解

去掉像撒上盐和胡椒一样的孤立亮点、暗点，同时尽量保留较明显的边界。

将邻域像素从小到大排序，取中间那个值。极亮或极暗的离群值通常排在两端，不容易影响中间值。

核心机制与推导

中值滤波取局部排序的中间值，是非线性秩统计滤波。少数极大或极小离群值落在排序两端，不会直接支配输出，因此适合椒盐噪声。它通常保留清晰阶跃，但对细线、尖角和小目标仍可能有强烈形态影响。中值不能表示成固定卷积核，不满足叠加性；逐通道中值还可能把不同邻居的颜色分量组合到一起，产生并非任何原像素拥有的颜色。

$O = \text{median}\{I(q); q \in \text{邻域}\}$ ；[0,10,11,12,255]的中值为11，均值为57.6。

参数、实验与结果解读

项目默认参数：kernel=5。

建议实验：给图像加入少量黑白脉冲，对比中值和均值，同时检查一像素细线是否被消掉。

结果解读：重点观察黑白孤立点是否消失，以及边缘是否比均值滤波保留得更清楚。

边界与误区：核过大会消除真实的小点、细线和尖角。随机颗粒噪声也不一定适合用中值处理。

学习练习（答案见独立答案册）

Q024-1 为什么中值抗椒盐噪声？

Q024-2 中值是不是卷积？

Q024-3 窗口为何常用奇数尺寸？

Q024-4 中值能完全保留边缘吗？

Q024-5 彩色逐通道中值有什么问题？

Q024-6 噪声变密后应无限增大核吗？

025 双边滤波 (bilateral)

实验输入：image。用途：相机噪声预处理。

学习目标与直观理解

平滑物体内部的噪声，同时尽量不把边缘两边的不同颜色混在一起。

一个邻居要有较大贡献，既要离中心近，也要颜色相似。跨过明显颜色边界的像素会得到较小权重。

核心机制与推导

双边滤波的权重由空间距离和颜色距离相乘：邻居既要靠近，又要与中心相似。颜色权重使强边缘两侧不容易互相平均，而平坦区仍能降噪。由于权重取决于当前图像，它是非线性滤波。 σ 空间控制影响范围， σ 颜色控制多大的颜色差仍被认为相似；平台将一个 σ 同时传给两者，只能演示联动效果。噪声很强时，中心像素本身不可靠也会影响权重估计。

$$O(p) = \sum_q w(p,q)I(q) / \sum_q w(p,q); \quad w = \exp(-\|p-q\|^2 / 2\sigma_s^2) \exp(-\|I(p)-I(q)\|^2 / 2\sigma_r^2)。$$

参数、实验与结果解读

项目默认参数：kernel=5；sigma=50。

建议实验：固定核逐步提高 sigma，检查平坦区噪声、边缘泄漏和细小划痕的保留程度。

结果解读：先看平坦区域，再看物体轮廓。颜色尺度增大后，差异更大的颜色也参与平均，边缘保护会减弱。

边界与误区：双边滤波并非总能保住细纹理；细小缺陷可能与噪声一起被抹平，而且运算通常比高斯慢。

学习练习（答案见独立答案册）

Q025-1 双边为何能相对保边？

Q025-2 σ 颜色非常大会怎样？

Q025-3 σ 颜色过小会怎样？

Q025-4 为什么它不是普通卷积？

Q025-5 双边一定保留缺陷吗？

Q025-6 本平台 sigma 的调参限制是什么？

026 非局部均值去噪 (nlm)

实验输入：image。用途：相机噪声预处理。

学习目标与直观理解

利用照片中重复出现的纹理帮助去噪，例如多处相似的墙面或表面图案。

它比较的是像素周围的小图块，而不只是单个颜色。在搜索范围内，越相似的图块越能共同决定去噪后的值。

核心机制与推导

非局部均值比较的是中心周围的小图块，而不是单个像素差。搜索窗内，结构相似的图块中心以较大权重参与平均，利用重复纹理的自相似性。patch 窗决定比较结构的范围，search 窗决定从哪里寻找类似样本，h 决定允许的差异。名称中的非局部不意味着默认遍历整张图。平台使用彩色快速 NLM，模板窗 7、搜索窗 21，strength 同时影响亮度与色度去噪。

$w(p,q) \propto \exp(-\|P_p - P_q\|^2/h^2)$ ，归一化后 $O(p) = \sum q w(p,q)I(q)$ ；P 表示局部图块。

参数、实验与结果解读

项目默认参数：strength=10。

建议实验：用有重复纹理的图逐渐增大 strength，检查细纹理保留和涂抹感出现的位置。

结果解读：增加强度后，观察噪声颗粒减少的同时，重复纹理是否仍然自然。

边界与误区：强度太高会产生像涂抹过的区域。与原图对照确认细纹、划痕没有被当作噪声消除。

学习练习（答案见独立答案册）

Q026-1 NLM 与双边最核心的区别？

Q026-2 搜索窗越大一定越好吗？

Q026-3 h 增大有什么后果？

Q026-4 patch 太小有什么问题？

Q026-5 没有重复纹理还能工作吗？

Q026-6 项目中可直接调整哪一类参数？

027 自定义卷积核 (convolution)

实验输入：image。用途：设计边缘、模糊和锐化算子。

学习目标与直观理解

亲手定义“怎样参考周围像素”，用一个小矩阵实现模糊、锐化或边缘增强。

矩阵叫卷积核：每个位置的数是对应邻居的权重，逐项相乘再相加得到新像素。OpenCV 的 filter2D 实际按不翻转核的相关方式计算。

核心机制与推导

离散核对邻域做乘加，核系数决定保留平滑内容、增强细节还是提取方向变化。严格卷积会先翻转核；OpenCV filter2D 执行相关，对非对称核二者不同。核总和是直流增益：和为 1 可保留常量，和为 0 常用于消除常量背景，但这不足以完全判断滤波性质。平台输出仍为 uint8，负响应会截为零；研究导数必须保留浮点响应，并将显示变换与数值计算分开。

相关 $O(x,y)=\sum_{u,v} K(u,v)I(x+u,y+v)$ ；卷积使用 $I(x-u,y-v)$ ；常量输入 c 输出 $c\Sigma K$ 。

参数、实验与结果解读

项目默认参数：matrix=[[0,-1,0],[-1,5,-1],[0,-1,0]]。

建议实验：用非对称差分核处理一条亮暗阶跃，交换阶跃方向并分别查看浮点结果和 8 位结果。

结果解读：先比较默认锐化核和所有元素相等的平均核。观察权重总和对整体亮度、正负权重对边缘的影响。

边界与误区：本实验输出为 8 位图，负值和过大值会被截断。若研究梯度方向，应在 Python 中用浮点输出保留符号。

学习练习（答案见独立答案册）

Q027-1 filter2D 是严格数学卷积吗？

Q027-2 核总和为 0 表示什么？

Q027-3 为什么导数结果要用浮点？

Q027-4 锐化核和为 1 为什么仍增强边缘？

Q027-5 边界处理会改变结果吗？

Q027-6 可分离核有什么计算优势？

028 锐化 (sharpen)

实验输入：image。用途：纹理、文字增强。

学习目标与直观理解

增强文字和纹理附近的明暗差，使边缘看起来更清晰。

先将原图模糊，再用原图减去模糊图获得“细节层”，最后把细节层按锐化量加回原图。

核心机制与推导

非锐化掩模先计算模糊图，再把原图减去模糊图得到高频细节，按系数加回。它改变已有频率的幅度，不解决模糊退化的逆问题，因此看起来更锐不等于真实分

分辨率提高。amount 决定细节增益，模糊核决定哪些结构被归入细节；核较大可增强较宽尺度的局部对比，也更容易形成光晕。噪声同样属于高频，所以常需先降噪并保留原图用于测量。

$O = I + a(I - G\sigma * I) = (1+a)I - a(G\sigma * I)$ ； $a=0$ 保持原图，最后限幅。

参数、实验与结果解读

项目默认参数：amount=1；kernel=5。

建议实验：增大 amount，观察文字边缘的亮暗光晕，比较原图与处理图的边缘定位偏差。

结果解读：比较字边和细纹是否更容易分辨。逐渐增加锐化量，看什么时候出现明暗相间的光晕。

边界与误区：锐化也会放大噪声，不能恢复已经丢失的真实细节；强烈光晕尤其不适合直接用于尺寸测量。

学习练习（答案见独立答案册）

Q028-1 锐化为何会放大噪声？

Q028-2 amount=0 时应得到什么？

Q028-3 锐化与去模糊有何区别？

Q028-4 光晕如何形成？

Q028-5 大核与大 amount 的作用相同吗？

Q028-6 能用锐化结果直接测间隙吗？

029 傅里叶频谱 (fft)

实验输入：image。用途：周期噪声分析、纹理和边缘提取。

学习目标与直观理解

从“图片在哪里亮”切换到“亮度怎样重复变化”，观察周期纹理和细节所对应的频率。

傅里叶变换把图像拆成不同方向、不同变化速度的波。显示时把缓慢变化的低频移到中心，并用对数压缩亮度差。

核心机制与推导

二维离散傅里叶变换把图像表示为不同空间频率和方向的复数波叠加。幅值说明某种周期成分的强弱，相位承载其位置关系；只看幅值无法还原原图。fftshift 将零频移至中心，便于看低频到高频分布， $\log(1+\text{幅值})$ 压缩大动态范围。图像有限窗口相当于截断信号，边界不连续会导致频谱泄漏；频谱中的条纹方向与空间周期变化方向有关，不能当作物体坐标。

$$F(u,v)=\sum_{x,y} I(x,y)\exp[-j2\pi(ux/W+vy/H)]; \text{ 逆变换需要完整复数 } F, \text{ 不能仅用 } |F|.$$

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：比较水平条纹、垂直条纹和随机噪声的频谱，再观察裁剪边界造成的额外频率成分。

结果解读：中心通常很亮，表示平均亮度和缓慢变化强。远离中心的亮点或条纹可能对应规则纹理、边缘或噪声。

边界与误区：频谱中的位置不是原图位置。不能把频谱中的亮点当作图中某个物体，方向关系也要结合纹理理解。

学习练习（答案见独立答案册）

Q029-1 中心亮点代表图中中心物体吗？

Q029-2 为什么使用对数幅值？

Q029-3 只保留幅值能重建原图吗？

Q029-4 空间平移会怎样影响频谱？

Q029-5 为什么周期纹理形成成对亮点？

Q029-6 FFT 滤波为什么容易有边界伪影？

030 频域低通 (lowpass)

实验输入：image。用途：周期噪声分析、纹理和边缘提取。

学习目标与直观理解

保留缓慢的亮度变化，去掉快速变化的细节，直观看到频域中的“模糊”。

在频谱中心画一个圆，只保留圆内低频，然后变回图像。半径比例越大，保留下来的细节越多。

核心机制与推导

频域低通将中心附近频率保留、远处频率抑制。平台使用硬圆盘理想低通，其频率边界突变，对应空间域振荡且延伸很长的核，因而会在强边缘附近产生振铃。radius 乘以图像较短边得到频域半径；增大半径意味着保留更多高频，模糊反而减弱。逆变换后平台取绝对值并归一化显示，所以输出适合观察，不能直接保留原始亮度定量关系。

$$H(u,v)=1[D(u,v)\leq r]; F_{out}=H\cdot F; r=radius\cdot\min(H\text{图},W\text{图}).$$

参数、实验与结果解读

项目默认参数：radius=0.1。

建议实验：对黑白方块逐渐增大 radius，记录轮廓恢复与边缘波纹，并与高斯低通比较。

结果解读：从小半径到大半径比较：轮廓逐渐恢复，细纹理也会回来。观察它与高斯模糊的区别。

边界与误区：这里用的是边界很硬的圆形滤波器，物体边缘可能出现波纹。结果又做了显示归一化，亮度不能直接当原始测量值。

学习练习（答案见独立答案册）

Q030-1 低通半径增大是更模糊还是更清楚？

Q030-2 理想低通为什么振铃？

Q030-3 如何减少振铃？

Q030-4 低通能去掉所有噪声吗？

Q030-5 radius 是像素坐标中的目标半径吗？

Q030-6 为什么输出均值不能直接与原图比较？

031 频域高通 (highpass)

实验输入：image。用途：周期噪声分析、纹理和边缘提取。

学习目标与直观理解

突出边缘、细纹和快速变化，淡化大块均匀区域。

与低通相反，去掉频谱中心的低频，只保留较远处的高频。平台取逆变换的绝对值并归一化显示。

核心机制与推导

高通抑制低频，突出快速变化的边缘、细纹和噪声。平台以理想低通圆盘的补集作为通带，因此同样有振铃风险。高通的直流增益为零，理想常量图输出应接近零；其有符号空间响应可显示边缘方向，但平台取绝对值并归一化后只剩强度。高通残差可按适当比例加回原图形成高提升滤波，单独输出高通图本身并不是一幅完整的恢复图。

$H_{\text{高}} = 1 - H_{\text{低}}$ ；理想线性条件下 $I = I_{\text{低}} + I_{\text{高}}$ ；取绝对值、裁剪后此可加性不再成立。

参数、实验与结果解读

项目默认参数：radius=0.1。

建议实验：观察高通中的纹理、噪声与边界；改变半径后检查粗结构何时消失。

结果解读：边界和纹理变亮，平坦处往往较暗。改变半径后，观察粗轮廓与细纹的保留情况。

边界与误区：高频也包含噪声，亮处不一定是有意义的边缘；取绝对值后不能再从结果判断原来的正负变化方向。

学习练习（答案见独立答案册）

Q031-1 高通为什么让平坦区域暗？

Q031-2 高通半径增大会怎样？

Q031-3 高频都是有用边缘吗？

Q031-4 为什么结果不能判断亮到暗方向？

Q031-5 低通与高通结果相加一定还原吗？

Q031-6 高通与锐化如何联系？

第 03 模块 阈值与形态学

032 固定阈值 (threshold)

实验输入：image。用途：印刷字符、零件轮廓、掩膜生成。

学习目标与直观理解

用一条亮度分界线把图像分成黑白两类，例如亮零件和暗背景。

先转灰度，再逐像素比较：大于阈值记为 255（白），其余记为 0（黑）。它只比较亮度，不认识物体。

核心机制与推导

固定阈值在灰度轴上放置一个决策边界，并对所有位置使用同一规则。它假设前景和背景在该特征上可分，阈值本身并不知道哪种区域是物体。平台采用严格大于：等于阈值的像素归入黑色。阈值提高时白色集合只会缩小，但物体数量可能因区域断裂而先增后减。输入照明不均或目标内部变化大时，继续微调单个阈值常无法兼顾整图，需要改善成像或改用局部特征。

$M(x,y)=255$ 当 $I(x,y)>T$ ，否则 0； $T_2>T_1$ 时，白区(T_2) $\subseteq$ 白区(T_1)。

参数、实验与结果解读

项目默认参数：threshold=127。

建议实验：在带阴影的零件图上扫过多个阈值，记录前景面积、连通区域数与目标完整性。

结果解读：白色是本次选中的区域。提高阈值后，通常只有更亮的部分保留；降低阈值会选入更多背景。

边界与误区：检查目标是否完整、背景是否干净。如果同一目标一半亮一半暗，单一阈值很难分好，可试自适应阈值。

学习练习（答案见独立答案册）

Q032-1 像素恰好等于阈值会变白吗？

Q032-2 提高阈值白色面积如何变化？

Q032-3 黑字白底怎样得到文字前景？

Q032-4 阈值能直接输出语义类别吗？

Q032-5 为什么阴影使全局阈值失效？

Q032-6 如何选择阈值而不只凭视觉？

033 自适应阈值 (adaptive)

实验输入：image。用途：印刷字符、零件轮廓、掩膜生成。

学习目标与直观理解

处理一张图中光照不均的问题，例如纸张一侧有阴影时仍然找出文字。

每个位置有自己的阈值：先估计附近像素的加权亮度，再减去常数 C 。邻域大小决定看多大一片区域。

核心机制与推导

自适应阈值为每个像素估计局部背景，再用局部统计量减常数 C 形成阈值。平台采用高斯加权均值，强调近邻贡献。窗口需要大于文字笔画或目标细结构，使统

计能代表背景，又应小于光照变化尺度，才能跟随阴影变化。C 增大使阈值下降，THRESH_BINARY 下白像素变多；这不等于黑字前景变多。局部方法并非自动语义分割，纹理本身也会引发大量黑白变化。

$T(x,y)=\sum \text{邻域 } w \cdot I - C$ ； $M=255 \cdot 1[I>T]$ ；窗口为奇数且应留有足够背景样本。

参数、实验与结果解读

项目默认参数：block=21；constant=5。

建议实验：在阴影文字图上分别改变 block 与 constant，注意黑字极性和背景碎斑。

结果解读：观察阴影两侧的同类内容是否都能保留。邻域太小容易追随纹理，太大则越来越像全局阈值。

边界与误区：增大 C 会降低局部阈值，让更多像素变白。本平台亮处为白，读黑色文字时要留意前景极性。

学习练习（答案见独立答案册）

Q033-1 为什么需要局部窗口？

Q033-2 C 增大时白区增加还是减少？

Q033-3 窗口比笔画还小会怎样？

Q033-4 窗口很大是否更稳？

Q033-5 为什么平台采用高斯加权？

Q033-6 自适应阈值适合任意彩色目标吗？

034 Otsu 自动阈值 (otsu)

实验输入：image。用途：印刷字符、零件轮廓、掩膜生成。

学习目标与直观理解

让程序自动挑一个全图亮度阈值，适合目标与背景亮度能明显分成两群的图片。

算法尝试多个分界点，寻找能让两组亮度差异尽可能大的阈值。它依据分布选阈值，并不知道哪一组是目标。

核心机制与推导

Otsu 将每个候选阈值两侧看作两类，计算其概率与平均灰度，选择类间方差最大的阈值。总方差固定时，这等价于最小化类内方差之和。借助直方图累积概率和累积一阶矩，可在线性于灰度级数的时间扫描所有阈值。算法不要求人工指定 T ，但其目标只是灰度分布分离；当背景占绝大多数、光照渐变或存在多峰时，最优统计阈值不一定符合任务语义。

$\sigma_b^2(T) = \omega_0 \omega_1 (\mu_0 - \mu_1)^2$ ； ω 是两类占比， μ 是两类均值；选择使 σ_b^2 最大的 T 。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：对双峰色块、渐变背景和小面积目标分别运行，比较自动阈值与真实目标分割。

结果解读：查看黑白分割是否符合预期，再到结果数据读取 threshold，理解程序这次选了什么数。

边界与误区：自动不代表一定正确。渐变阴影、多个亮度群或目标很小时，选出的阈值可能不适合任务。

学习练习（答案见独立答案册）

Q034-1 Otsu 优化的目标是什么？

Q034-2 为什么小目标容易被忽略？

Q034-3 Otsu 必须两峰才可计算吗？

Q034-4 算法计算量取决于像素还是灰度级？

Q034-5 为什么先适度去噪可能有帮助？

Q034-6 自动阈值是否可跨图直接复用？

035 腐蚀 (erode)

实验输入：image。用途：连接断点、去除小噪点、提取局部亮暗缺陷。

学习目标与直观理解

缩小亮区域，去掉小白点或切断细的白色连接。

让一个小形状在图上滑动，每次取覆盖范围内的最小值。对二值图来说，只有整个邻域都白，中心才保留白色。

核心机制与推导

二值腐蚀可以理解为寻找结构元素能够完全放入前景的位置；灰度腐蚀则取结构元素覆盖位置的最小值。结构元素的形状决定方向偏好，十字、矩形、椭圆并非仅显示不同。腐蚀扩大暗区域并缩小亮区域，细连接可能被切断。多次迭代相当于扩大有效邻域，但其形状由结构元素复合决定。平台允许彩色逐通道处理；若目的是区域集合操作，应先明确二值掩膜。

$A \ominus B = \{x: B \text{ 平移至 } x \text{ 后完全位于 } A \text{ 内}\}$ ；灰度形式 $O(x) = \min_{b \in B} I(x+b)$ 。

参数、实验与结果解读

项目默认参数：kernel=5；iterations=1；shape=ellipse。

建议实验：对含小亮点、细桥和大方块的掩膜换用不同形状核，观察哪些结构先消失。

结果解读：观察白区边缘向内收缩，细线可能断开。核尺寸和迭代次数越大，收缩越明显。

边界与误区：腐蚀操作的是亮区，不是自动识别出的物体。若目标是黑色，效果看起来会相反；彩色输入按通道处理。

学习练习（答案见独立答案册）

Q035-1 腐蚀为什么能断开细桥？

Q035-2 腐蚀总让物体变小吗？

Q035-3 矩形核与十字核有什么差别？

Q035-4 腐蚀后可以直接测原零件宽度吗？

Q035-5 彩图腐蚀等于对物体轮廓腐蚀吗？

Q035-6 图像边界为何要特别处理？

036 膨胀 (dilate)

实验输入：image。用途：连接断点、去除小噪点、提取局部亮暗缺陷。

学习目标与直观理解

扩大亮区域，填补细小断裂或把距离近的白区连接起来。

小形状滑动时取覆盖范围内的最大值。对二值图来说，只要附近有白像素，中心就能变白。

核心机制与推导

二值膨胀将每个前景点扩展成一个结构元素覆盖的区域，灰度形式取局部最大值。它能连接短断裂，但也会把邻近目标粘在一起。结构元素半径给出扩张的大致空间尺度，实际离散轮廓依赖形状与锚点。膨胀通常与腐蚀组合以清理掩膜；它不是腐蚀的逆运算，因为小结构消失或多个区域合并后，原始边界信息已经丢失。

灰度 $O(x) = \max_{b \in B} I(x+b)$ ；二值膨胀对应 A 与 B 的 Minkowski 和（需遵循锚点约定）。

参数、实验与结果解读

项目默认参数：kernel=5；iterations=1；shape=ellipse。

建议实验：让两块前景的间距逐渐缩小，寻找给定核使它们第一次连通的间距。

结果解读：观察白区边缘向外扩张、细缝是否闭合。核越大、次数越多，邻近目标越容易粘在一起。

边界与误区：膨胀改变了目标大小。可用于连通处理，但不应把膨胀后的宽度直接当作原始尺寸。

学习练习（答案见独立答案册）

Q036-1 膨胀如何填补断裂？

Q036-2 膨胀是腐蚀的逆吗？

Q036-3 为什么计数后端不应盲目加膨胀？

Q036-4 核更大和迭代更多等价吗？

Q036-5 灰度膨胀输出局部什么统计量？

Q036-6 如何选择核大小？

037 开运算 (open)

实验输入：image。用途：连接断点、去除小噪点、提取局部亮暗缺陷。

学习目标与直观理解

清除比结构元素小的亮点，同时尽量保留较大的亮区域。

先腐蚀，让小白点消失；再膨胀，恢复大目标的大致轮廓。已经完全消失的小点不会再长回来。

核心机制与推导

开运算先腐蚀再膨胀，可视为保留那些能容纳结构元素的前景结构，再重建其可覆盖部分。它具有反扩张性，结果通常是原前景的子集；在固定定义下重复开运算具有幂等性。它按空间尺度和形状筛选，不认识噪声含义，真实的小零件也可能被去掉。OpenCV 的 `iterations=n` 意味着先做 n 次腐蚀，再做 n 次膨胀，不应简单理解为重复执行同一个完整开运算。

$A \ominus B = (A \oplus B) \ominus B$; $(A \odot B) \odot B = A \odot B$ （相同边界和定义下）。

参数、实验与结果解读

项目默认参数：`kernel=5`; `iterations=1`; `shape=ellipse`。

建议实验：在大目标旁加入小亮点和细线，比较开运算去噪收益与真实小结构损失。

结果解读：看孤立亮噪声是否减少，再检查细长目标有没有断裂、尖角有没有变圆。

边界与误区：它按尺寸和形状筛选，分不清噪声与真实小零件。选择结构元素时要与希望保留的最小目标比较。

学习练习（答案见独立答案册）

Q037-1 为什么先腐蚀再膨胀能去亮点？

Q037-2 开运算会完整恢复原轮廓吗？

Q037-3 幂等性指什么？

Q037-4 开运算适合去黑洞吗？

Q037-5 怎样保留细长目标？

Q037-6 为什么平台 iterations=2 可能比 1 强？

038 闭运算 (close)

实验输入：image。用途：连接断点、去除小噪点、提取局部亮暗缺陷。

学习目标与直观理解

填补亮目标里的小黑洞和窄裂缝，让区域更完整。

先膨胀，使小缝被白区填满；再腐蚀，恢复外边界的大致大小。

核心机制与推导

闭运算先膨胀再腐蚀，相当于优先填补无法容纳背景结构元素的暗缝与孔洞，再恢复大致外边界。它对前景通常具有扩张性和幂等性。闭运算能改善碎裂轮廓，但会改变拓扑结构：孔洞可能消失，相邻物体可能合并。若孔洞本身就是检测目标或装配特征，闭运算会删除关键证据。正确使用需明确前景极性、核尺度以及下游关注的是数量、形状还是尺寸。

$A \bullet B = (A \oplus B) \ominus B$ ；亮前景下结果倾向填补小暗结构，而不是识别缺损原因。

参数、实验与结果解读

项目默认参数：kernel=5；iterations=1；shape=ellipse。

建议实验：对带小孔的零件和相邻双零件做闭运算，分别检查孔洞消失与粘连风险。

结果解读：观察目标内部的小孔是否消失，断开的边缘是否连接。与原图比较外轮廓有没有明显变化。

边界与误区：核过大会把两个真实独立的零件接成一个，导致计数减少或测量偏大。

学习练习（答案见独立答案册）

Q038-1 为什么闭运算能补小孔？

Q038-2 闭运算会影响零件数量吗？

Q038-3 闭运算是开运算的逆吗？

Q038-4 检查螺孔缺失前应做强闭运算吗？

Q038-5 为什么同一个核对横缝竖缝效果不同？

Q038-6 如何判断闭运算过强？

039 形态学梯度 (morph_gradient)

实验输入：image。用途：连接断点、去除小噪点、提取局部亮暗缺陷。

学习目标与直观理解

用形态学方法突出物体边界，得到较粗的一圈轮廓响应。

膨胀后的图减去腐蚀后的图，两者最不同的地方就是亮暗边界附近。核越大，边界带通常越宽。

核心机制与推导

形态学梯度是局部最大值与最小值之差，可理解为结构元素覆盖范围内的局部动态范围。它对亮暗边界都响应，不给出梯度方向或符号。二值图上得到围绕边界的带状区域，其宽度受结构元素影响，通常并非一像素边。与 Sobel 的线性导数不同，形态学梯度依赖极值，容易受孤立亮点或暗点影响；可结合适当平滑或鲁棒前处理。

$G=(I\oplus B)-(I\ominus B)=\max_{\text{邻域}}(I)-\min_{\text{邻域}}(I)$ ；恒定区域 $G=0$ 。

参数、实验与结果解读

项目默认参数：kernel=5；iterations=1；shape=ellipse。

建议实验：对阶跃边缘分别使用 3 和 9 的结构元素，测量边界带宽，再与 Canny 的细边比较。

结果解读：亮线围绕颜色或亮度发生变化的位置。比较不同核尺寸下边界的宽度。

边界与误区：这不是精确的一像素边缘图，纹理也会产生响应；测量轮廓位置时要考虑核引入的宽度。

学习练习（答案见独立答案册）

Q039-1 形态学梯度量的是什么？

Q039-2 为什么输出边缘比较粗？

Q039-3 能从结果判断由暗到亮方向吗？

Q039-4 与 Sobel 有何本质差别？

Q039-5 孤立噪声为什么产生强响应？

Q039-6 适合直接当像素精确边界吗？

040 顶帽 (tophat)

实验输入：image。用途：连接断点、去除小噪点、提取局部亮暗缺陷。

学习目标与直观理解

从缓慢变化的背景上突出小而亮的细节，例如亮斑、细亮划痕。

原图减去开运算结果。开运算去掉的小亮结构，就在相减后被保留下来。

核心机制与推导

白顶帽用原图减去其开运算结果。开运算可去除无法容纳结构元素的细小亮结构，剩余较缓慢背景；相减后这些亮结构被突出。因此核应比目标亮结构宽，但不应大到完全破坏背景估计。它是形态学的局部背景消除，能用于不均匀背景上的亮点或细亮线。顶帽没有学习“缺陷”，任何符合尺度的正常文字、纹理和反光也会响应。

$T_{\text{白}} = I - (I \circ B)$ ；亮目标小于结构元素时更容易从背景中被提取。

参数、实验与结果解读

项目默认参数：kernel=5；iterations=1；shape=ellipse。

建议实验：在渐变背景上放不同大小的亮圆，改变核尺寸，观察哪些圆能被顶帽保留。

结果解读：亮处表示比所选结构元素更小、比周围更亮的结构。改变核尺寸，观察哪些细节被强调。

边界与误区：核太小可能看不到目标，太大可能把大范围光照也留下；亮响应还需结合原图判断是否为缺陷。

学习练习（答案见独立答案册）

Q040-1 为什么顶帽突出亮小目标？

Q040-2 核比目标还小会怎样？

Q040-3 顶帽与原图减高斯有什么差别？

Q040-4 顶帽能同时找暗划痕吗？

Q040-5 为什么正常字符也被检测出来？

Q040-6 如何验证核选择?

041 黑帽 (blackhat)

实验输入: image。用途: 连接断点、去除小噪点、提取局部亮暗缺陷。

学习目标与直观理解

突出亮背景上的小暗结构, 例如暗划痕和细黑线。

闭运算结果减去原图。闭运算填掉的小暗缝和暗点, 会在差值图里变成亮响应。

核心机制与推导

黑帽用闭运算结果减去原图。闭运算填补窄暗缝、小暗孔, 得到较平滑的亮背景估计, 相减便突出原来低于背景的结构。它与顶帽在前景极性上互补, 但不宜不加区分地解释为所有缺陷。结构元素方向可针对细长暗划痕设计; 若背景纹理与缺陷尺度相近, 仅靠黑帽难以分离, 需要方向、多尺度或更复杂特征。

$T_{\text{黑}} = (I \circ B) - I$; 黑帽响应是非负的暗结构残差, 空间尺度由 B 决定。

参数、实验与结果解读

项目默认参数: kernel=5; iterations=1; shape=ellipse。

建议实验: 在亮金属背景上放置暗线与暗圆, 分别用横向、竖向和椭圆核比较方向响应。

结果解读: 结果的亮区对应原图中的暗细节, 颜色含义与原图相反。可与顶帽对照理解。

边界与误区: 响应由结构尺寸决定, 不是缺陷类别判断。正常印字也可能产生强响应。

学习练习 (答案见独立答案册)

Q041-1 黑帽为什么不是原图直接取反?

Q041-2 黑帽适合什么缺陷外观?

Q041-3 核方向为什么重要？

Q041-4 黑帽与顶帽可以组合吗？

Q041-5 大面积阴影一定会被去掉吗？

Q041-6 参数调好是否意味着检测可靠？

042 骨架提取 (skeleton)

实验输入：image。用途：线宽、拓扑、裂纹路径分析。

学习目标与直观理解

把较粗的白色区域压缩为中间的细线，方便观察连通关系和大致走向。

先二值化，再反复剥掉外层，保留每一轮无法由膨胀恢复的骨架部分。本平台采用形态学骨架近似。

核心机制与推导

平台采用迭代形态学骨架：对当前前景腐蚀，再把当前图减去腐蚀后膨胀的结果，将残差累积；继续腐蚀直到前景消失。不同腐蚀层留下的不可再被开运算覆盖部分形成骨架。它与严格保持拓扑的一像素细化算法不同，不能保证任何输入都得到单像素、无分支或连通的中心线。边界设零保证全白图也逐步收缩；噪声和小轮廓凹凸会制造伪分支。

$S(A) = \bigcup_k [(A \ominus k B) - ((A \ominus k B) \circ B)]$ ；平台使用 3×3 十字结构元素。

参数、实验与结果解读

项目默认参数：threshold=127。

建议实验：对粗线、环形和带毛刺目标求骨架，检查连通性、分支数量和不同阈值的影响。

结果解读：查看主体连接是否保留，线条是否沿区域中部延伸。毛刺或小分支可能来自原轮廓上的噪声。

边界与误区：骨架不是外边界，也不保证处处只有一个像素宽。先清理掩膜，结果通常更容易解释。

学习练习（答案见独立答案册）

Q042-1 这里的骨架与细化完全相同吗？

Q042-2 为什么要累积每轮残差？

Q042-3 全白图为什么需要零边界？

Q042-4 毛刺为什么造成多余分支？

Q042-5 骨架长度就是物体周长吗？

Q042-6 如何改善骨架质量？

043 距离变换 (distance)

实验输入：image。用途：分水岭种子、厚度和间隙分析。

学习目标与直观理解

测量每个白像素离最近黑像素有多远，找到区域内部最“深”的位置。

先得到二值掩膜，再为白区中的每一点计算到背景的距离。靠近边界的距离小，内部中心的距离大。

核心机制与推导

距离变换对每个前景像素计算到最近零像素的距离，因此前景内部越深，数值越大，背景距离为零。它可用于估计局部厚度、寻找分水岭种子和构造距离权重。平台使用 L2 距离与 5×5 掩模，是欧氏距离的近似计算；原始浮点数组单位是像素，显示归一化后不再是距离值。两个相邻峰不一定对应两个真实物体，边界噪声和目标形状也会产生局部极值。

$D(p) = \min_{q \in \text{背景}} \|p - q\|_2$ ；圆形内部中心距离近似半径；局部厚度约 2D 需结合中轴条件。

参数、实验与结果解读

项目默认参数：threshold=127。

建议实验：对圆、细条和粘连双圆查看原始距离与热图，比较最大距离、目标宽度和种子位置。

结果解读：显示越亮通常距离越大。精确像素距离在 distance_pixels 数组中，max_distance_px 是最大值。

边界与误区：显示图经过归一化，亮度 255 不等于距离 255 像素。距离是到背景的距离，不是目标之间的间隙。

学习练习（答案见独立答案册）

Q043-1 距离是到前景还是背景？

Q043-2 最大距离等于直径吗？

Q043-3 为什么不能读取热图颜色当距离？

Q043-4 L1 与 L2 距离有何区别？

Q043-5 距离峰怎样帮助分水岭？

Q043-6 全前景且没有背景时应注意什么？

第 04 模块 边缘与形状

044 Sobel (sobel)

实验输入：image。用途：尺寸测量、轮廓定位。

学习目标与直观理解

找出图中亮度变化快的地方，观察边界和纹理的位置。

分别计算左右方向和上下方向的亮度差，再把两个方向的强度合成梯度幅值。平坦区域响应小，跳变区域响应大。

核心机制与推导

Sobel 将一维平滑与另一方向的差分组合，分别估计水平、垂直导数。 G_x 对随 x 变化的强度敏感，因此常在垂直边缘处响应；导数方向和边缘延伸方向相互垂直。梯度幅值反映变化强度，方向由 atan2 得到。平台保留浮点中间结果，再将幅值归一化显示，所以跨图片不能直接用显示亮度比较导数大小。Sobel 不包含非极大值抑制，输出常是较宽的边缘带。

$$K_x = [-1, 0, 1; -2, 0, 2; -1, 0, 1]; G = \sqrt{(G_x^2 + G_y^2)}, \theta = \text{atan2}(G_y, G_x)。$$

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：对水平、竖直和斜线分别看 G_x 、 G_y 与幅值，确认导数方向与线条方向的区别。

结果解读：亮处表示变化强，暗处表示平坦。看看目标轮廓和背景纹理是否都被强调了。

边界与误区：输出强度经过归一化，不是二值边缘，也不表示那里一定有物体；噪声同样会产生亮响应。

学习练习（答案见独立答案册）

Q044-1 G_x 检出的是水平线吗？

Q044-2 为什么使用有符号浮点导数？

Q044-3 Sobel 为什么具有一点抗噪能力？

Q044-4 幅值与方向如何计算？

Q044-5 为什么 Sobel 输出不一定一像素宽？

Q044-6 归一化显示适合定量比较吗？

045 Scharr (scharr)

实验输入：image。用途：尺寸测量、轮廓定位。

学习目标与直观理解

观察一种对小邻域梯度方向更均衡的边缘算子，并与 Sobel 比较斜边表现。

与 Sobel 一样估计横、纵方向的亮度变化，但采用不同的 3×3 权重，改善部分方向上的误差。

核心机制与推导

Scharr 同样估计一阶导数，但在 3×3 小核约束下优化旋转对称性，使不同方向边缘的响应更一致。其平滑方向权重比 Sobel 更强调中心行或列。它并非增加特征语义，也不保证对噪声总更优；强度尺度与 Sobel 不同，比较时应归一化核增益或使用一致标定。平台将 G_x 、 G_y 合成幅值，只展示响应强弱。

$K_x = [-3, 0, 3; -10, 0, 10; -3, 0, 3]$ ； $K_y = K_x$ 的转置，幅值计算与 Sobel 相同。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：旋转同一条边缘，比较 Sobel 和 Scharr 对不同角度的响应变化。

结果解读：挑选带斜线或圆弧的区域，对比响应是否连续，以及不同方向的边缘强度。

边界与误区：Scharr 仍是梯度强度图，不会自动连接边缘；两次显示的独立归一化也会影响亮度对比。

学习练习（答案见独立答案册）

Q045-1 Scharr 相对 Sobel 优化了什么？

Q045-2 Scharr 数值更大就代表更准确吗？

Q045-3 它是否自带 Canny 双阈值？

Q045-4 为什么斜边更值得比较？

Q045-5 Scharr 会自动去噪吗？

Q045-6 何时优先考虑 Scharr？

046 Laplacian (laplacian)

实验输入：image。用途：尺寸测量、轮廓定位。

学习目标与直观理解

寻找亮度变化速度再次发生变化的位置，观察轮廓两侧和细小细节。

一阶差分像“坡度”，二阶差分像“坡度怎样改变”。Laplacian 合并横、纵二阶变化，平台取绝对值显示。

核心机制与推导

Laplacian 是二阶导数之和，对各方向亮度曲率响应。与一阶梯度不同，它常在边缘两侧产生相反符号，零交叉可用于定位变化位置。二阶微分对高频噪声更敏感，因此常先高斯平滑形成 LoG。平台将浮点响应做 convertScaleAbs，取绝对值后方向与零交叉两侧符号丢失；结果只是二阶变化强度图，不是已完成边缘判定。

$\nabla^2 I = \partial^2 I / \partial x^2 + \partial^2 I / \partial y^2$ ；典型离散核 $[0, 1, 0; 1, -4, 1; 0, 1, 0]$ 。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：对无噪与带噪阶跃图比较 Laplacian，分别查看原始有符号响应和绝对值显示。

结果解读：边缘附近会出现强响应，细纹和孤立噪点也很显眼。可先用高斯平滑再比较。

边界与误区：因为显示时取绝对值，正负号丢失，不能用这张显示图直接判断零交叉。

学习练习（答案见独立答案册）

Q046-1 一阶与二阶导数有什么区别？

Q046-2 为什么 Laplacian 更怕噪声？

Q046-3 LoG 为什么先高斯后 Laplacian？

Q046-4 本平台结果能直接做零交叉吗？

Q046-5 Laplacian 方差能绝对判断清晰度吗？

Q046-6 为什么均匀亮度偏移理论上不影响结果？

047 Canny (canny)

实验输入：image。用途：尺寸测量、轮廓定位。

学习目标与直观理解

把照片里的明显亮暗边界提取成细白线，便于观察物体轮廓。例如，橙子与背景交界处会出现一圈线，但果皮纹理也可能留下线。

先估计亮度变化强度，再把宽的响应压成细线。高于高阈值的点作为可靠边缘；介于两个阈值之间的弱边缘，只有连到可靠边缘才保留。本平台直接对灰度图调用 Canny，不额外加高斯模糊。

核心机制与推导

Canny 的核心是梯度、非极大值抑制、双阈值与滞后连接。先沿梯度方向比较邻居，只保留局部峰，使边缘变细；高阈值确定可靠强边，低阈值保留候选弱边，只有与强边连通的弱边才最终保留。传统完整流程常含高斯平滑，但本项目直接对灰度图调用 Canny，没有显式的独立高斯步骤。默认梯度幅度约定也应与库参数区分，不能把理论公式当作所有实现的固定配置。

强边 $G \geq Th$ ；弱候选 $Tl \leq G < Th$ ；最终边缘=强边及与之相连的弱候选，且 $Th \geq Tl$ 。

参数、实验与结果解读

项目默认参数：low=60；high=160。

建议实验：分别提高 low 和 high，观察噪点、细弱边与边缘连续性；另外加高斯预处理比较。

结果解读：白色表示保留下来的边缘，黑色表示未保留。先看目标外轮廓是否连贯，再看背景和纹理是否产生过多碎线；白线越多并不一定越好。

边界与误区：提高高阈值会减少边缘的可靠起点；提高低阈值会删掉更多弱连接。轮廓断裂可尝试降低阈值，碎线太多可提高阈值或先去噪。

学习练习（答案见独立答案册）

Q047-1 双阈值解决什么问题？

Q047-2 非极大值抑制沿哪个方向比较？

Q047-3 所有超过低阈值的点都会保留吗？

Q047-4 高低阈值必须固定 3:1 吗？

Q047-5 本平台是否明确先做高斯？

Q047-6 Canny 结果可以直接计算实体面积吗？

048 轮廓、面积与周长 (contours)

实验输入：image。用途：零件计数、轮廓检测和形状一致性。

学习目标与直观理解

从黑白分割区域中找出外边界，并计算面积、周长、位置等几何量。

先按亮度阈值分出白区，再沿外轮廓追踪边界。面积小于最小面积的轮廓被过滤；平台使用外轮廓，不单独枚举内部孔洞。

核心机制与推导

轮廓从二值区域边界追踪有序点集，使面积、弧长、矩和外接框可以在几何层面计算。检索模式决定是否包含孔洞和嵌套边界；平台使用外轮廓模式，因此内部孔洞不作为独立轮廓保留。链近似压缩共线点，节省存储但影响后续基于离散点的距离计算。轮廓面积是多边形几何面积，连通域面积则是前景像素计数，两者在小目标和细线处差异尤其明显。

轮廓 $C=\{p_0, \dots, p_{n-1}\}$ ；面积用鞋带公式，周长用相邻点距离和；二者分别以 px^2 、 px 计。

参数、实验与结果解读

项目默认参数：threshold=127；min_area=100。

建议实验：对实心块、环和一像素细线比较轮廓面积、像素面积与内部孔洞表现。

结果解读：轮廓旁的编号对应 objects 中的记录。area_px2 是面积，perimeter_px 是周长，centroid 是中心坐标。

边界与误区：先确认二值掩膜正确，再相信几何数据。相接的零件可能成为一个轮廓，噪声也可能被算成小目标。

学习练习（答案见独立答案册）

Q048-1 RETR_EXTERNAL 会保留孔洞吗？

Q048-2 轮廓面积为何不同于白像素数？

Q048-3 CHAIN_APPROX_SIMPLE 做了什么？

Q048-4 为什么细线面积可能为零？

Q048-5 min_area 能修复粘连吗？

Q048-6 怎样避免外轮廓误当真实物体？

049 连通域与质心 (components)

实验输入：image。用途：零件计数、轮廓检测和形状一致性。

学习目标与直观理解

给每片彼此连通的白色区域编号，统计区域像素数和中心，适合观察目标是否分离。

相邻的白像素被归为同一个连通域，本实验默认考虑包括对角线在内的八邻域。面积阈值过滤太小的区域。

核心机制与推导

连通域把前景像素构成图，相邻关系为边，搜索每个连通分量并分配标签。4 连通只看上下左右，8 连通还包含对角线，因此斜接触区域的数量可能不同。统计面积是像素个数，质心是像素坐标平均，适合区域计数。背景通常编号为 0；标签编号来自扫描和实现规则，不是类别或跨帧身份。平台使用 `connectedComponentsWithStats` 默认连接方式，并按像素面积筛选。

$A_k = \sum 1[L(x,y)=k]$; $cx = \sum x/A_k$, $cy = \sum y/A_k$ (求和限于第 k 域)。

参数、实验与结果解读

项目默认参数: `threshold=127`; `min_area=100`。

建议实验：构造仅在角点接触的两个白块，比较 4/8 连通，再与外轮廓数量比较。

结果解读：以 `components` 列表和 `count` 为准：`area_px2` 是白像素个数，`centroid` 表示这片像素的平均位置。

边界与误区：显示图层用轮廓作辅助标记，具体编号以数据为准。连通域像素面积与轮廓多边形面积不一定完全相等。

学习练习（答案见独立答案册）

Q049-1 4 连通与 8 连通差在哪？

Q049-2 连通域面积是什么？

Q049-3 标签 1 是否总表示同一个零件？

Q049-4 背景标签应参与计数吗？

Q049-5 连通域能拆开相互接触的零件吗？

Q049-6 质心可能落在区域外吗？

050 凸包 (hull)

实验输入: `image`。用途：零件计数、轮廓检测和形状一致性。

学习目标与直观理解

用一条绷紧的橡皮筋套住物体，观察能包住它的最小凸形边界。

凸包会跨过原轮廓的凹陷，连接最外侧的点。它回答的是整体外包络，而不是原轮廓的每一处细节。

核心机制与推导

凸包是包含所有轮廓点的最小凸集合，相当于用橡皮筋包住点集。它填平凹陷但保留最外侧点，适合估计整体外形、凸性缺陷和紧致度。凸包不是最小外接矩形，也不是原始物体分割。常用 $\text{solidity} = \text{原轮廓面积} / \text{凸包面积}$ 衡量凹陷程度，但前提是轮廓和孔洞处理口径一致。离群点会显著拉大凸包，因此噪声清理比单纯计算凸包更重要。

$\text{solidity} = A_{\text{轮廓}} / A_{\text{凸包}}$ ($A_{\text{凸包}} > 0$)；凸包内任意两点连线都在凸包内。

参数、实验与结果解读

项目默认参数：threshold=127；min_area=100。

建议实验：比较星形、圆形和带远处噪点轮廓的凸包，观察凹陷填补及面积变化。

结果解读：看绿色边界在哪些地方跨过凹槽，可用这些差异认识凸与凹。

边界与误区：本平台 objects 的 area_px2 等仍来自原轮廓，不是凸包面积；不要把显示出来的凸包与这些原轮廓数值混淆。

学习练习（答案见独立答案册）

Q050-1 凸包与外接框有何区别？

Q050-2 为什么凸包会掩盖缺口？

Q050-3 solidity 越小意味着什么？

Q050-4 凸包面积能小于原轮廓面积吗？

Q050-5 一个远处误检点有什么影响？

Q050-6 凸包能用于手势分析吗？

051 形状匹配 (shape_match)

实验输入：image、reference。用途：零件计数、轮廓检测和形状一致性。

学习目标与直观理解

比较目标与参考图中的形状有多接近，降低颜色和纹理对匹配的影响。

先提取两图轮廓，用描述整体形状的 Hu 矩作比较。平台将目标轮廓与参考图中面积最大的有效轮廓比较。

核心机制与推导

形状匹配常先由轮廓计算中心矩、归一化矩，再组合为 Hu 不变矩，以降低平移、尺度和旋转变化的影响。OpenCV matchShapes 将这些量经过符号对数处理后比较，平台使用 I1 距离，并取参考图筛选后的最大外轮廓。距离小表示该形状描述更接近，不是概率。有限分辨率、噪声、镜像和孔洞处理都会影响不变性；轮廓相似也不意味着纹理、颜色或语义相同。

中心矩 $\mu_{pq} = \sum (x - c_x)^p (y - c_y)^q$ ；归一化后构造 Hu 向量，I1 比较其变换后的分量。

参数、实验与结果解读

项目默认参数：threshold=127；min_area=100。

建议实验：对同一轮廓旋转、缩放、加缺口，比较距离，并检查参考中最大轮廓是否确为目标。

结果解读：查看每个对象的 shape_distance，越小通常越相似。用已知相似和不相似形状建立自己的参考范围。

边界与误区：它不是 0–1 的概率。遮挡、粘连或错误阈值会改变轮廓，导致同一物体也得到较大距离。

学习练习（答案见独立答案册）

Q051-1 Hu 矩为什么能减弱平移影响？

Q051-2 shape_distance 越大越相似吗？

Q051-3 相似度能区分同形不同颜色吗？

Q051-4 理论旋转不变为何实际有波动？

Q051-5 本平台参考图有多个轮廓时用哪个？

Q051-6 镜像一定得到相同距离吗？

052 霍夫直线 (hough_lines)

实验输入：image。用途：直边、角度和车道定位。

学习目标与直观理解

把一串近似排成直线的边缘点汇总为线段，用于找轨道、边框或直边。

先提取边缘，再让点为可能的直线“投票”。票数足够、长度够长的候选才留下，短缺口可以连接。

核心机制与推导

霍夫变换把图像空间的点映射到参数空间。一条直线用法向距离 ρ 和角度 θ 表示，每个边缘点为可能经过它的直线投票；多个共线点的曲线在参数空间聚集形成峰值。平台使用概率霍夫 HoughLinesP，返回线段端点，votes 控制支持强度，length 和 gap 分别约束最短长度与允许断口。边缘检测质量和参数离散步长决定可定位的精度。

$\rho = x \cos\theta + y \sin\theta$ ； θ 是直线法向角，返回线段方向应由端点差另算。

参数、实验与结果解读

项目默认参数：votes=50；length=40；gap=10。

建议实验：对同一直线添加断裂和噪点，分别调 votes、length、gap，观察长线连接与误合并。

结果解读：lines 每项是 $[x1, y1, x2, y2]$ 。提高票数或最短长度通常会减少零碎线，增大允许间隙可能连接断线。

边界与误区：同一粗边界可能出现多条线段；没有返回线段只说明当前边缘和阈值不足，不代表图中绝对没有直线。

学习练习（答案见独立答案册）

Q052-1 为什么不用斜率截距表示？

Q052-2 θ 是线条方向角吗？

Q052-3 gap 调大有什么风险？

Q052-4 votes 和 length 相同吗？

Q052-5 为什么同一真实边可能返回多条线？

Q052-6 霍夫适合精密亚像素测量吗？

053 霍夫圆 (hough_circles)

实验输入：image。用途：轴承、孔洞、瓶盖检测。

学习目标与直观理解

从图像中寻找可能的圆形边界，例如孔洞、垫圈或圆形标记。

边缘的方向提供圆心线索，再在允许的半径范围内寻找支持较多的圆。

核心机制与推导

圆由中心和半径三个参数定义，直接三维投票成本高。梯度霍夫利用圆边缘梯度指向圆心这一几何关系，先聚集中心，再评估半径。平台预先做 5×5 高斯平滑，使用 HOUGH_GRADIENT，并设置固定最小圆心距离。votes 在这里对应 param2 的累积阈值，不能当作直线霍夫完全相同的票数语义。半径搜索范围越符合先验，通常越容易排除无关圆弧。

$(x-a)^2+(y-b)^2=r^2$ ；理想圆边缘法线通过圆心 (a,b) 。

参数、实验与结果解读

项目默认参数：votes=30；min_radius=5；max_radius=100。

建议实验：在同心圆、缺口圆和反光圆片上改变半径范围与 votes，观察漏检及重复检测。

结果解读：circles 每项包含圆心 x 、 y 和半径 r 。先检查圆有没有贴合真实边界，再调整半径范围与票数。

边界与误区：较低票数更容易检出圆，也更容易误检。透视下的圆可能看起来像椭圆，不能指望圆检测完全贴合。

学习练习（答案见独立答案册）

Q053-1 为什么梯度能帮助找圆心？

Q053-2 param1 与 param2 分别影响什么？

Q053-3 降低 votes 一定更好吗？

Q053-4 圆被透视拍成椭圆还能稳定检出吗？

Q053-5 半径先验有什么价值？

Q053-6 为什么同心圆可能漏掉一个？

054 轮廓面积 (contour_area)

实验输入：image。用途：零件计数、轮廓检测和形状一致性。

学习目标与直观理解

估计轮廓圈住的二维面积，用于比较目标大小或剔除小噪点。

程序把轮廓看成多边形，按边界坐标算内部面积。因此单位是像素平方 px^2 ，不是毫米平方。

核心机制与推导

轮廓面积将边界点看作闭合多边形，利用相邻顶点叉积求面积。它与分辨率平方相关：图像线性放大 s 倍，理想面积变为 s^2 倍。平台只取外轮廓，所以有孔物体的外轮廓面积包含孔洞覆盖的部分。面积对平移与旋转不变，但阈值、离散边界及

透视会改变结果。换算物理面积时，单一 pixels_per_mm 只适用于固定平面和尺度。

$A = \frac{1}{2} |\sum_i (x_i y_{i+1} - x_{i+1} y_i)|$ ；平面尺度 p px/mm 时， $A_{mm^2} = A_{px^2} / p^2$ 。

参数、实验与结果解读

项目默认参数：threshold=127；min_area=100。

建议实验：对同一方块缩放两倍验证面积近四倍，再给方块挖孔比较外轮廓和掩膜面积。

结果解读：关注 objects 中的 area_px2，并对照同编号轮廓是否包住了完整目标。

边界与误区：像素面积会随拍摄距离改变；本平台外轮廓面积也不会扣除内部孔洞，不能直接当成材料的实际面积。

学习练习（答案见独立答案册）

Q054-1 放大两倍面积变多少？

Q054-2 有孔零件外轮廓面积是净面积吗？

Q054-3 像素面积换 mm² 除以 p 还是 p^2 ？

Q054-4 有向面积的符号有什么作用？

Q054-5 为什么细小目标测量偏差较大？

Q054-6 相同面积是否说明形状相同？

055 轮廓周长 (contour_perimeter)

实验输入：image。用途：零件计数、轮廓检测和形状一致性。

学习目标与直观理解

量出目标边界绕一圈的长度，理解形状复杂度与边缘粗糙程度。

把相邻轮廓点之间的距离相加，闭合轮廓还会加上最后一点到第一点的距离。

核心机制与推导

周长沿闭合轮廓累加相邻点间欧氏距离，最后一点需要连接第一点。相比面积，周长对边缘噪声和锯齿更加敏感，因为每个局部弯折都增加路径。过度平滑或多边形近似又会减少周长，必须固定轮廓提取与预处理口径。圆度常由面积和周长组合，但不宜跨分辨率、不同噪声条件直接套阈值。

$P = \sum_i \|p_{i+1} - p_i\|_2$ ；圆度 $C = 4\pi A/P^2$ ，连续理想圆 $C=1$ 。

参数、实验与结果解读

项目默认参数：threshold=127；min_area=100。

建议实验：给圆边界加微小锯齿，观察面积变化小而周长明显增长的现象。

结果解读：关注 perimeter_px，单位是像素。面积接近但边界更曲折的目标，周长往往更长。

边界与误区：噪声、锯齿和阈值波动会拉长轮廓。比较周长前应统一分辨率和预处理方法。

学习练习（答案见独立答案册）

Q055-1 arcLength 的 closed 参数为什么重要？

Q055-2 放大两倍周长如何变化？

Q055-3 为什么周长对噪声更敏感？

Q055-4 圆度低一定代表缺陷吗？

Q055-5 简化轮廓会怎样影响周长？

Q055-6 周长可以直接用于毫米验收吗？

056 图像矩与质心 (centroid)

实验输入：image。用途：零件计数、轮廓检测和形状一致性。

学习目标与直观理解

找到目标区域的几何中心，作为定位、轨迹或偏移测量的参考点。

可以想象把每一小块区域都当成同样重，计算它们的平均位置。图像矩是高效计算这种平均位置的累加量。

核心机制与推导

图像矩把位置按像素质量或区域面积加权。零阶矩表示总质量，一阶矩除以零阶矩得到质心；中心矩再以质心为原点描述分布。二值掩膜、灰度加权图和轮廓多边形的矩对应不同质量模型，不能混为一谈。质心不是外接框中心，也不保证在前景内部。平台由轮廓矩计算，退化轮廓 $m_{00}=0$ 时不能正常相除。

$cx=m_{10}/m_{00}$, $cy=m_{01}/m_{00}$; $mpq=\sum x^p y^q I(x,y)$ (图像矩形式)。

参数、实验与结果解读

项目默认参数: `threshold=127`; `min_area=100`。

建议实验：对 L 形、环形与亮度渐变区域比较几何质心、灰度质心和外接框中心。

结果解读：`centroid` 给出 $[x, y]$ ，从左上角起算。看中心标记是否随目标位置一起移动。

边界与误区：凹形目标的中心可能落在物体外部；这里也没有按照真实质量或材质密度加权。

学习练习（答案见独立答案册）

Q056-1 零阶矩是什么？

Q056-2 质心一定在目标内吗？

Q056-3 灰度质心为什么偏向亮区？

Q056-4 $m_{00}=0$ 应怎样处理？

Q056-5 质心与外接框中心为何不同？

Q056-6 平移图像后中心矩会怎样？

057 外接框 (bounding_box)

实验输入：image。用途：零件计数、轮廓检测和形状一致性。

学习目标与直观理解

用矩形概括物体的范围，比较固定坐标方向的框与可旋转的紧致框。

轴对齐框沿图像水平和垂直方向；最小面积矩形可以旋转，寻找更贴合轮廓的方向。

核心机制与推导

水平外接框取 x 、 y 极值，计算简单但对倾斜长物体会包含大量背景。最小面积旋转矩形允许改变方向，通常通过凸包和候选边方向搜索获得更紧的矩形。返回的宽高和角度依赖库约定，同一个几何矩形可能通过宽高交换加 90° 表示。框并不是真实物体边界，缺口和圆角都被忽略；用于尺寸估计时还需考虑阈值与成像方向。

轴对齐框由 $xmin$ 、 $ymin$ 、 $xmax$ 、 $ymax$ 定义；旋转框最小化 $A(\theta)=w(\theta)h(\theta)$ 。

参数、实验与结果解读

项目默认参数：threshold=127；min_area=100。

建议实验：将细长矩形旋转，比较水平框面积与旋转框面积，并记录角度跳变时四顶点是否连续。

结果解读：box 是 $[x, y, \text{宽}, \text{高}]$ ；oriented_box 是旋转框的四个顶点。用数据比较倾斜物体的两种范围。

边界与误区：框内通常还含背景，不能把框面积当作物体面积；紧致框的角度也可能在宽高交换时跳变。

学习练习（答案见独立答案册）

Q057-1 水平框为何随旋转变大？

Q057-2 最小面积框等于真实轮廓吗？

Q057-3 宽高为什么突然交换？

Q057-4 boundingRect 的 w 是否总等于 xmax-xmin？

Q057-5 哪种框更适合粗定位？

Q057-6 用框宽代替零件宽有什么风险？

第 05 模块 几何与传统分割

058 ROI 裁剪 (crop)

实验输入：image。用途：只分析有效检测区域。

学习目标与直观理解

只取图中的一块矩形区域，减少无关背景，或为后续算法准备局部输入。

裁剪就是按行列范围取出一个数组片段，不缩放里面的像素。ROI 指“感兴趣区域”，格式为 [x,y,宽,高]。

核心机制与推导

ROI 裁剪选择原图的一个子区域，并建立新的局部坐标原点。NumPy 切片使用半开区间，右端和下端不包含，因此 [y:y+h,x:x+w] 恰好得到 h×w 的区域。裁剪不改变原区域内像素的尺度，但检测坐标必须加回偏移才能回到原图。若随后又缩放，则应按逆序先除缩放再加偏移。平台记录 origin_offset，且对越界矩形进行约束；保存或传递 ROI 时要保留这个几何关系。

$x_{\text{原}} = x_{\text{局部}} + x_0$, $y_{\text{原}} = y_{\text{局部}} + y_0$; ROI=[x0,y0,w,h], 不等同于 [x1,y1,x2,y2]。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：裁剪一个角落目标，在 ROI 中读坐标，再加偏移验证原图位置。

结果解读：结果尺寸应等于所选区域大小，origin_offset 记录它在原图中的左上角位置。

边界与误区：结果中的点加上 `origin_offset` 才能映射回原图。裁剪改变的是坐标起点，不是实际像素大小。

学习练习（答案见独立答案册）

Q058-1 裁剪会改变每毫米像素数吗？

Q058-2 `[10,20,100,50]` 在本项目表示什么？

Q058-3 为什么切片右下端不包含？

Q058-4 ROI 检测点怎样映射回原图？

Q058-5 越界 ROI 应如何处理？

Q058-6 裁剪结果是否一定独立占内存？

059 缩放与插值 (**resize**)

实验输入：image。用途：模型输入、图像缩放。

学习目标与直观理解

改变图片宽高，比较放大、缩小时不同插值方式对边缘和细节的影响。

新网格与旧网格通常对不上，插值负责估计新像素。最近邻直接取最近的旧值，线性和三次插值会综合周围像素。

核心机制与推导

缩放本质是重采样：为输出像素找到输入连续坐标，再通过插值估计值。最近邻直接选一个样本，双线性组合四邻域，双三次和 Lanczos 使用更宽邻域。缩小时若不先抑制超过新采样率允许的高频，会产生混叠，面积重采样常适合这种场景。标签图的数值代表类别，应使用最近邻，避免插值生成不存在的类别。不同库的像素中心对齐约定也可能产生半像素偏移。

双线性 $O=(1-a)(1-b)I_{00}+a(1-b)I_{10}+(1-a)bI_{01}+abI_{11}$ ； a 、 b 为小数偏移。

参数、实验与结果解读

项目默认参数：`scale=0.5`；`method=linear`。

建议实验：缩小棋盘纹理观察摩尔纹，再分别用最近邻和线性缩放类别标签图。

结果解读：放大后观察斜边锯齿和文字清晰度，缩小后观察细线是否消失。结果尺寸随比例变化。

边界与误区：放大不能创造可靠的真实细节；分割标签图一般用最近邻，避免插值产生不存在的类别编号。

学习练习（答案见独立答案册）

Q059-1 为什么缩小前需要抗混叠？

Q059-2 标签图为什么选最近邻？

Q059-3 双线性一定比最近邻清晰吗？

Q059-4 放大能增加真实细节吗？

Q059-5 缩放后焦距参数怎样变？

Q059-6 为什么不同库缩放结果略有偏移？

060 旋转 (rotate)

实验输入：image。用途：方向校正。

学习目标与直观理解

将图片绕中心旋转，理解角度、插值和画布边界的关系。

先计算旋转矩阵，再为输出位置寻找输入像素。平台保持原画布宽高，多出的内容会被裁掉，空缺处填黑。

核心机制与推导

平面旋转围绕指定中心改变坐标，其连续变换可由正交矩阵表示。实现通常反向遍历输出网格，从输入位置插值，避免正向映射造成空洞。平台以图像中心旋转，输出画布仍为原尺寸，因此角部可能裁掉且边界出现空白。若要完整保留，应

变换四角、重新计算外包画布，并修正平移量。旋转不会消除透视，也不保证多次插值后图像完全可逆。

$[x'-cx, y'-cy]^T = R\theta [x-cx, y-cy]^T$; $R\theta$ 为二维旋转矩阵，显示坐标 y 向下需遵循库角度约定。

参数、实验与结果解读

项目默认参数：angle=15。

建议实验：对带角落标记的图片旋转 45°，检查裁切；比较一次 30° 与三次 10° 的模糊程度。

结果解读：观察正角度时的旋转方向，以及四角出现的黑边。与原图比较是否有内容被截出画布。

边界与误区：黑角不是算法找到的背景，而是没有来源像素的填充。若需完整保留，应在 Python 中扩大输出画布。

学习练习（答案见独立答案册）

Q060-1 为什么旋转后角落消失？

Q060-2 反向采样有什么好处？

Q060-3 旋转再反向旋转能精确恢复吗？

Q060-4 旋转中心不同会怎样？

Q060-5 图像坐标角度为何容易混淆？

Q060-6 旋转可以校正斜拍文档吗？

061 仿射变换 (affine)

实验输入：image。用途：平面图像对齐。

学习目标与直观理解

用一个矩阵同时描述平移、旋转、缩放或剪切，理解坐标变换怎样作用于图片。

2×3 矩阵的前两列控制方向和尺度，最后一列控制平移。例如默认矩阵把内容向右 20、向下 10 像素移动。

核心机制与推导

仿射变换由线性变换加平移组成，能表达旋转、缩放、错切及其组合。它保持直线和平行关系，但一般不保持长度、角度与面积；面积按线性部分行列式绝对值缩放。二维仿射有六个自由度，三对不共线点可解。矩阵接近奇异时逆映射会放大误差；项目输入为 2×3 矩阵，固定输出画布也可能裁掉内容。

$p' = Ap + t$ ；齐次形式 $[p'; 1] = [A, t; 0, 0, 1][p; 1]$ ；面积倍率 $= |\det A|$ 。

参数、实验与结果解读

项目默认参数：matrix=[[1,0,20],[0,1,10]]。

建议实验：用横向错切观察矩形变平行四边形，验证平行边仍平行而直角不再保持。

结果解读：用明显的角点作参照，确认方向和位移。平行线在仿射变换后仍然平行。

边界与误区：画布大小保持不变，超出部分被裁去。仿射不能修正所有透视问题，斜拍平面通常需要透视变换。

学习练习（答案见独立答案册）

Q061-1 仿射需要最少几对点？

Q061-2 仿射保持哪些几何性质？

Q061-3 $\det A = 0$ 意味着什么？

Q061-4 先旋转再平移与反过来相同吗？

Q061-5 仿射能完整校正透视梯形吗？

Q061-6 面积如何随仿射变化？

062 透视变换 (perspective)

实验输入：image。用途：文档矫正、平面测量。

学习目标与直观理解

把斜拍的纸张或平面零件拉正，理解四个对应点如何决定平面映射。

依次选左上、右上、右下、左下四点，程序将这个四边形映射到整个矩形画布。这个映射叫单应变换。

核心机制与推导

透视变换用单应矩阵描述两个平面视图之间的射影关系，齐次坐标计算后必须除以第三分量。矩阵整体乘常数不改变映射，因此有八个自由度，至少四对一般位置对应点才能求解。它保持直线，但不保持平行、长度和角度。适合平面文档校正或近似纯旋转视图，不能统一对齐存在明显深度视差的所有物体。平台将手选四边形映射到整张输出图，不自动保证真实宽高比。

$[u,v,w]^T = H[x,y,1]^T$, $x' = u/w$, $y' = v/w$; H 为 3×3 且仅确定到比例。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：按左上、右上、右下、左下选四点，校正文档；故意交换点序观察为何需凸四边形校验。

结果解读：检查原来平面上的直线是否仍直，边框是否被拉到矩形边缘；homography 保存变换矩阵。

边界与误区：平台输出尺寸沿用原图，不一定是物体真实长宽比。点序错误会扭曲图像，非平面物体也不能靠一个矩阵完全拉正。

学习练习（答案见独立答案册）

Q062-1 单应有几个自由度？

Q062-2 四个点任意选都可以吗？

Q062-3 为什么输出需要除第三分量？

Q062-4 单应能对齐近物和远物吗？

Q062-5 校正后尺寸比例一定真实？

Q062-6 分母接近零有什么风险？

063 图像配准 (register)

实验输入：image、reference。用途：参考差异检测、平面定位。

学习目标与直观理解

把当前图像对齐到参考图，使相同位置尽量重合，为差异检测做准备。

程序找两图可匹配的局部特征，再用一致的对应点估计平面变换，将当前图映射到参考图坐标。

核心机制与推导

图像配准先建立对应关系，再选择变换模型并将一图映射到参考坐标系。本项目流程为 ORB、汉明距离 KNN 匹配、比率筛选、RANSAC 单应估计和透视重采样。质量应同时看内点覆盖范围、重投影误差和视觉对齐；内点集中在一小块时，即使数量多，远处外推也可能失真。配准只修正几何关系，曝光差、非刚体变化和视差仍会留下残差。

重投影误差 $e_i = \|p_{\text{参考}_i} - \pi(H p_{\text{主}_i})\|_2$ ； π 表示齐次坐标归一化。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：用已知平移图验证 H 方向，再测试重复纹理和只在局部有特征的图对。

结果解读：看明显角点、文字边缘是否对齐；同时查看 matches 和 inliers，了解有多少匹配支持变换。

边界与误区：较多内点不保证对齐完全正确。视差、非平面物体或重复纹理可能造成局部错位，差异检测前需目视核对。

学习练习（答案见独立答案册）

Q063-1 本项目配准用什么特征？

Q063-2 匹配点越多一定越准确吗？

Q063-3 H 是主图到参考还是反过来？

Q063-4 配准后差图仍亮可能是什么？

Q063-5 为什么纯色图配准困难？

Q063-6 如何评估配准是否可用于测量？

064 区域生长 (region_grow)

实验输入：image。用途：颜色相近区域分割。

学习目标与直观理解

从你点选的位置出发，找到与种子颜色接近且相互连接的一片区域。

像水从种子向四周蔓延一样，满足颜色容差的相邻像素被加入。本平台以最初种子的颜色为固定比较基准。

核心机制与推导

区域生长从种子出发，通过邻接关系把满足相似性条件的像素加入集合。平台 floodFill 使用固定范围和 4 连通，候选颜色与种子颜色比较，且 B/G/R 分量分别受容差约束。它与浮动范围中“只要和已接纳邻居接近即可”的规则不同：后者在渐变背景上可能逐步漂移很远。容差决定颜色范围，但空间连通性决定远处同色孤岛不会自动加入。

固定范围示意：每通道 $|I_c(q) - I_c(\text{seed})| \leq \text{tol}$ ，并与种子通过合格的 4 邻域路径连通。

参数、实验与结果解读

项目默认参数：tolerance=25。

建议实验：在渐变区域和同色分离双块上点种子，调容差观察边界泄漏及连通限制。

结果解读：白色是生长到的区域。增加容差后区域通常扩大，观察它什么时候越过目标边界进入背景。

边界与误区：与种子颜色相似但不连通的区域不会自动选入；目标有渐变时，容差过小可能只得到局部。

学习练习（答案见独立答案册）

Q064-1 固定范围与浮动范围有何区别？

Q064-2 同色但不连通区域会一起选中吗？

Q064-3 为什么种子位置重要？

Q064-4 tolerance 越大是否区域越大？

Q064-5 这里的容差是 RGB 欧氏距离吗？

Q064-6 如何减少泄漏？

065 分水岭 (watershed)

实验输入：image。用途：相邻零件、细胞分割。

学习目标与直观理解

尝试把彼此接触的亮物体分开，例如粘在一起的颗粒。

先通过距离变换寻找各物体内部较深的位置作为种子，再让不同种子向外扩展，相遇处形成分界线。

核心机制与推导

分水岭把图像看作地形，多个标记从低处扩张，相遇处形成分界。直接使用大量局部极小值会过分割，标记控制版本则以可靠前景和背景种子约束区域数。平台先 Otsu 和开运算得到前景，再用距离变换阈值生成中心种子，将不确定区域标为

零，调用 OpenCV watershed。seed_ratio 改变种子位置和分离程度；错误种子不会被“智能”纠正，粘连目标能否拆开展取决于中心是否分开。

前景种子 $D > r \cdot \max(D)$ ；标记 0 表示未知，结果 -1 表示分水岭边界。

参数、实验与结果解读

项目默认参数：seed_ratio=0.45。

建议实验：对粘连双圆调整 seed_ratio，观察种子由连接到分离时实例分割的变化。

结果解读：看边界图层是否落在接触位置，regions 是否接近实际数量。种子比例会影响哪些内部区域成为起点。

边界与误区：一个物体出现多个种子可能被切碎，多个物体共用一个种子则分不开。先确认前景掩膜是否正确。

学习练习（答案见独立答案册）

Q065-1 为什么直接分水岭容易过分割？

Q065-2 距离变换为何适合做前景种子？

Q065-3 seed_ratio 增大一定增加目标数吗？

Q065-4 labels=-1 是什么？

Q065-5 两物体只有一个种子会怎样？

Q065-6 分水岭与颜色 K-means 有何区别？

066 GrabCut 前景分割 (grabcut)

实验输入：image。用途：前景提取和背景替换准备。

学习目标与直观理解

用一个粗矩形告诉程序主体大致在哪里，再让它进一步区分前景和背景。

框外作为背景样本，框内允许同时包含前景和背景。算法反复学习两类颜色，并在颜色差异和边界平滑之间找分割方案。

核心机制与推导

GrabCut 将前景和背景颜色分别建模为高斯混合分布，用负对数似然衡量像素属于某类的代价，再用相邻像素的平滑代价鼓励一致标签。图割优化二值标签，随后根据新标签更新颜色模型，交替迭代。矩形外是确定背景，矩形内是可能前景，因此必须留有背景样本。能量中的邻接权重在颜色差大处较小，使边界更容易沿明显颜色边缘通过；前景背景颜色相似时仍会失败。

$E(L) = \sum p D_p(L_p) + \lambda \sum (p, q) w_{pq} \cdot 1[L_p \neq L_q]$ ；数据项来自 GMM，平滑项依赖邻近颜色差。

参数、实验与结果解读

项目默认参数：iterations=5。

建议实验：用紧框与含过多背景的框比较分割，再测试前景和背景颜色相近的场景。

结果解读：打开前景掩膜，检查主体是否完整、框内背景是否被排除。框应包住目标，但周围也要留背景。

边界与误区：前景与背景颜色相近时容易选错。增加迭代不一定解决样本不合适的问题，框住整张图也无法提供背景线索。

学习练习（答案见独立答案册）

Q066-1 GrabCut 为什么需要背景区域？

Q066-2 图割优化的两部分是什么？

Q066-3 为什么不是迭代越多一定越好？

Q066-4 四种掩膜状态有什么用途？

Q066-5 颜色相似时为何漏掉目标？

Q066-6 GrabCut 会输出物体类别吗？

067 颜色聚类分割 (kmeans_segment)

实验输入：image。用途：颜色分类和区域简化。

学习目标与直观理解

把繁杂的颜色简化为少量代表色，观察按颜色分组和按物体分割的区别。

K-means 反复做两件事：把像素分给最近的颜色中心，再用该组平均颜色更新中心。K 就是颜色组数。

核心机制与推导

颜色 K-means 把每个像素视作颜色空间中的一个点，交替执行最近中心分配与类内均值更新，降低平方距离总和。平台直接使用 BGR 三维特征，并不加入位置，因此远处同色区域会属于同一类。输出以聚类中心替换原颜色，是颜色量化图；类别编号与零件、背景等语义无固定对应。初始中心影响局部最优，K-means++ 和多次初始化可改善但不能保证全局最优。

$J = \sum_i \|x_i - \mu_{c_i}\|^2$ ；分配 $c_i = \arg\min_k \|x_i - \mu_k\|^2$ ，更新 μ_k 为该组均值。

参数、实验与结果解读

项目默认参数：clusters=5。

建议实验：从 K=2 增到 8，观察颜色细分，并比较同色但空间分离区域的标签。

结果解读：结果像减少了调色板。查看 centers_BGR，比较增加颜色数后哪些细节重新出现。

边界与误区：同色的不同物体可能归为一组，一个多彩物体也可能分成多组；颜色簇不是物体类别。

学习练习（答案见独立答案册）

Q067-1 聚类编号能直接当语义类别吗？

Q067-2 为什么不连通像素也会同组？

Q067-3 K 增大意味着分割更准确吗？

Q067-4 为什么中心用均值更新？

Q067-5 颜色空间会影响结果吗？

Q067-6 如何让聚类更关注空间连续性？

第 06 模块 特征与匹配

068 Harris 角点 (harris)

实验输入：image。用途：定位、匹配和运动估计。

学习目标与直观理解

找出在多个方向上都变化明显的位置，例如棋盘交叉点、窗角，作为稳定的位置标记。

沿直边移动小窗口时，某个方向变化不大；移开角点时，多个方向都会变化。Harris 用这种差别为候选点打分。

核心机制与推导

Harris 从窗口在各方向微移时的强度变化出发，一阶近似得到结构张量 M 。两个特征值都小时为平坦区，一大一小时为边缘，两者都大时任意方向移动都会造成明显变化，因此是角点。响应 R 用行列式与迹避免显式求特征值。平台通过 `goodFeaturesToTrack` 开启 Harris 模式，还会进行质量阈值、距离抑制和数量限制；`max_features` 是上限，不保证一定返回那么多点。

$M = \sum w [I_x^2, I_x I_y; I_x I_y, I_y^2]$ ； $R = \det(M) - k \cdot \text{trace}(M)^2$ ， k 为经验系数。

参数、实验与结果解读

项目默认参数：`max_features=300`。

建议实验：比较棋盘角、单直边和纯色区，再增大特征数上限查看是否仍有足够可靠点。

结果解读：看标记是否集中在角落、纹理交叉处，而不是均匀墙面。最多特征点是上限，不保证一定找到这么多。

边界与误区：模糊会削弱角点，重复图案会带来许多相似点。角点存在不代表它已与另一张图成功匹配。

学习练习（答案见独立答案册）

Q068-1 为什么单条边不是稳定角点？

Q068-2 Harris 响应怎样区分角点？

Q068-3 它具有尺度不变性吗？

Q068-4 `max_features=300` 必定有 300 点吗？

Q068-5 为什么需要非极大值或距离抑制？

Q068-6 旋转时理论上为什么较稳定？

069 Shi-Tomasi 角点 (shi)

实验输入：image。用途：定位、匹配和运动估计。

学习目标与直观理解

选出适合短距离跟踪的角点，常用作稀疏光流的起点。

Shi-Tomasi 也考察小窗口在不同方向的变化，但更关注最弱方向是否仍足够明显，避免选择仅像一条边的位置。

核心机制与推导

Shi-Tomasi 直接用结构张量较小特征值作为角点质量，因为局部运动估计要求两个方向都具有足够约束。若最小特征值接近零，求解会病态，出现沿边滑动的孔径问题。与 Harris 相比，判据更直接联系 Lucas-Kanade 跟踪的条件数。平台在灰度图上筛选并保持特征间距，适合为稀疏光流选择初始点，但强纹理点也可能因遮挡和模糊在下一帧失效。

$R = \min(\lambda_1, \lambda_2)$ ；选 $R > T$ 的局部极大点，使结构张量在两个方向都有足够约束。

参数、实验与结果解读

项目默认参数：`max_features=300`。

建议实验：在同一图上比较 Harris 与 Shi-Tomasi 分布，再用选点进行光流观察失效位置。

结果解读：比较棋盘角、文字拐角与平坦区的点数，并与 Harris 的位置分布对照。

边界与误区：这些点只有坐标，没有自动获得物体语义或匹配身份。跟踪是否成功还需看后续帧。

学习练习（答案见独立答案册）

Q069-1 为什么选最小特征值？

Q069-2 它与 Harris 的主要区别？

Q069-3 为什么适合光流选点？

Q069-4 平坦区为什么不能可靠跟踪？

Q069-5 好角点能保证后续一直跟踪成功吗？

Q069-6 点都集中在一角有什么风险？

070 SIFT 特征 (sift)

实验输入：image。用途：定位、匹配和运动估计。

学习目标与直观理解

寻找在缩放和旋转后仍比较容易重新认出的局部特征，用来匹配同一场景的不同照片。

SIFT 在多个模糊尺度上找显著点，再为每一点周围的梯度方向生成一串数字，称为描述子。

核心机制与推导

SIFT 先构建高斯尺度空间，用相邻尺度差分 DoG 近似尺度归一化 LoG，在空间与尺度邻域找极值。随后细化位置，剔除低对比及不稳定边缘响应，为关键点分配梯度主方向。描述子将邻域分成 4×4 单元，每单元统计 8 个方向，形成 128 维向

量，并归一化降低亮度幅值影响。尺度和方向归一化提供近似不变性，但强透视、非刚体和重复纹理仍可能误配。

$D(x,y,\sigma)=L(x,y,k\sigma)-L(x,y,\sigma)$ ；描述子维数 $4\times4\times8=128$ ，常用 L2 距离比较。

参数、实验与结果解读

项目默认参数：max_features=300。

建议实验：对同一纹理缩放、旋转和改变曝光，比较关键点重复率及匹配是否仍指向同一物理位置。

结果解读：图层标出特征位置，descriptors 数组保存描述子。观察纹理丰富处通常比纯色处有更多点。

边界与误区：点多不等于匹配准；重复纹理和强烈视角变化仍会误配，需要距离筛选和几何验证。

学习练习（答案见独立答案册）

Q070-1 为什么在尺度空间找点？

Q070-2 DoG 与 LoG 有何联系？

Q070-3 主方向赋值有什么作用？

Q070-4 128 维从哪里来？

Q070-5 SIFT 应用汉明距离吗？

Q070-6 尺度不变为何不等于任意视角不变？

071 ORB 特征 (orb)

实验输入：image。用途：定位、匹配和运动估计。

学习目标与直观理解

以较低计算成本提取局部特征，常用于实时匹配与定位教学。

ORB 先找角点、估计方向，再比较附近像素对的亮暗，得到二进制描述子。比较描述子时常用汉明距离，即不同位的数量。

核心机制与推导

ORB 结合 FAST 角点与旋转 BRIEF。图像金字塔提供有限尺度覆盖，角点附近的灰度质心估计方向，然后将成对像素亮度比较的采样模式按方向旋转，得到二进制串。比较两个描述子只需异或后统计不同位，因此较快。二进制特征的鲁棒性依赖比较点分布与图像清晰度；高特征数量不能弥补模糊或重复纹理。平台 ORB 描述子用于配准、匹配与双视图流程。

BRIEF 位 $b_i = 1[I(p_i) < I(q_i)]$ ；汉明距离 $d = \text{popcount}(a \text{ XOR } b)$ 。

参数、实验与结果解读

项目默认参数：max_features=300。

建议实验：对同图旋转、缩小和加模糊，比较 ORB 的点数、分布及几何内点率。

结果解读：观察特征是否覆盖目标，而不是只集中在背景。count 表示实际检测点数，不是匹配数。

边界与误区：大幅缩放、模糊或无纹理会降低稳定性；不要把描述子的数值当作颜色或置信度。

学习练习（答案见独立答案册）

Q071-1 ORB 为什么快？

Q071-2 旋转 BRIEF 怎样处理方向？

Q071-3 为什么不能默认用 L2 匹配 ORB？

Q071-4 金字塔能保证任意尺度不变吗？

Q071-5 增加 nfeatures 能解决无纹理吗？

Q071-6 重复纹理为何容易误配？

072 HOG 方向梯度 (hog)

实验输入：image。用途：传统行人识别、形状描述。

学习目标与直观理解

用许多小线段描述局部边缘朝向，理解传统算法如何用形状而不是原始颜色表示图像。

每个小格子统计不同方向的梯度强度。平台用线段画出九个方向的分布，是 HOG 思路的可视化。

核心机制与推导

HOG 将梯度幅值按方向分桶，统计局部形状的边缘分布。标准检测描述子通常先在 cell 内累积，再将多个 cell 组成 block 做对比度归一化，最后拼接向量并接分类器。无符号方向把相反梯度折叠到 0–180°，弱化亮暗极性差异。项目只画 9 方向局部直方图，每个格子独立缩放，未完整实现标准 block 归一化与行人分类器，因此应将其理解为特征可视化。

$h_c(b) = \sum_{p \in \text{cell}} m(p) \cdot \text{投票}_b(\theta(p))$ ；典型 block 归一化 $v' = v / \sqrt{(\|v\|^2 + \epsilon^2)}$ 。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：对不同方向的条纹看局部线段分布，并比较对比度变化时原始梯度与归一化描述的差异。

结果解读：观察人物轮廓、直边或纹理处的主要线段方向；同一格里较长的线表示该方向响应较强。

边界与误区：各格会独立缩放显示，线长不能直接跨格比较。这里没有运行行人分类器，也不是完整的标准化 HOG 检测流程。

学习练习（答案见独立答案册）

Q072-1 为什么用梯度而非原灰度？

Q072-2 block 归一化有什么作用？

Q072-3 9 个方向就能识别人吗？

Q072-4 无符号方向为什么取模 π ?

Q072-5 平台线长能跨 cell 比较强度吗?

Q072-6 HOG 对旋转是否天然不变?

073 LBP 局部纹理 (lbp)

实验输入: image。用途: 表面纹理分析。

学习目标与直观理解

把局部纹理变成数值模式, 用于观察粗糙表面、重复纹理等微小亮暗结构。

让中心像素与周围八个像素比较, 邻居不暗于中心就记 1, 否则记 0; 八个位组合成 0-255 的编码。

核心机制与推导

LBP 在局部比较邻居与中心灰度, 按固定环绕顺序将比较结果编码成位串。它描述微结构相对亮暗模式, 对保持强度次序的严格单调变换较稳定, 但对噪声和灰度近等值比较敏感。通常统计区域内 LBP 码的直方图作为纹理特征, 而非将码值大小看成粗糙度。旋转不变和 uniform LBP 是扩展定义, 平台的基础 8 邻域版本不能自动获得这些性质。

$$\text{LBP} = \sum_{i=0}^7 2^{i \cdot 1} [g_i \geq g_c];$$
 编码顺序必须固定, 改变邻域顺序会改变码值。

参数、实验与结果解读

本入口无普通数值参数; 输入内容、交互提示和模型预处理仍会影响结果。

建议实验: 对同一纹理加亮、旋转和加噪, 比较 LBP 图与区域码直方图的变化。

结果解读: 结果灰度表示纹理编码, 不再表示原来的明暗。观察同类纹理区域是否呈现相似的模式分布。

边界与误区: 编码 200 不代表比编码 100 更粗糙。边缘一圈在平台中被置零; 噪声也会改变比较结果。

学习练习（答案见独立答案册）

Q073-1 LBP 值越大表示越粗糙吗？

Q073-2 为什么对单调灰度变换较稳？

Q073-3 它为什么对噪声敏感？

Q073-4 基础 LBP 旋转不变吗？

Q073-5 实际纹理分类常使用什么？

Q073-6 平台边缘为何置零？

074 特征匹配 (matching)

实验输入：image、reference。用途：平面配准、全景拼接。

学习目标与直观理解

在两张照片之间画出可能对应的点，为后续配准和拼接提供线索。

先提取 ORB 描述子，再比较最佳与次佳候选的距离。最佳候选明显优于次佳候选时，才通过比率筛选。

核心机制与推导

描述子匹配把几何问题先转为特征空间最近邻搜索。平台对每个 ORB 描述子寻找两个最近候选，要求最佳距离显著小于次佳，排除重复纹理等歧义。这是相对可信度检验，不是对匹配绝对正确性的证明；两个都很差时也可能通过。之后仍需几何验证。本平台该入口虽然展示通过比率的连线，内部共用函数仍估计单应矩阵，因此特征数量不足或几何退化会使实验失败。

通过条件 $d_1 < r \cdot d_2$ ； r 越小越严格。ORB 用汉明距离，SIFT 通常用 L2。

参数、实验与结果解读

项目默认参数：ratio=0.75。

建议实验：在重复窗格图上改变 ratio，比较候选数和最终几何内点数。

结果解读：连接线应指向同一个实体位置。看重复纹理附近是否出现交叉或不合理的连接。

边界与误区：比率越小越严格，匹配数可能减少。平台还会尝试估计单应矩阵，因此需要足够的可靠匹配才能完成实验。

学习练习（答案见独立答案册）

Q074-1 比率筛选为何需要第二近邻？

Q074-2 ratio 降低会发生什么？

Q074-3 比率通过能保证正确吗？

Q074-4 交叉检查与比率筛选相同吗？

Q074-5 为什么此入口也可能报单应失败？

Q074-6 匹配连线交叉一定错误吗？

075 RANSAC 鲁棒匹配 (ransac)

实验输入：image、reference。用途：平面配准、全景拼接。

学习目标与直观理解

从有误配的特征对中找出支持同一个几何关系的一组，减少错误连线干扰。

RANSAC 多次随机抽少量点估计变换，再统计有多少其他点也符合它。支持最多的方案留下，其余视为离群点。

核心机制与推导

RANSAC 在含离群点的数据中反复抽取最小样本估计模型，用全体点的残差统计支持该模型的内点，保留较好假设并通常用内点重估。单应最少四对非退化点。成功概率取决于内点率和样本大小，内点率下降会急剧增加迭代需求。阈值太小会排除真实但有噪声的对应，太大则吸收误配。平台单应使用 4 px 重投影阈值，该数值与图像分辨率有关。

$N \geq \log(1-p)/\log(1-w^s)$ ；p 为期望成功概率，w 为内点率，s 为最小样本数。

参数、实验与结果解读

项目默认参数：ratio=0.75。

建议实验：人为加入错误对应，观察内点率下降时稳定性；比较 1 px 与 4 px 残差门限。

结果解读：结果只画出符合几何关系的内点。比较 matches 与 inliers，观察多少候选被排除。

边界与误区：内点比例高也可能是重复纹理造成的一致误配。还要检查变换后的实际位置是否正确。

学习练习（答案见独立答案册）

Q075-1 为什么随机小样本能抗离群点？

Q075-2 内点率减半为何迭代会大增？

Q075-3 阈值设置过大有什么问题？

Q075-4 四对点就一定能求好单应吗？

Q075-5 内点最多的模型一定是真实模型吗？

Q075-6 图像缩放后阈值该考虑什么？

076 图像拼接 (stitch)

实验输入：image、reference。用途：平面配准、全景拼接。

学习目标与直观理解

把有重叠部分的两张照片合成更大的画面，理解匹配、变换和融合的关系。

先通过特征估计单应矩阵，把两图放到共同画布；重合区域再按距边界的远近加权融合。

核心机制与推导

拼接包含特征对应、几何映射、画布估计和接缝融合四个不同问题。平台用 ORB 和 RANSAC 单应将主图变换到参考坐标，再映射两图四角确定全画布，加入

平移避免负坐标被裁掉。重叠区按到有效边界的距离加权，减少突兀接缝。距离权重应由有效掩膜计算，不能把黑色像素当无效。几何视差、运动物体与曝光差分别需要不同处理，单纯平滑融合无法修正错误对齐。

重叠区 $O = wA + (1-w)B$, $w = dA / (dA + dB + \epsilon)$ ；最终主图变换为平移矩阵 T 与 H 的乘积。

参数、实验与结果解读

项目默认参数：ratio=0.75。

建议实验：用有近景物体与远景的图对拼接，区分接缝颜色问题和双影几何问题。

结果解读：重点看接缝附近的直线、文字和人影是否连续，再检查画布是否包含两图的有效区域。

边界与误区：近处物体的视差、运动目标和曝光差会造成重影。融合能减轻接缝，不能修好错误几何。

学习练习（答案见独立答案册）

Q076-1 为什么先计算完整画布？

Q076-2 羽化融合能消除视差吗？

Q076-3 为什么不能用像素是否为黑判断有效区？

Q076-4 哪类拍摄更适合单应拼接？

Q076-5 接缝亮度突变怎样处理？

Q076-6 画布异常巨大通常说明什么？

077 模板匹配 (template)

实验输入：image、template。用途：固定视角定位、工业模板搜索。

学习目标与直观理解

用一小块已知图案，在大图里寻找最相似的位置，例如固定视角下的标签或图标。

让模板在原图上逐位置滑动，每处计算归一化相关系数，选取得分最高的位置。

核心机制与推导

模板匹配让小图在大图所有合法位置滑动，计算窗口与模板的相似性。平台使用去均值的归一化相关，将亮度偏移和正比例强度变化的影响部分消除。纯色模板去均值后方差接近零，分母退化，因此需要纹理。输出最大值只说明候选中的最佳，不证明目标存在；旋转和尺度变化会破坏像素对应，需要多尺度多角度搜索或改用特征方法。

$NCC = \Sigma(T - \mu_T)(I_{\text{窗}} - \mu_I) / \sqrt{[\Sigma(T - \mu_T)^2 \cdot \Sigma(I_{\text{窗}} - \mu_I)^2]}$ ；越接近 1 越相关。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：用真实目标和不含目标的图分别匹配，收集最佳分数，观察为何需要拒绝阈值。

结果解读：框是最佳位置，score 越接近 1 通常相关性越强。先确认模板内容有纹理、尺寸小于原图。

边界与误区：即使目标不存在，也可能得到一个“最高分”位置。要用负样本确定阈值，尺度或角度变化也会明显影响得分。

学习练习（答案见独立答案册）

Q077-1 为什么纯色模板不适合 NCC？

Q077-2 最大分数存在就意味着目标存在吗？

Q077-3 NCC 能处理任意亮度变化吗？

Q077-4 模板旋转后为何分数下降？

Q077-5 分数图大小如何确定？

Q077-6 如何找多个实例？

078 KNN 小型学习 (knn)

实验输入：image。用途：理解距离、间隔和聚类。

学习目标与直观理解

通过颜色样本理解“附近大多数样本属于哪类，就把新样本归到哪类”的方法。

平台取像素的 R、G 作为二维特征，按 B 是否高于样本中位数生成教学标签；KNN 查找最近的 k 个样本投票。

核心机制与推导

KNN 不显式学习分界参数，而是保存训练样本，预测时按距离找最近 k 个邻居投票。k 小时边界灵活但受噪声影响大，k 大时更平滑但可能吞没少数类。距离受特征尺度影响，量纲大的分量会主导结果。平台取 R/G 作为特征，以 B 是否高于样本中位数构造标签，画的是二维特征空间决策图；这只是监督学习机制演示，没有独立真实任务验证集。

$\hat{y}(x) = \operatorname{argmax}_c \sum_{i \in N_k(x)} 1[y_i = c]$ ；也可使用距离加权投票，但平台为基础邻居分类。

参数、实验与结果解读

项目默认参数：complexity=3。

建议实验：对相同输入比较 k=1、3、9，观察边界碎片与少数样本区域变化。

结果解读：结果是一张特征空间图：横轴 R、纵轴 G，背景色表示预测类别，点表示样本。不是原图上的分割结果。

边界与误区：增大 k 通常让边界更平滑，但这些标签只是教学构造，不能据此宣称真实物体分类准确率。

学习练习（答案见独立答案册）

Q078-1 KNN 的训练与预测成本特点？

Q078-2 k 太小会怎样？

Q078-3 为什么需要特征缩放?

Q078-4 本平台标签来自哪里?

Q078-5 输出背景色对应原图像素位置吗?

Q078-6 训练点分类好能证明泛化吗?

079 SVM 小型学习 (svm)

实验输入: image。用途: 理解距离、间隔和聚类。

学习目标与直观理解

理解分类器如何在特征空间中画出分界, 把两组样本尽量分开。

平台用 R、G 颜色特征和人工构造的蓝通道标签训练 RBF 核 SVM。C 控制对训练错误的惩罚强度。

核心机制与推导

SVM 寻找尽量大的分类间隔, 同时允许部分样本违反间隔约束。C 控制违约惩罚与间隔宽度的权衡, RBF 核把相似度写成距离指数衰减, 从而形成非线性边界。核宽度参数 γ 决定单个样本影响范围, C 大不等于模型必然更好。平台 RBF γ 固定为 0.0001, complexity 对应 C; 特征和教学标签与 KNN 相同, 不能把边界图当作物体识别效果。

$$\min \frac{1}{2} \|w\|^2 + C \sum \xi_i; y_i(w \cdot \phi(x_i) + b) \geq 1 - \xi_i; \text{ RBF } K(x, z) = \exp(-\gamma \|x - z\|^2)。$$

参数、实验与结果解读

项目默认参数: complexity=3。

建议实验: 保持样本不变增大 C, 观察分界对离群点的贴合程度, 并思考验证集选择。

结果解读: 背景颜色显示不同预测类别的区域。调节 C, 观察分界怎样更贴近或更宽容地跨过训练点。

边界与误区：这不是对原图逐像素识别物体的结果，也没有独立测试集；边界贴合样本不等于泛化能力强。

学习练习（答案见独立答案册）

Q079-1 间隔最大化为什么有意义？

Q079-2 C 大代表什么？

Q079-3 γ 与 C 有何不同？

Q079-4 支持向量是什么？

Q079-5 为什么特征标准化对 RBF 重要？

Q079-6 本平台调 complexity 是调什么？

080 K-means 小型学习 (kmeans_demo)

实验输入：image。用途：理解距离、间隔和聚类。

学习目标与直观理解

在二维颜色空间中观察无监督分组：没有预先给每个样本正确类别，也能把相近点聚在一起。

用 R、G 作为坐标，不断把点分配给最近中心，并移动中心到该组均值。复杂度在这里代表聚类数，最少为 2。

核心机制与推导

这个入口把像素投影到 R/G 二维平面，学习 K 个中心，并画出最近中心对应的 Voronoi 分区。它没有监督标签，聚类目标仅是减少类内平方距离。平台散点黑白颜色沿用蓝通道构造标签，只是辅助展示，不能拿它当聚类真值。complexity 在这里表示聚类数，且最少为 2，与 KNN 的邻居数和 SVM 的 C 含义完全不同。

$c_i = \operatorname{argmin}_k \|x_i - \mu_k\|^2$ ；分界处到相邻两中心距离相等，因此二维欧氏情况下边界为直线片段。

参数、实验与结果解读

项目默认参数：complexity=3。

建议实验：固定图像改 K，比较中心分区数量与散点颜色，不把二者一致率当准确率。

结果解读：背景分区表示离哪个中心最近。增加聚类数会把空间划得更细，类别编号本身没有语义。

边界与误区：散点的黑白颜色沿用蓝通道教学标签，并不是聚类真值；不要用背景色与点颜色一致率评价聚类。

学习练习（答案见独立答案册）

Q080-1 为什么分区边界常是直线？

Q080-2 聚类中心编号有固定语义吗？

Q080-3 黑白散点是聚类真值吗？

Q080-4 K-means 为什么可能陷入局部最优？

Q080-5 K 越大目标函数越低就一定更好吗？

Q080-6 如何评价聚类？

第 07 模块 工业视觉

081 零件计数 (count)

实验输入：image。用途：固定相机、稳定光照下的质量检测。

学习目标与直观理解

在前景与背景能分开的条件下统计独立零件，认识“图像区域数”和“真实物体数”的区别。

平台先二值化并找外轮廓，过滤太小的区域，再将保留的轮廓数作为计数。

核心机制与推导

零件计数是“前景分割—提取独立区域—过滤—解释为物体”的组合流程。平台统计满足面积阈值的外轮廓数，因此一个轮廓对应一个零件是核心假设。粘连产生少计，断裂和反光可能多计；内部孔洞通常不会增加外轮廓数量。面积阈值只处理尺寸筛选，不能修正实例分离问题。评估时应记录每张图的漏计、多计及原因，而不是只展示一张成功示例。

$N = \text{数量}\{C_i: \text{Area}(C_i) \geq A_{\min}\}$ ；计数误差 $e = N_{\text{预测}} - N_{\text{真实}}$ ，可分别统计多计与少计。

参数、实验与结果解读

项目默认参数：threshold=127；min_area=100。

建议实验：构造分离、接触、重叠三组零件，记录同一阈值设置下的计数错误。

结果解读：把图上编号逐个对应到实际零件。少计时先看是否两个零件连成一个白区，多计时检查噪点和断裂。

边界与误区：平台按亮前景处理。遮挡、粘连或颜色接近背景都可能影响计数，调整面积阈值不能解决所有分割错误。

学习练习（答案见独立答案册）

Q081-1 为什么分割看起来完整仍少计？

Q081-2 min_area 调大能解决粘连吗？

Q081-3 带孔零件会被算两个吗？

Q081-4 什么情况下噪声导致多计？

Q081-5 评估计数只看平均误差够吗？

Q081-6 工业现场最先改善什么？

082 尺寸、角度与间隙 (measure)

实验输入：image。用途：固定相机、稳定光照下的质量检测。

学习目标与直观理解

从分割出来的轮廓估计宽、高、方向和目标间距，理解像素测量怎样换成实际单位。

用可旋转的最小面积矩形包住目标，并寻找不同轮廓边界间最近距离。有同一平面的“每毫米像素数”时，像素长度除以它得到毫米。

核心机制与推导

该入口将轮廓、旋转矩形和边界点距离组合为测量流程。宽高是最小面积矩形边长，角度来自该矩形，间隙取不同轮廓采样点间最近距离。像素长度转毫米需同一平面的有效尺度 p ；图像倾斜、物体高度变化和镜头畸变会让尺度随位置变化。误差来自成像、阈值、几何拟合和尺度标定，不能只看算法输出小数位。生产测量通常还需远心成像或平面校正、重复性与基准件验证。

$L_{mm}=L_{px}/p$ ；相对误差近似 $\delta L_{mm}/L_{mm} \approx \delta L_{px}/L_{px} - \delta p/p$ （微小有符号扰动）。

参数、实验与结果解读

项目默认参数：threshold=127；min_area=100；pixels_per_mm=0。

建议实验：用已知长度基准件标定 p ，在画面中心与四角复测，并比较不同阈值的尺寸偏差。

结果解读：先看旋转框是否贴合目标，再读 width_px、height_px、angle_deg 和 gaps。提供有效尺度后才会出现毫米长度。

边界与误区：未标定时只有像素意义。相机斜视、不同高度和分割偏差都会影响实际尺寸，外接框宽高也可能随方向交换。

学习练习（答案见独立答案册）

Q082-1 相机标定完成就能直接测毫米吗？

Q082-2 输出很多小数是否意味着高精度？

Q082-3 pixels_per_mm=10，宽 250 px 是多少？

Q082-4 为什么阈值会改变宽度？

Q082-5 为什么最小框宽高会交换？

Q082-6 如何验证测量方案？

083 颜色一致性 (color_check)

实验输入：image、reference。用途：固定相机、稳定光照下的质量检测。

学习目标与直观理解

比较当前样本与参考样本的颜色是否接近，适合相同照明和拍摄条件下的颜色一致性检查。

将两图转成浮点 Lab，逐像素计算颜色距离 ΔE_{76} ，再求平均。同时保留原始图像绝对差的区域提示。

核心机制与推导

颜色一致性包含两条不同计算链：平台将归一化浮点 BGR 转 Lab，逐像素计算 ΔE_{76} 并取均值；同时保留 BGR 绝对差灰度阈值形成差异图层。sensitivity 控制后者，并非 ΔE_{76} 阈值。颜色比较要求同位置对应同一材料，且曝光、白平衡、光源与色彩管理尽量一致。全图均值可能掩盖小面积严重色偏，因此还应看 ROI、分位数或异常比例。

$$\Delta E_{76}(p) = \|\text{Lab 当前}(p) - \text{Lab 参考}(p)\|_2; \text{mean_deltaE76} = (\sum \Delta E_{76}) / N。$$

参数、实验与结果解读

项目默认参数：sensitivity=25。

建议实验：在相同图中只改变小块颜色，比较全图平均色差与该 ROI 色差，再检查红色提示层的阈值含义。

结果解读：mean_deltaE76 越小通常越接近；查看两图的 mean_Lab 可以帮助判断偏亮还是偏色。

边界与误区：红色差异图层使用的是像素差阈值，不是 ΔE 阈值。光照、白平衡和对齐误差都可能造成较大差异。

学习练习（答案见独立答案册）

Q083-1 本平台红层是 ΔE 超阈值区域吗？

Q083-2 为什么必须转浮点 Lab？

Q083-3 均值小就表示所有区域合格吗？

Q083-4 为什么白平衡改变会误报？

Q083-5 先求平均 Lab 再算距离等于平均 ΔE 吗？

Q083-6 阈值应该从哪里来？

084 参考图差异 (difference)

实验输入：image、reference。用途：固定相机、稳定光照下的质量检测。

学习目标与直观理解

找出当前图与已经对齐的参考图哪里变了，适合固定视角的外观变化检查。

逐位置计算两图像素的绝对差，再将差异强度超过敏感度阈值的位置标出；变亮和变暗都会产生差异。

核心机制与推导

参考差异逐像素比较主图与已对齐参考图，取绝对差后按强度阈值标记变化。绝对值同时响应变亮和变暗，但不保留方向。平台 `changed_fraction` 统计超阈值像素占比；该量反映变化范围，不直接代表缺陷面积或严重度。配准误差会在轮廓两侧产生条带，光照变化则可能大范围响应。工程中宜先验证对齐与曝光，再按 ROI、面积和形状筛选，而不是把所有差异自动判成缺陷。

$$D=|I-R|; M=1[\text{gray}(D)>T]; \text{changed_fraction}=\Sigma M/N。$$

参数、实验与结果解读

项目默认参数：sensitivity=25。

建议实验：对参考做 1 px 平移、整体增亮和局部缺损，比较三类残差的空间形态。

结果解读：差异图层指出变化位置，changed_fraction 是超阈值像素占比。降低敏感度数值会标出更多位置。

边界与误区：红区只代表“与参考不同”，不代表一定是缺陷。位置偏移、阴影和正常外观变化也会被标记。

学习练习（答案见独立答案册）

Q084-1 absdiff 与饱和减法有什么区别？

Q084-2 sensitivity 降低为什么红区增多？

Q084-3 同一物体轻微移动为何大面积报差？

Q084-4 changed_fraction 能直接当缺陷率吗？

Q084-5 如何保留变化方向？

Q084-6 为什么要用独立正常样本定阈值？

085 表面缺陷规则 (defects)

实验输入：image。用途：固定相机、稳定光照下的质量检测。

学习目标与直观理解

用简单规则寻找比周围明显亮或暗的小结构，例如稳定表面上的斑点和划痕。

先把原图模糊成局部背景估计，再求原图与背景的绝对差，超过阈值的地方作为候选。

核心机制与推导

该规则用高斯模糊估计局部背景，再计算原图与背景的绝对残差。缓慢变化被背景吸收，尺度较小的亮暗异常留在残差里，所以它隐含“缺陷比正常背景变化更快”的假设。平台平滑尺度固定，sensitivity 只控制残差阈值。正常印字、边缘和周

期纹理也满足高频条件，会产生候选；大面积缓慢变化的污染则可能被背景模型吸收而漏检。

$B=G\sigma*I$, $D=|I-B|$, $M=1[\text{gray}(D)>T]$ ；项目背景高斯 $\sigma=7$ 。

参数、实验与结果解读

项目默认参数：sensitivity=25。

建议实验：用正常文字、细划痕和大面积污渍测试，分析哪些符合局部高频残差假设。

结果解读：对照原图确认候选是否覆盖目标缺陷，再检查正常纹理是否也大量变红。changed_fraction 是候选比例。

边界与误区：这是局部残差规则，没有学会缺陷类别；正常文字、边缘和反光都可能被选中。

学习练习（答案见独立答案册）

Q085-1 该方法学到了缺陷类别吗？

Q085-2 为什么大块污渍可能漏检？

Q085-3 正常印字为何误报？

Q085-4 平滑尺度与阈值作用相同吗？

Q085-5 为什么反光容易造成误报？

Q085-6 怎样改进固定规则？

086 缺件与错装规则 (assembly)

实验输入：image、reference。用途：固定相机、稳定光照下的质量检测。

学习目标与直观理解

检查指定区域与标准参考是否一致，用来尝试发现缺件或装配外观变化。

每个矩形 ROI 内计算平均像素差，低于阈值记为通过；所有区域都通过时，整体才通过。

核心机制与推导

缺件与错装入口把每个指定 ROI 与标准参考比较，求灰度绝对差的平均值，并以阈值判定通过。整体结果是所有区域通过的逻辑与。这检测的是外观一致性，不直接验证零件型号或装配功能。ROI 太大时小缺件被平均稀释，太小时正常位置波动可能导致误报。参考必须几何对齐；若想区分缺件、错件、旋转等原因，还需要更多结构化特征或模型。

$\text{score}_j = \text{mean}_{\{\text{ROI}_j\}}(\text{gray}|I-R|)$; $\text{pass}_j = (\text{score}_j \leq T)$, $\text{pass}_{\text{总}} = \text{AND}_j \text{pass}_j$ 。

参数、实验与结果解读

项目默认参数：sensitivity=25; regions=[]。

建议实验：对同一缺件使用大 ROI 与紧 ROI，观察平均差异被稀释的程度。

结果解读：逐项查看 regions 中的 difference 和 pass，定位是哪个区域拉高了差异。

边界与误区：平均值可能稀释一个很小的缺件。先对齐参考图、缩紧检测区域，再用真实合格与不合格样本验证阈值。

学习练习（答案见独立答案册）

Q086-1 为什么小缺件可能仍判通过？

Q086-2 ROI 是越紧越好吗？

Q086-3 一个区域失败时整体怎样？

Q086-4 pass=true 是否证明装配功能正常？

Q086-5 位置偏移与缺件怎样区分？

Q086-6 阈值如何验证？

087 工业异常热力图 (anomaly)

实验输入：image、normal_samples。用途：少量正常样本、固定视角下的外观异常探索；参考库可下载复用。

模型架构：M01 ResNet18 | 残差卷积分类骨干。资源 ID：resnet18。详见前面的架构专题。

学习目标与直观理解

只提供正常样本，让程序找出待检图中与正常外观不相似的位置，适合探索少样本外观异常。

把每张图分成局部特征块，正常块组成记忆库；待检块与库中最近的正常块越不相似，异常分数越高。平台使用随机子采样的 PatchCore 风格方法。

核心机制与推导

工业异常入口使用 ResNet18 中间层局部特征，结合不同感受野的信息，建立正常 patch 向量记忆库。新图每个 patch 到库中最近向量的距离越大，越偏离已有正常外观；距离图再上采样显示。项目是 PatchCore 风格教学实现，以固定随机子采样控制库大小，没有论文中的贪心 coreset。正常样本必须覆盖允许变化，且训练库、查询使用相同预处理和特征模型。距离不是概率，图内归一化热图也不可直接跨图比较严重度。

$s(p) = \min_{m \in \text{记忆库}} \|f(p) - m\|_2$ ；库采用 layer2/layer3 局部特征，项目组合维数为 384。

参数、实验与结果解读

项目默认参数：score_threshold=0。

建议实验：用不同正常光照建库，对比只用单一条件时的误报；读取原始分数而非仅比较热图颜色。

结果解读：先看热图高响应是否落在异常处，再比较 anomaly_score、mean_score。阈值为 0 时仅展示分数，不做合格判定。

边界与误区：分数不是异常概率。不同图的热图会各自归一化，不能只凭颜色跨图比较；光照和位置变化也可能得到高分。

学习练习（答案见独立答案册）

Q087-1 为什么只用正常样本也能找异常？

Q087-2 分数 0.8 就是 80% 异常概率吗？

Q087-3 本项目与完整 PatchCore 有何差别？

Q087-4 正常库越大一定越好吗？

Q087-5 阈值为 0 表示全部正常吗？

Q087-6 为什么换模型后旧库不能直接用？

088 字符校验 (**char_check**)

实验输入：image。用途：批号、标签、编码检查。

模型架构：M11 PP-OCrv4 / RapidOCR | 文字检测、方向与序列识别。资源 ID：rapidocr。详见前面的架构专题。

学习目标与直观理解

先读出标签文字，再检查格式是否符合规则，例如只能包含大写字母和数字的批号。

OCR 负责读字，正则表达式负责规定格式，例如“必须是六位数字”。每段识别出的文字都要整段符合规则，才会标记为通过。

核心机制与推导

字符校验分为视觉识别与字符串规则两层：OCR 输出文本与置信度，正则表达式约束长度、字符集和结构。平台要求每段识别文字整段匹配，而不是只要含有一个合法子串就通过。规则验证能排除格式错误，却无法发现所有“合法字符识别错成另一个合法字符”的情况。真实编码校验还可能需校验位、业务数据库或多次观测，必须区分格式正确、内容正确和编码存在。

`valid(text)=fullmatch(pattern,text)`；例如 `[0-9]{6}` 要求恰好六位数字。

参数、实验与结果解读

项目默认参数：`pattern=[A-Z0-9]+`。

建议实验：测试 123456、12345A、1234567，再测试一个数字识别成另一数字但仍满足格式的情况。

结果解读：查看 `texts` 中的 `text`、`confidence` 和 `valid`。文字读错与格式不符是两类问题，应分别排查。

边界与误区：格式通过不等于编码真实有效。比如识别错一个数字后，仍可能符合“都是数字”的规则。

学习练习（答案见独立答案册）

Q088-1 `fullmatch` 与 `search` 有何区别？

Q088-2 OCR 置信度高就不需规则吗？

Q088-3 六位数字规则能发现 1 被读成 7 吗？

Q088-4 `[A-Z0-9]+` 限制长度了吗？

Q088-5 空文本应自动通过吗？

Q088-6 怎样评估整个系统？

089 工业模板定位 (`industrial_template`)

实验输入：`image`、`template`。用途：固定视角定位、工业模板搜索。

学习目标与直观理解

在稳定相机视角下，用已知零件或标记的小图寻找它在当前画面的位置。

平台使用归一化相关模板匹配，逐位置比较亮度变化模式；它不会自动为模板搜索各种缩放和旋转。

核心机制与推导

工业模板定位沿用归一化相关匹配，但工程重点是稳定成像与可拒绝判定。先选有独特纹理、受反光影响小的模板，再限制搜索区域，统计合格、位置偏差和无目标样本的分数。平台只找单个最佳平移位置，不自动搜索旋转、尺度或多实例。模板同时包含过多背景时，可能在没有完整零件的位置也得高分；还应检查峰值与次峰差异、定位误差及目标有效面积。

$\text{loc}^* = \arg\max \text{NCC}(\text{loc})$; 工程接受条件应结合 $\text{score} \geq \tau$ 、ROI 约束和位置误差, 平台最高分本身不等于通过。

参数、实验与结果解读

本入口无普通数值参数; 输入内容、交互提示和模型预处理仍会影响结果。

建议实验: 让零件轻微旋转、改变光照并从图中移除, 比较最佳分数与定位偏差。

结果解读: 查看最佳框是否落在完整的同类图案上, 再比较合格和不合格样本的 score 分布。

边界与误区: 最佳匹配不等于检测通过。反光、转动或重复零件都可能使最高分框选错位置。

学习练习 (答案见独立答案册)

Q089-1 工业模板与普通模板入口算法不同吗?

Q089-2 为什么模板不宜包含太多背景?

Q089-3 限制搜索 ROI 有何作用?

Q089-4 最佳分数与次峰差值有何价值?

Q089-5 旋转变化如何处理?

Q089-6 怎样定义定位性能?

090 角度测量 (**angle_measure**)

实验输入: image。用途: 固定相机、稳定光照下的质量检测。

学习目标与直观理解

根据物体外轮廓估计它相对图像坐标轴的方向, 适合观察细长零件是否倾斜。

最小面积外接矩形可以旋转, 它的方向用于表示目标方向。矩形的宽高定义会影响返回角度。

核心机制与推导

角度测量使用最小面积旋转矩形的方向，并非直接拟合物体的物理主轴。矩形长短边交换会改变 `angle` 的表示区间，处理连续角度时应依据四顶点或明确的长边方向统一规范。无箭头的长条只有轴向， 0° 与 180° 表示同一轴；近圆或正方形缺少稳定方向，微小噪声便可引发大跳变。需要真实朝向时应加入不对称标记或关键点。

由长边向量 $v=(dx,dy)$ 得 $\theta=\text{atan2}(dy,dx)$ ；无向轴常归一化到 $[0,180^\circ)$ 。

参数、实验与结果解读

项目默认参数：`threshold=127`；`min_area=100`；`pixels_per_mm=0`。

建议实验：逐帧旋转细长矩形和正方形，比较原始 `angle` 与统一长边角度的连续性。

结果解读：结合 `oriented_box` 四个角和 `angle_deg` 一起看，不要只盯一个角度数。对连续旋转样本检查是否发生宽高交换。

边界与误区：圆形或接近正方形的目标没有稳定主方向，角度跳变不一定表示物体突然转动。

学习练习（答案见独立答案册）

Q090-1 `angle_deg` 跳 90° 一定是物体转动吗？

Q090-2 为什么圆形角度不稳定？

Q090-3 0° 与 180° 是否不同朝向？

Q090-4 `pixels_per_mm` 会影响角度吗？

Q090-5 最小框方向与 PCA 方向总相同吗？

Q090-6 如何比较两条无向轴角度差？

091 间隙测量 (`gap_measure`)

实验输入：`image`。用途：固定相机、稳定光照下的质量检测。

学习目标与直观理解

测量两个已分割目标边界之间最近的间隔，例如两块零件之间的最小缝隙。

对两条轮廓的边界点寻找最近距离。它量的是边到边，而不是中心到中心。

核心机制与推导

间隙入口比较不同轮廓的边界采样点，使用最近邻搜索取最小欧氏距离，测的是边到边而不是中心距离。项目轮廓采用链压缩，保留的点未覆盖每一段连续边界，因此该值是离散点间距，不保证等于连续轮廓最短距离。更精确方案可密集采样或计算点到线段、线段到线段距离。间隙通常由最靠近的局部凸起决定，噪点和毛刺会明显影响结果。

$gap = \min_{\{p \in C1, q \in C2\}} \|p - q\|_2$ ；项目 $C1$ 、 $C2$ 是轮廓采样点集， $gap_mm = gap_px / p$ 。

参数、实验与结果解读

项目默认参数：threshold=127；min_area=100；pixels_per_mm=0。

建议实验：用两条错位长矩形比较采样点距离与连续线段距离，再检查细毛刺对最小间隙的影响。

结果解读：gaps 中 pair 指出对应目标编号，gap_px 给出像素间隙；提供尺度后还会有 gap_mm。

边界与误区：先看两个目标有没有被连成同一轮廓；如果粘连，就无法得到它们之间的有效缝隙。

学习练习（答案见独立答案册）

Q091-1 为什么不能用质心距离减宽度替代？

Q091-2 项目间隙是精确连续几何距离吗？

Q091-3 两目标已经粘连会得到有效缝隙吗？

Q091-4 一个毛刺会怎样影响结果？

Q091-5 如何提高距离计算精度？

Q091-6 最小间隙能代表整条缝的宽度吗？

第 08 模块 文字与图文理解

092 二维码识别 (qr)

实验输入：image。用途：物料追溯。

学习目标与直观理解

在图像中找到二维码并读出其中编码的文本，常用于追溯和标签读取。

先定位二维码四边形，校正倾斜，再按二维码编码规则解码。算法输出位置和文字，而不是物体类别。

核心机制与推导

二维码识别先定位具有特定结构的定位图案，估计符号四边形与模块网格，再透视归一化、采样黑白模块、读取格式信息、反掩模并做纠错解码。纠错可以恢复一定范围的码字错误，却不能补救所有失焦、严重透视或定位失败；常见纠错比例也不能直接解释成任意位置可遮挡相同比例面积。平台调用 OpenCV 多码检测解码，位置与文本应分别核验。

几何定位→网格采样→码字读取→纠错→内容解析；模块宽度需要足够像素才能稳定采样。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：对同一二维码逐步降分辨率、模糊和遮挡，区分定位失败与解码失败。

结果解读：查看 codes 中的 text 和 polygon；框的位置正确但文本为空，可能表示找到了候选却未成功解码。

边界与误区：无结果不等于没有二维码。模糊、反光、遮挡或像素太少时，应先改善成像条件。

学习练习（答案见独立答案册）

Q092-1 二维码识别等于 OCR 吗？

Q092-2 找到四边形却无文本是什么情况？

Q092-3 纠错为什么不能保证任意遮挡？

Q092-4 二维码太小为何难读？

Q092-5 静区有什么作用？

Q092-6 无结果能证明没有二维码吗？

093 条码识别 (barcode)

实验输入：image。用途：商品条码。

学习目标与直观理解

读取支持的一维商品条码，学习条纹结构如何变成数字编码。

检测平行条纹、估计方向，再根据支持的码制解码。本接口主要面向 EAN/UPC，不覆盖所有条码标准。

核心机制与推导

一维条码以条与空的相对宽度序列表达数字或字符。检测器先寻找平行条纹区域及方向，校正后沿适当方向采样强度，恢复窄宽模块序列，按支持码制的起止符和校验规则解码。清晰度主要受横跨条纹方向的分辨率影响，沿条纹方向的拉伸影响可能较小。平台 OpenCV 条码接口主要面向支持的 EAN/UPC 等码制，不能把“条码”理解为所有标准通用。

图像条纹→一维强度信号→条空宽度→码制符号→校验；需正确方向与足够静区。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：比较沿条纹与横跨条纹的运动模糊，观察哪一种更破坏解码。

结果解读：查看 codes 中的 type、text 和四边形位置，核对识别出的数字与标签印字。

边界与误区：若反复为空，先确认码制是否支持，再检查条纹方向、对比度和清晰度；不要只不断降低阈值。

学习练习（答案见独立答案册）

Q093-1 为什么条码读取需先估计方向？

Q093-2 横向模糊为何尤其危险？

Q093-3 校验位可以发现所有错误吗？

Q093-4 识别不到时应先调阈值吗？

Q093-5 条码框与数字文本必须一起核对吗？

Q093-6 二维码算法能直接读一维条码吗？

094 文字检测与识别 (ocr)

实验输入：image。用途：标签、批号和印刷文字读取；识别数据可下载为 JSON。

模型架构：M11 PP-OCrv4 / RapidOCR | 文字检测、方向与序列识别。资源 ID：rapidocr。详见前面的架构专题。

学习目标与直观理解

把图片里的印刷文字变成可以复制和检索的字符串，例如标签、批号或说明文字。

先找文字行位置，再校正方向，最后用识别模型把图像纹理转成字符序列。

核心机制与推导

OCR 是多个模型与几何步骤构成的流水线：检测文字行区域，按四边形矫正截图，必要时分类文字方向，再将截图编码为沿宽度展开的特征序列，解码成字符。

项目使用 PP-OCrv4 的检测/识别 ONNX 权重与方向分类器。CTC 类解码把连续重

复标签折叠并移除 blank，解决图像时间步与字符数不等的问题。检测漏行、裁切缺字、方向错误和识别混淆属于不同故障层，应分别检查。

CTC: $P(y|x) = \sum_{\pi: B(\pi)=y} P(\pi|x)$; B 将重复路径符号与 blank 按规则压缩为最终文本。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：对小字号、旋转文字、反光文字分别检查框、截图和最终字符串，定位错误阶段。

结果解读：逐段核对 texts 中的 text、confidence 和 polygon；尤其检查容易混淆的 0/O、1/I 和小数点。

边界与误区：文字框不等于表格单元格或标题类别；反光、弯曲和小字号可能导致漏字或错字。

学习练习（答案见独立答案册）

Q094-1 OCR 架构中检测与识别分别做什么？

Q094-2 CTC 为什么需要 blank？

Q094-3 只提高识别模型能修复漏检吗？

Q094-4 OCR 置信度能当字符串全对概率吗？

Q094-5 0/O 混淆怎样缓解？

Q094-6 文字框能直接表示表格结构吗？

095 版面分析 (layout)

实验输入：image。用途：文档结构整理、OCR 分区前处理。

模型架构：M12 DocLayout-YOLO | YOLOv10 文档区域检测架构。资源 ID：layout。详见前面的架构专题。

学习目标与直观理解

把文档图片中的标题、正文、表格、图片等区域分开，为后续 OCR 或结构整理提供位置。

这是在文档版面样本上训练的目标检测器，识别的是区域类型和矩形范围。

核心机制与推导

版面分析把页面当作具有多尺度语义区域的图像，识别标题、正文、表格、插图和公式等框。项目使用 DocLayout-YOLO 文档检测器，网络在整体上下文与局部结构间交换信息，以适应整页大表格和小标题同时存在的尺度差异。检测输出是区域几何及类别，阅读顺序、表格网格和正文内容不是这些框天然携带的信息。大图缩放可能使小文字结构消失，因此输入分辨率会影响布局识别。

输出集合 $\{(box_i, class_i, score_i)\}$ ；后续可构建区域邻接或阅读顺序图，但不属于单次检测输出。

参数、实验与结果解读

项目默认参数：confidence=0.25。

建议实验：用双栏文章、含跨栏表格和公式的页面，检查框类别，再单独推断阅读顺序。

结果解读：先看区域框是否完整、是否重叠错误，再核对类别和置信度。

边界与误区：表格框不代表已经解析出单元格，正文框也不直接给出阅读顺序；需要结合 OCR 和后续结构处理。

学习练习（答案见独立答案册）

Q095-1 版面模型与普通 OCR 有何区别？

Q095-2 DocLayout-YOLO 架构为何关注多尺度？

Q095-3 检出表格框意味着得到单元格吗？

Q095-4 双栏阅读顺序为何不能按 y 排序？

Q095-5 项目输入是 PDF 还是图片？

Q095-6 怎样评估版面结果？

096 图像相似度检索 (similarity)

实验输入：image、gallery。用途：相似图片检索、样例发现和特征空间学习。

模型架构：M13 CLIP ViT-B/32 | 视觉与语言双编码器。资源 ID：clip。详见前面的架构专题。

学习目标与直观理解

用一张图作为查询，在图库中寻找语义或外观较接近的图片。

CLIP 把每张图片变成一串概括内容的数字，称为特征向量。把它们看成指向不同方向的箭头，方向越接近，余弦相似度越大。

核心机制与推导

图像检索使用 CLIP 的视觉编码器将图片映射到固定维向量，归一化后用余弦相似度排序。ViT 将图像切成 patch，经位置编码和多层自注意力聚合全局语义，再投影到对齐空间。图库特征可离线缓存，查询只需编码一次并计算向量距离。该特征受图文预训练目标影响，擅长语义而非精密像素一致性；同类型不同实例可能很近，微小缺陷可能被忽略。

$s(q,g)=q \cdot g / (\|q\| \|g\|)$ ；单位向量时 $\|q-g\|^2=2-2s$ ，排序可相互转换。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：用同一物体不同背景、同类不同物体和局部缺陷图片建库，分析检索依据偏向什么。

结果解读：看 ranking 的排序和对应图片，而不只看第一名分数。比较前几名差距和实际内容是否吻合。

边界与误区：相似度不是“同一物体”的概率，也不是逐像素一致性；很小的划痕或精密尺寸差异可能不会影响语义排序。

学习练习（答案见独立答案册）

Q096-1 CLIP 图像编码器如何得到向量？

Q096-2 为什么检索前做 L2 归一化？

Q096-3 相似度 0.9 是同物概率吗？

Q096-4 为什么小划痕检索不敏感？

Q096-5 图库特征何时需要重建？

Q096-6 大图库怎样加速？

097 图文检索 (text_retrieval)

实验输入：image、gallery。用途：观察语言描述如何影响图文匹配。

模型架构：M13 CLIP ViT-B/32 | 视觉与语言双编码器。资源 ID：clip。详见前面的架构专题。

学习目标与直观理解

用一句文字描述寻找相近图片，或比较一张图片与多个文字候选哪个更匹配。

CLIP 把文字和图片分别变成可相互比较的数字表示，就像用同一套坐标描述两者。含义越接近，通常相似度越高；有图库时会为每条文字分别排序。

核心机制与推导

CLIP 通过双编码器分别处理图片和文本，两侧投影到同一维度的共享向量空间。训练中用批内配对图文作正样本，其他配对作负样本，双向对比损失拉近匹配对。推理不需要让每张图与每句文本做一次交叉注意力，因此适合预编码大图库。文本模板、粒度与语言都会影响向量，softmax 若使用也只在给定候选集合内相对归一化；平台主要输出余弦分数。

$s_{ij} = \text{normalize}(v_i) \cdot \text{normalize}(t_j)$ ；对比训练 logits 常乘温度倒数，推理相似度不等于检测概率。

参数、实验与结果解读

项目默认参数：prompt=a person。

建议实验：比较 “dog”“a photo of a dog”和更细描述的检索排序，并加入语义相近干扰候选。

结果解读：有图库时看 queries 中各条描述的排序；没有图库时看当前图片对应的文字候选。页面主列表优先显示第一条查询。

边界与误区：分数是相对相似度，不是检测概率。英文提示通常更稳定，文字改变可能导致排序明显变化。

学习练习（答案见独立答案册）

Q097-1 CLIP 与跨模态交叉注意力架构差在哪？

Q097-2 对比学习的正负样本如何构造？

Q097-3 为什么提示词会改变排序？

Q097-4 候选 softmax 分数能跨集合比较吗？

Q097-5 图文检索会输出目标框吗？

Q097-6 中文提示效果为何可能较弱？

098 文字提示目标检测 (grounding)

实验输入：image。用途：开放词汇目标定位和提示词对比。

模型架构：M14 OWL-ViT Base Patch32 | 文本条件区域检测。资源 ID：owlvit。详见前面的架构专题。

学习目标与直观理解

输入物体名称或简短描述，让模型尝试在图中找出对应位置。

OWL-ViT 比较文本特征与图像区域特征，返回匹配的候选框；它不局限于一个固定的传统检测分类头。

核心机制与推导

开放词汇检测将固定类别分类器换成与文本嵌入比较的区域分类机制。OWL-ViT 保留视觉 Transformer 的 patch token，为每个位置预测候选框及区域嵌入，文本

编码器生成类别查询向量，再计算区域与文本相似性。它与只保留全图向量的 CLIP 检索不同。训练仍包含视觉语言预训练和检测监督，开放词汇并不意味着未见领域必然可靠；长而抽象的描述也未必符合其查询表示能力。

区域 i 对文本 c 的分数来自 $\text{normalize}(v_i) \cdot \text{normalize}(t_c)$ 的可学习变换；框头另行回归位置。

参数、实验与结果解读

项目默认参数：confidence=0.25；prompt=a person。

建议实验：输入常见物体名、同义词和专业零件名，比较框位置与低阈值带来的误检。

结果解读：核对框是否真的包含提示词描述的东西。降低阈值后若增加大量不相关框，说明召回和误检发生了权衡。

边界与误区：开放词汇不等于理解任何描述。抽象概念、中文或专业细分类别都可能定位失败。

学习练习（答案见独立答案册）

Q098-1 OWL-ViT 如何支持新类别词？

Q098-2 为什么 CLIP 全图检索不能直接替代它？

Q098-3 开放词汇等于不需要训练数据吗？

Q098-4 框分数与文字生成概率相同吗？

Q098-5 很长的提示为什么可能无效？

Q098-6 降低阈值为何出现无关框？

099 图像描述 (caption)

实验输入：image。用途：辅助概括图片内容，学习视觉到语言生成。

模型架构：M15 BLIP Base Caption | 视觉条件自回归描述。资源 ID：blip。详见前面的架构专题。

学习目标与直观理解

让模型用一句话概括图片中的主要内容，帮助认识图像到语言的生成过程。

BLIP 先提取视觉特征，再根据已经生成的词继续预测下一个词，逐步写出描述。

核心机制与推导

图像描述是条件语言生成：视觉编码器先提取 patch 特征，文本解码器在每一步根据已生成词和图像表示预测下一个 token。BLIP 的训练还包含图文对比与匹配目标，但描述推理的关键通路是视觉编码器加带交叉注意力的自回归解码器。语言先验使句子流畅，也可能补出画面没有的信息；解码策略控制候选搜索，不等于事实核验。平台使用本地 BLIP base 描述权重，输出主要为英文。

$P(y|I) = \prod_t P(y_t | y_{<t}, \text{Enc 图像}(I))$ ；生成在结束符或长度上限停止。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：对拥挤图逐项核对生成句中的对象、动作、数量和关系，标记遗漏与虚构。

结果解读：把输出句子中的对象、动作和关系逐项与原图核对，而不是只判断句子是否流畅。

边界与误区：流畅描述可能遗漏细节或添加不存在的东西。它不能代替精确计数、OCR 或质量判定。

学习练习（答案见独立答案册）

Q099-1 描述模型由哪些主要模块组成？

Q099-2 自回归是什么意思？

Q099-3 为什么流畅句子仍可能错误？

Q099-4 beam search 能解决幻觉吗？

Q099-5 图像描述可以代替 OCR 吗？

Q099-6 怎样评价描述质量？

100 视觉问答 (vqa)

实验输入：image。用途：练习针对图像提问，观察模型对颜色、对象和关系的理解。

模型架构：M16 BLIP VQA | 图像、问题与答案三段通路。资源 ID：blip-vqa。详见前面的架构专题。

学习目标与直观理解

针对图片提一个具体问题，观察模型如何结合图像和文字给出简短答案。

BLIP VQA 同时编码图像与问题，再生成与问题有关的文字答案。相同图片换一个问题，关注的信息也会变化。

核心机制与推导

视觉问答比图像描述多了一条问题条件通路。BLIP VQA 先编码图像，文本问题编码器通过交叉注意力读取视觉 token，形成融合了问题关注点的表示；答案解码器再自回归生成短答案。架构允许相同图片针对不同问题提取不同信息，但仍会利用语言数据偏差，例如常见问题对应常见答案。细小文字、精确计数和无法从图中确定的属性需要专门验证。

$$P(a|I,q)=\prod_t P(a_t|a_{<t},\text{Fuse}(\text{Enc 图}(I),\text{Enc 问题}(q)))。$$

参数、实验与结果解读

项目默认参数：prompt=What is in the picture?。

建议实验：对同一图询问颜色、数量与被遮挡信息，区分可见证据支持的答案和仅凭先验的回答。

结果解读：问题尽量具体，例如询问物体颜色。核对答案是否能在图片中直接找到证据。

边界与误区：英文通常更稳定。精确数量、细小文字或专业知识容易出错；有答案不代表模型有可靠依据。

学习练习（答案见独立答案册）

Q100-1 VQA 比普通 caption 多了什么？

Q100-2 交叉注意力的 Q/K/V 来自哪里？

Q100-3 为什么换问题会关注不同区域？

Q100-4 有答案就说明图中有证据吗？

Q100-5 精确计数为何经常困难？

Q100-6 如何减少不可靠回答？

第 09 模块 深度学习识别

101 图像分类 (classify)

实验输入：image。用途：成品粗分类、材料外观归类；工业专用品类通常需要另行训练。

模型架构：M01 ResNet18 | 残差卷积分类骨干。资源 ID：resnet18。详见前面的架构专题。

学习目标与直观理解

为整张图片选择最可能的类别，例如图里主要是一辆车还是一种动物。它回答“主要是什么”，不负责给每个物体画框。

ResNet18 逐层把像素变为形状和语义特征，最后给 ImageNet 的 1000 个类别打分。预处理会缩放并裁剪画面中心。

核心机制与推导

图像分类通过逐层卷积将局部边缘、纹理组合为更大感受野的语义特征，最后压缩空间维度并输出类别分数。ResNet18 的残差支路学习对输入的修正，使信息和梯度可沿恒等路径传播，缓解深层优化困难。全局平均池化降低参数量，却使输出成为整图标签而非目标位置。平台采用 ImageNet 权重的预处理和中心裁剪，softmax 在已知 1000 类中归一化；未知类仍可能被高置信度归入其中一类。

残差块 $y = \text{ReLU}(F(x) + S(x))$ ； S 为恒等或投影； $p_c = \exp(z_c) / \sum_k \exp(z_k)$ 。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：将目标放中心与边缘分别分类，比较中心裁剪影响，再替换背景检查模型依赖。

结果解读：top5 列出得分最高的五个候选类别；probability 是模型给出的概率分数，范围为 0–1。比较第一名与后几名，并核对中心裁剪是否保留了目标。

边界与误区：分数高也可能是错的。模型只在已学类别里选择，不能可靠地识别没有训练过的工业缺陷。

学习练习（答案见独立答案册）

Q101-1 ResNet18 的主体架构如何组成？

Q101-2 残差连接为何帮助训练？

Q101-3 尺寸变化时如何相加？

Q101-4 分类头为何不能输出每个物体框？

Q101-5 softmax=0.99 能说明未知图必定正确吗？

Q101-6 中心裁剪会造成什么失败？

102 目标检测 (detect)

实验输入：image。用途：通用人、车和常见物品定位；可作为视频轨迹与事件检测的输入。

模型架构：M02 YOLOv8n | 单阶段多尺度检测。资源 ID：yolov8n。详见前面的架构专题。

学习目标与直观理解

在图里同时找出常见物体的位置和类别，例如分别框出每个人、每辆车。

YOLO 根据整图特征提出候选框和类别分数，再删除低分和重复框。这里使用 COCO 80 类权重。

核心机制与推导

YOLOv8n 将检测分为共享视觉特征、多尺度融合和任务预测。浅层保留定位细节，深层提供语义，颈部在不同尺度交换信息；分类与框回归分支分别预测类别和位置。anchor-free 不代表没有网格参考点，而是不依赖预定义多种宽高的 anchor box。边界回归可用离散分布的期望解码距离，训练包含定位、分类和分布相关损失。推理阈值筛掉低分候选，NMS 抑制重复框，再去掉 letterbox 的缩放与填充。

$\text{IoU}(A,B)=|A \cap B|/|A \cup B|$ ；分布回归距离 $d=\sum_k k \cdot \text{softmax}(l)_k$ ，结合网格参考点解码边界。

参数、实验与结果解读

项目默认参数：confidence=0.25。

建议实验：让小目标占不同像素面积，调 confidence，观察漏检与重复框；检查框映射回原图是否正确。

结果解读：先核对框是否贴合，再看类别和 confidence（置信分数，通常为 0–1）。调高阈值会减少低分框，也可能漏掉较难的真实目标。

边界与误区：框不是精确轮廓，置信度也不是测量精度。小物体、遮挡或类别超出训练范围时，空结果并不奇怪。

学习练习（答案见独立答案册）

Q102-1 YOLOv8 的 backbone、neck、head 分别负责什么？

Q102-2 C2f 与 SPPF 的作用是什么？

Q102-3 anchor-free 是完全没有参考点吗？

Q102-4 为什么需要 NMS？

Q102-5 letterbox 后怎样恢复框？

Q102-6 COCO 权重能直接识别任意工业零件吗？

103 旋转框检测 (obb)

实验输入: image。用途: 航拍船舶、飞机、车辆等密集定向目标的定位。

模型架构: M03 YOLOv8n-OBb | 旋转目标框。资源 ID: yolov8n-obb。详见前面的架构专题。

学习目标与直观理解

用可旋转的框包住倾斜物体, 比水平框更紧凑地表达方向和范围。

模型除了位置和大小, 还估计框的方向。平台所用权重在 DOTA 航拍类别上训练, 返回四个顶点。

核心机制与推导

旋转框检测在目标中心、宽高之外估计方向, 更紧凑地表示倾斜长条目标。项目 YOLOv8n-obb 在检测结构上增加角度预测, 最终输出四顶点。旋转几何的重叠不能简单用水平外包框 IoU 代替; 框角度还存在周期与宽高交换的等价性, 训练损失和后处理需处理这种表示问题。当前 DOTA 权重是航拍领域, 形状像工业零件并不意味着类别与纹理已被模型学会。

框可表示为 (cx, cy, w, h, θ) 或四顶点; (w, h, θ) 与 $(h, w, \theta + 90^\circ)$ 可表示同一矩形。

参数、实验与结果解读

项目默认参数: confidence=0.25。

建议实验: 比较水平框与旋转框对细长斜目标的背景包含量, 并测试接近正方形目标的角度稳定性。

结果解读: 查看 polygon 是否沿目标方向贴合, 配合类别和 confidence 判断是否合理。

边界与误区: 航拍权重不等于工业零件权重; 对称目标的方向也可能不稳定, 不能单凭框角度推断朝向。

学习练习 (答案见独立答案册)

Q103-1 OBB 头比水平检测多预测什么?

Q103-2 为什么旋转框对密集目标有利？

Q103-3 能直接用水平框 IoU 评价 OBB 吗？

Q103-4 角度跳变为何可能不是错误？

Q103-5 圆形目标能可靠得到朝向吗？

Q103-6 DOTA 模型检测不到螺丝怎么办？

104 实例分割 (instance)

实验输入：image。用途：独立物体面积、重叠关系与实例级计数。

模型架构：M04 YOLOv8n-Seg | 原型式实例分割。资源 ID：yolov8n-seg。详见前面的架构专题。

学习目标与直观理解

把每一个物体的像素区域单独分出来，即使两个物体属于同一类也使用不同实例编号。

模型先定位实例，再预测每个实例的掩膜，恢复到原图大小。掩膜表示哪些像素属于那个实例。

核心机制与推导

YOLOv8 实例分割在共享骨干与检测头之外生成一组全图掩膜原型，并为每个候选实例预测组合系数。原型按系数线性组合，经非线性得到实例掩膜，再与检测框、候选筛选和尺度映射结合。共享原型比为每个实例单独生成完整高分辨率掩膜更经济，但细孔和薄结构受特征分辨率限制。项目恢复掩膜时去除 letterbox，并保存实例标签；重叠写入单张标签图时只能保留某种覆盖次序。

$M_i = \sigma(\sum_k c_{ik} \cdot P_k)$ ； P_k 为共享原型， c_{ik} 为第 i 实例的系数，之后裁剪/上采样/阈值化。

参数、实验与结果解读

项目默认参数：confidence=0.25。

建议实验：对相邻同类物体比较语义与实例标签，再检查细孔是否被保留和原图边界是否对齐。

结果解读：切换“掩膜”和“目标框”图层，对照边界是否贴合。instance_labels 中 0 为背景，正整数代表不同实例。

边界与误区：同一个编号不是跨视频稳定身份。遮挡部分和细线轮廓可能不准，彩色显示也只是便于区分实例。

学习练习（答案见独立答案册）

Q104-1 实例分割头由哪些额外部件组成？

Q104-2 为什么原型可以共享？

Q104-3 同类两个目标标签应该相同吗？

Q104-4 直接把 letterbox 掩膜拉到原图有何问题？

Q104-5 实例 ID 能当视频跟踪 ID 吗？

Q104-6 掩膜比框更精细就能直接精密测量吗？

105 人体姿态 (pose)

实验输入：image。用途：人体姿态理解、动作前处理与人机交互教学。

模型架构：M05 YOLOv8n-Pose | 人体检测与关键点。资源 ID：yolov8n-pose。详见前面的架构专题。

学习目标与直观理解

在每个人身上定位肩、肘、腕、髋等关键点，理解姿态的几何表达。

人体姿态模型同时预测人的位置和 17 个关键点，平台把高置信度点按固定骨架关系连接起来。

核心机制与推导

姿态估计把人体表示为一组具名关键点与固定连接关系。YOLOv8-pose 共享检测骨干和多尺度特征，同时预测人体框与每个人的关键点坐标及置信信息，属于面

向实例的端到端预测结构。关键点编号定义了左肩、右肩等语义，显示骨架只是按预设边连接坐标。遮挡点可能由先验估计，不能因画出了骨架就当作观测准确。二维关节角受透视影响，也不等于真实三维角度。

二维关节角 $\cos\theta=(\mathbf{u}\cdot\mathbf{v})/(\|\mathbf{u}\|\|\mathbf{v}\|)$ ； $\mathbf{u}$ 、 $\mathbf{v}$ 是从关节点出发的两段骨向量，需过滤低置信点。

参数、实验与结果解读

项目默认参数：confidence=0.25。

建议实验：对正面、侧面和遮挡人体观察 17 点与置信度，再比较二维关节角随视角变化。

结果解读：先看关节点是否落在正确身体部位，再看 keypoint_confidence。缺点或断线可能表示该部位不够可靠。

边界与误区：连成骨架不等于识别出了动作；单帧坐标也没有可靠的真实三维距离。

学习练习（答案见独立答案册）

Q105-1 姿态头与检测头如何关联？

Q105-2 17 个点的顺序能随意更改吗？

Q105-3 有骨架就代表识别出动作吗？

Q105-4 低置信关键点怎样处理？

Q105-5 二维膝关节角等于真实角度吗？

Q105-6 遮挡点输出坐标是否一定来自可见证据？

106 语义分割 (semantic)

实验输入：image。用途：像素面积统计、场景区域划分和下游规则的掩膜输入。

模型架构：M06 DeepLabV3-MobileNetV3-Large | 轻量语义分割。资源 ID：deeplab。详见前面的架构专题。

学习目标与直观理解

为每个像素指定类别，例如哪些像素是人、车或背景，但不区分同类物体中的第几个。

DeepLabV3 将局部外观和较大范围上下文结合，为每个位置输出各类别分数，取最高分作为标签。

核心机制与推导

项目的语义分割为 DeepLabV3 + MobileNetV3-Large。轻量骨干用倒残差、深度可分离卷积和通道注意力降低计算；空洞卷积在不继续降低分辨率时扩大感受野。ASPP 以不同膨胀率的卷积分支及全局池化汇集上下文，拼接后经投影和分类卷积得到每类 logits，再上采样到原图。逐像素 argmax 只给类别，不能区分同类实例；辅助头主要服务训练，项目使用主输出。

空洞卷积 $y[p] = \sum_k w[k]x[p+r \cdot k]$ ； r 为膨胀率； $\text{labels}(x,y) = \text{argmax}_c \text{logits}(c,x,y)$ 。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：查看相邻两个人为何得到同类标签，再比较细边界和大区域的分割质量。

结果解读：彩色区域表示类别；在 segments 中看类别名称和像素数。两个人相邻时可能显示为同一种颜色。

边界与误区：这里是 VOC 类别语义分割，不能把每片连通颜色都当作一个实例，也不会自动识别专用缺陷类别。

学习练习（答案见独立答案册）

Q106-1 本项目 DeepLabV3 使用什么骨干？

Q106-2 ASPP 有哪些典型分支？

Q106-3 空洞卷积增加参数量吗？

Q106-4 语义图中两人连在一起是错误吗？

Q106-5 应先 argmax 再插值吗？

Q106-6 VOC 权重能自动增加工业缺陷类吗？

107 全景分割 (panoptic)

实验输入：image。用途：同时理解物体与场景区域，学习 thing/stuff 的差异。

模型架构：M07 DETR-ResNet50-Panoptic | 集合预测与像素分配。资源 ID：detr-panoptic。详见前面的架构专题。

学习目标与直观理解

同时区分可数的独立物体和大面积背景区域，让“第几个人”与“哪片地面”出现在同一份分割中。

全景分割将实例与语义信息组合：同类的人可分开编号，而同类背景材质区域可以合并。

核心机制与推导

全景分割同时处理可数实体 thing 与不宜按个数划分的材质区域 stuff，并要求最终像素解释一致。DETR 的卷积骨干产生特征图，Transformer 编码全局关系，一组可学习 object queries 通过解码器预测对象；分割分支结合查询和高分辨率特征生成掩膜。训练使用二分图匹配，使预测集合与真值一对一对应。后处理融合同类 stuff、处理重叠与低置信区域，segment ID 必须经 segments 表才能映射到语义类。

$PQ = \Sigma \text{ 匹配 IoU} / (TP + 0.5FP + 0.5FN)$ ；它同时考虑分割质量与识别质量，区别于纯像素 IoU。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：对包含多个人和大片背景的图，核对 segment ID、class ID 与 thing/stuff 归属。

结果解读：先在 segments 中用 segment id 查 label_id，再用 classes 查类别名称；标签图里的数是区域编号。

边界与误区：不要直接把区域编号当类别编号。低分区域可能未分配标签，热图颜色也没有固定物理含义。

学习练习（答案见独立答案册）

Q107-1 DETR 的 object query 是什么？

Q107-2 二分图匹配为什么重要？

Q107-3 全景与实例分割区别？

Q107-4 标签值 5 就是类别 5 吗？

Q107-5 同类 stuff 为什么可合并？

Q107-6 低置信区域怎样解释？

108 交互式分割 (sam)

实验输入：image。用途：人工辅助标注、交互提取前景和零件轮廓。

模型架构：M08 SAM2 Hiera Tiny | 提示分割与视频记忆。资源 ID：sam2。详见前面的架构专题。

学习目标与直观理解

通过点选或框选告诉模型你想提取哪个物体，适合辅助标注和前景选择。

图像先被编码成特征，前景点、背景点或矩形框作为提示，引导 SAM2 输出符合提示的区域。

核心机制与推导

SAM2 把“提取视觉特征”和“根据提示选择区域”分开。Hiera 图像编码器输出层级特征，提示编码器把正负点或框转换为稀疏 token，掩膜解码器让提示与图像特征交互，预测一个或多个掩膜及质量估计。图像特征可在多次交互间复用，减少重复开销。SAM2 还具有视频记忆体系，但单图提示分割不等于已经启用跨帧传播。平台同时有点和框时优先使用点，提示并不提供类别名称。

`mask=Decoder(ImageFeatures,PromptEmbedding)`；正点约束希望包含的区域，负点约束排除区域。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：对相邻目标先给一个正点，再加入负点，观察误选区域如何收缩。

结果解读：看掩膜是否完整覆盖希望选中的物体。前景点应在物体内部，背景点可用来排除容易混入的区域。

边界与误区：掩膜不会告诉你物体叫什么。当前平台同时有点和框时优先使用点提示，修改提示比盲目重复运行更有意义。

学习练习（答案见独立答案册）

Q108-1 SAM2 架构有哪些核心模块？

Q108-2 为什么多次点选可以复用图像编码？

Q108-3 负点与删除正点相同吗？

Q108-4 掩膜质量分数是语义分类概率吗？

Q108-5 本平台点和框同时存在如何处理？

Q108-6 SAM 分出区域就能认定缺陷吗？

109 人脸关键点 (face)

实验输入：image。用途：面部几何分析、表情与头部姿态前处理；不做人脸身份识别。

模型架构：M09 MediaPipe Face Landmarker | 检测、ROI 与密集脸部点。资源 ID：face_landmarker。详见前面的架构专题。

学习目标与直观理解

标出脸部轮廓、眼睛、鼻子等局部位置，学习脸部几何，而不是识别人是谁。

MediaPipe 先定位人脸，再估计面部网格。返回的 x、y 通常按图像宽高归一化，乘宽高可换成像素坐标。

核心机制与推导

人脸关键点采用检测—对齐裁剪—密集回归流水线。检测网络先定位脸部，ROI 变换减少尺度与姿态差异，关键点网络预测面部网格和虹膜等点，再映射回原图。任务输出还可能包含其他分支，但本平台主要使用 landmarks，不做人脸身份识别。归一化 x/y 乘宽高可得到图像坐标， z 的约定来自模型的相对几何体系，不能直接读取为毫米；单目尺度与遮挡仍限制几何精度。

$x_{px}=x_{norm}\cdot W$, $y_{px}=y_{norm}\cdot H$ ；头部姿态若用 PnP，还需选定三维脸模型、相机内参和对应点。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：比较正脸、侧脸和遮挡脸的点分布，检查眼角、嘴角以及 z 是否被错误解释为真实距离。

结果解读：检查点是否落在对应的眼角、嘴角和脸部边缘，再读取 landmarks 中的位置。

边界与误区： z 是相对模型坐标，不是毫米。侧脸、小脸或遮挡会使部分点不可靠，本实验不做人脸身份识别。

学习练习（答案见独立答案册）

Q109-1 两阶段架构为什么先检测脸？

Q109-2 478 点就意味着精确三维扫描吗？

Q109-3 $x=0.25$ 在宽 800 图上是多少？

Q109-4 人脸关键点与人脸识别有何区别？

Q109-5 侧脸被遮挡的点可信吗？

Q109-6 由关键点估计头姿还需什么？

110 手部关键点 (hand)

实验输入：image。用途：手势交互、抓取姿态的教学分析。

模型架构：M10 MediaPipe Hand Landmarker | 手掌定位与 21 点回归。资源 ID：hand_landmarker。

详见前面的架构专题。

学习目标与直观理解

定位手腕和五根手指的关节点，为手势分析提供位置依据。

先找手掌，再预测每只手的 21 个关键点。图像显示坐标由归一化 x 、 y 乘原图宽高得到。

核心机制与推导

手部关键点通过手掌检测先找到相对稳定的目标区域，再由专门网络回归 21 个点，表示手腕与五指关节。手掌比整只伸展手的形状更稳定，有助于定位；裁剪旋转归一化后，关键点网络可集中建模手指细节。输出坐标再恢复到原图，手性和世界坐标等字段需依实际适配器区分。本平台展示的归一化坐标 z 不能直接当真实深度，手势分类需在关键点之后增加规则或时序模型。

单手 21 点=1 个手腕+5×4 个手指点；角度可由相邻骨向量计算，但要处理遮挡与投影。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：测试握拳、张手、交叉双手和镜像输入，核对指尖索引、手性与坐标变换。

结果解读：观察点是否沿实际手指排列，检查遮挡指尖是否被错误补到别处。

边界与误区：检测到关键点不等于已经分类了手势。 z 不可直接当作真实深度，快速运动和互相遮挡会降低稳定性。

学习练习（答案见独立答案册）

Q110-1 为什么先检测手掌而不是直接全图找 21 点？

Q110-2 21 点如何分配？

Q110-3 关键点网络已经识别手势了吗？

Q110-4 镜像会带来什么问题？

Q110-5 双手重叠为何容易失败？

Q110-6 为什么不能把归一化 z 乘宽度当毫米？

第 10 模块 标定与三维

111 单目相对深度 (depth)

实验输入：image。用途：可视化远近关系、场景结构与深度先验。

模型架构：M17 Depth Anything V2 Small | DINOv2 与 DPT 稠密解码。资源 ID：depth-anything。详见前面的架构专题。

学习目标与直观理解

从单张图片估计哪些地方相对近、哪些地方相对远，直观认识场景层次。

模型从纹理、遮挡和训练中学到的经验预测相对逆深度。没有真实尺度参照，不能直接得到米或毫米。

核心机制与推导

单目深度从纹理、透视、遮挡和语义先验推断三维层次，但单张图缺乏确定真实尺度的几何基线。Depth Anything V2 Small 使用预训练视觉 Transformer 提取多个层级的 token，再由 DPT 风格解码器重组为空间特征、多尺度融合并输出稠密相对逆深度。大值通常表示较近，不代表毫米。跨图尺度、偏移和显示归一化都可能不同；即使局部远近正确，镜面、透明物体和未知场景仍可产生错误结构。

理想逆深度与 $1/Z$ 相关，但模型输出 q 未经标定不能直接令 $Z=1/q$ 得到米制距离。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：比较同一场景不同裁剪的原始输出和显示色，观察相对远近与跨图尺度的区别。

结果解读：读取 `relative_inverse_depth` 数组时，较大数值通常表示更近。显示色彩是归一化后的便于观察的映射。

边界与误区：不同图的颜色不能直接比较距离。镜子、透明表面和陌生场景可能误导模型，不应把该结果当作精确测距。

学习练习（答案见独立答案册）

Q111-1 Depth Anything 的编码器和解码器各做什么？

Q111-2 单图为何无法唯一确定真实尺度？

Q111-3 输出大值是更远吗？

Q111-4 取倒数就能得到毫米吗？

Q111-5 为什么玻璃和镜子容易错？

Q111-6 怎样引入真实尺度？

112 相机标定 (**calibrate**)

实验输入：image、calibration_images。用途：尺寸校正、空间理解和重建。

学习目标与直观理解

利用已知尺寸的棋盘格，估计相机的成像参数和镜头畸变，为校正与测量打基础。

比较棋盘上已知三维点与图片里的角点位置，寻找能让投影最接近观测的相机矩阵和畸变参数。需要多张不同视角图片。

核心机制与推导

相机标定拟合三维点到二维像素的投影关系。棋盘提供已知平面坐标，多种姿态让焦距、主点、畸变与外参受到不同约束；只拍几张近乎相同的正视图会造成参数耦合。先提取精确角点，再优化所有观测重投影误差。内参属于相机及分辨率条件，外参描述每张图中的棋盘姿态；格边长度主要决定平移尺度。平台要求至少五张有效视角，实际还应覆盖边缘和倾斜姿态。

$s[u,v,1]^T = K[R|t][X,Y,Z,1]^T$; $K = [f_x, 0, c_x; 0, f_y, c_y; 0, 0, 1]$, 另加镜头畸变模型。

参数、实验与结果解读

项目默认参数: cols=9; rows=6; square_mm=25。

建议实验: 用重复正视图与多角度覆盖图分别标定, 在未参与拟合的图上比较重投影和直线校正效果。

结果解读: camera 是内参, distortion 是畸变系数, rms_reprojection_px 是投影误差。还要看校正后直线是否更直。

边界与误区: 小误差不保证所有位置都标得好。棋盘视角和位置应覆盖画面, 格子尺寸、内角点数量和图像分辨率必须正确。

学习练习 (答案见独立答案册)

Q112-1 内参与外参有何区别?

Q112-2 棋盘 rows/cols 是格子数吗?

Q112-3 为什么要多个不同视角?

Q112-4 格边长度填错会怎样?

Q112-5 RMS 很低就标定完美吗?

Q112-6 改变分辨率后 K 能直接复用吗?

113 畸变校正 (undistort)

实验输入: image。用途: 尺寸校正、空间理解和重建。

学习目标与直观理解

用已经得到的相机内参和畸变系数, 修正镜头让直线变弯的现象。

根据镜头模型重新安排像素位置, 把弯曲的成像映射回理想相机图像。

核心机制与推导

畸变校正通过相机模型将理想像素与实际镜头采样位置对应。径向畸变随到主点距离改变，切向畸变与镜头装配偏心有关。实现常从每个输出理想像素反查原图坐标并插值，避免空洞。新内参参与输出视场选择决定黑边和裁切权衡；校正镜头弯曲并不意味着物体平面已正视，也不自动消除透视缩短。参数必须匹配相机、焦距、对焦及图像坐标条件。

$x_d = x(1 + k_1r^2 + k_2r^4 + k_3r^6) + 2p_1xy + p_2(r^2 + 2x^2)$, y 类似； x/y 为归一化相机坐标。

参数、实验与结果解读

项目默认参数：camera=[[800,0,320],[0,800,240],[0,0,1]]；distortion=[-0.2,0.05,0,0,0]。

建议实验：观察画面边缘的直线，比较校正前后弯曲程度及有效视野损失。

结果解读：选择画面边缘的直线观察是否变直，同时检查边界有无黑边或视野损失。

边界与误区：参数必须来自相同相机和对应分辨率。随便填写一组内参也能得到变化，但不能说明校正正确。

学习练习（答案见独立答案册）

Q113-1 径向与切向畸变分别是什么？

Q113-2 畸变校正等于透视校正吗？

Q113-3 为什么常出现黑边？

Q113-4 参数看起来合理就能用吗？

Q113-5 remap 方式为什么适合重复视频？

Q113-6 校正后能无损恢复原图吗？

114 双目视差与深度 (stereo)

实验输入：image、reference。用途：尺寸校正、空间理解和重建。

学习目标与直观理解

用左右两台相机看到的水平位移推断远近，理解视差与距离的关系。

在已做极线校正的两图中沿同行找对应位置，横向差就是视差 d 。已知焦距 f 和基线 B 时，可用 $f \times B / d$ 计算深度。

核心机制与推导

双目视差在已校正的左右图同一行搜索对应位置。SGBM 用局部匹配代价和多方向路径平滑近似全局优化，P1 惩罚小视差变化，P2 惩罚较大跳变，以兼顾连续表面与边界。项目输出固定点视差需除以 16；无效或非正视差不能用于倒数深度。焦距需用像素、基线需用毫米才能得到毫米深度。远处视差小，固定像素误差会被放大为更大的距离误差。

$$Z = fB/d; \delta Z \approx -fB \cdot \delta d / d^2; f=800 \text{ px}, B=60 \text{ mm}, d=40 \text{ px} \text{ 时 } Z=1200 \text{ mm}.$$

参数、实验与结果解读

项目默认参数：disparities=64; block=5; focal=0; baseline=0。

建议实验：比较近远物体视差与无纹理区域有效率，再观察小视差扰动对深度的影响。

结果解读：先看 valid_fraction 和 disparity_px 的有效区域；视差越大通常越近。只有填写有效焦距与基线后才输出 depth_mm。

边界与误区：无纹理、遮挡和反光区域容易匹配失败。彩色图仅用于显示，不能把无效视差或未标定结果当作毫米深度。

学习练习（答案见独立答案册）

Q114-1 为什么输入必须先极线校正？

Q114-2 P1 与 P2 的作用是什么？

Q114-3 为什么视差要除以 16？

Q114-4 深度误差为何随距离增大？

Q114-5 baseline=60 能保证输出毫米吗？

Q114-6 透明和反光区域为何失败？

115 双目校正 (**stereo_rectify**)

实验输入：image、reference。用途：尺寸校正、空间理解和重建。

学习目标与直观理解

把双目图片变换到便于匹配的几何关系，让同一个点尽量落在左右图的同一行。

利用左右内参、畸变以及两相机间的旋转和平移，为两图分别计算重映射。

核心机制与推导

双目校正通过左右各自旋转与重投影，把两相机变换到具有共同极线方向的虚拟相机。需要内参、畸变以及两相机相对 R/T ；不仅把两图拉成同尺寸，更要让同一三维点对应的极线接近同一水平线。输出 $P1/P2$ 与 Q 描述校正后的投影与视差到三维变换， T 的单位决定三维尺度。应使用多处对应点检查纵向残差，而不只看图像是否“摆正”。

校正后理想对应点满足 $y_{\text{左}} \approx y_{\text{右}}$ ； $Q \cdot [x, y, d, 1]^T$ 给齐次三维坐标，最后需除 W 分量。

参数、实验与结果解读

项目默认参数：calibration={ }。

建议实验：在图像中心和四角标记同一物理点，比较校正前后左右纵坐标差。

结果解读：结果左半和右半是校正后的视图。找相同角点比较纵坐标，理想情况下应接近同一水平线。

边界与误区：需要真实的 $K1$ 、 $D1$ 、 $K2$ 、 $D2$ 、 R 、 T 。画面被变换不代表校正成功，错误参数会使后续视差失真。

学习练习（答案见独立答案册）

Q115-1 为什么需要 R 和 T ？

Q115-2 校正与配准把两图完全重合相同吗？

Q115-3 Q 矩阵做什么？

Q115-4 校正后 y 差很大说明什么？

Q115-5 T 用棋盘格单位会得到毫米吗？

Q115-6 为什么不能只用一组角点验证？

116 双视图基础重建 (reconstruct)

实验输入：image、reference。用途：尺寸校正、空间理解和重建。

学习目标与直观理解

从两个有视角变化的图像中估计相机相对姿态和部分三维点，认识双视图重建。

先匹配特征，用内参将像素换成视线方向，再估计相对旋转和平移；两条视线交会的位置用于三角化。

核心机制与推导

双视图重建从对应点与内参恢复相对姿态，再三角化空间点。像素经 K 逆变换成为归一化视线，本质矩阵 $E=[t] \times R$ 约束两视线的极线关系；分解得到候选姿态，用正深度条件选解。平移只能恢复方向和相对尺度，缺少实际基线时点云不能标成毫米。纯旋转缺少三角化基线，平面与小视差也容易退化。项目不做束调整，且匹配入口还要求可靠单应，因此有额外适用限制。

$x_2^T E x_1 = 0$ ； $P_1 = [I|0]$ ， $P_2 = [R|t]$ ；从两投影方程求齐次点 X ，除最后分量得到三维坐标。

参数、实验与结果解读

项目默认参数：camera=[[800,0,320],[0,800,240],[0,0,1]]；camera_reference=[[800,0,320],[0,800,240],[0,0,1]]。

建议实验：比较纯旋转与带平移图对，再检查重建点的正深度、重投影误差与尺度歧义。

结果解读：查看正深度点数、rotation 和 translation_relative，旋转点云观察是否形成合理结构。

边界与误区：整体尺度未知，不能直接读毫米。纯旋转、重叠不足或退化场景可能无法稳定重建；稀疏点也不是完整物体模型。

学习练习（答案见独立答案册）

Q116-1 本质矩阵与基础矩阵有何区别？

Q116-2 为什么只能恢复相对尺度？

Q116-3 纯旋转为什么不适合三角化？

Q116-4 正深度检查有什么作用？

Q116-5 项目是不是完整 SfM？

Q116-6 重建前应怎样处理畸变？

117 点云查看、滤波与配准 (pointcloud)

实验输入：pointcloud。用途：尺寸校正、空间理解和重建。

学习目标与直观理解

把三维坐标集合画出来，并尝试减少点数、找平面或对齐两份点云。

体素过滤在小立方格里保留代表点；平面模式用 RANSAC 找支持最多的平面；配准模式反复关联最近点并估计刚体变换。

核心机制与推导

点云流程包括空间采样、模型拟合与刚体配准。体素将坐标按网格量化，项目每格保留首个点而非质心。RANSAC 平面反复取三个非共线点估计法向，按点到平面距离选内点。ICP 在当前变换下找最近邻，保留较可信对应，再用 SVD 求最小二乘刚体变换，循环更新；它是局部优化，需要较好初始对齐。项目不保留颜色和法线，显示抽样点数也不等于全部输入点数。

点平面距= $|\mathbf{n} \cdot \mathbf{x} + d|$ ($\|\mathbf{n}\|=1$)；ICP 最小化 $\sum \|\mathbf{R}\mathbf{p}_i + \mathbf{t} - \mathbf{q}_i\|^2$ ，约束 $\mathbf{R}^T \mathbf{R} = \mathbf{I}$ 、 $\det \mathbf{R} = 1$ 。

参数、实验与结果解读

项目默认参数：voxel=0.05；operation=view；distance=0.05。

建议实验：对同一点云施加小变换与大旋转分别配准，比较残差、位置正确性和初值敏感性。

结果解读：view 看结构和点数，plane 看 inlier_count 与平面参数，register 看 transform、rmse 以及是否重合。

边界与误区：单位沿用输入，不自动变成毫米。ICP 需要较好的初始位置，低误差也可能是局部错配；显示点数可能少于保存点数。

学习练习（答案见独立答案册）

Q117-1 体素滤波一定取质心吗？

Q117-2 三个点都能拟合平面吗？

Q117-3 ICP 为什么需要初始对齐？

Q117-4 SVD 后为何检查 $\det R$ ？

Q117-5 RMSE 小一定配准正确吗？

Q117-6 点云单位如何确定？

第 11 模块 图像恢复

118 深度学习超分辨率 (superres)

实验输入：image。用途：观察学习式纹理恢复与传统插值的差异。

模型架构：M18 Swin2SR $\times 2$ | 窗口 Transformer 超分辨率。资源 ID：edsr。详见前面的架构专题。

学习目标与直观理解

把图片宽高放大两倍，并尝试补充看起来合理的细节，与普通插值放大作比较。

Swin2SR 根据局部图块和学习到的图像规律重建高分辨率内容。平台分块处理并融合重叠部分以控制内存。

核心机制与推导

超分辨率试图从低分辨率观测恢复高分辨率图，属于多解逆问题。Swin2SR 以浅层卷积提取特征，使用基于 SwinV2 的窗口注意力和移位窗口在局部与跨窗口交换信息，再由重建头上采样。项目是 $\times 2$ 权重，内部目录 edsr 是历史 ID，不应讲成 EDSR 架构。推理按重叠小块处理并平均融合，控制内存但可能改变跨块上下文。高频纹理来自学习先验，放大像素数不能证明恢复了真实文字或缺陷。

退化示意 $y = \text{Downsample}(k \cdot x) + n$ ；模型 $\hat{x} = f_{\theta}(y)$ ，多种 x 可产生相同 y ，因此恢复需要先验。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：与双三次插值对比细字和重复纹理，并在有真实高清参考时计算误差、检查伪细节。

结果解读：先确认输出宽高是原图两倍，再放大观察文字边缘、纹理和图块接缝。

边界与误区：新增纹理可能是模型推测，不是相机真正拍到的信息；不能用它证明微小文字或做可靠尺寸测量。

学习练习（答案见独立答案册）

Q118-1 Swin2SR 的架构主链是什么？

Q118-2 移位窗口为什么有用？

Q118-3 $\times 2$ 的像素总量变几倍？

Q118-4 为什么不能按 edsr 目录名讲 EDSR？

Q118-5 重叠分块为什么要融合？

Q118-6 视觉更锐利是否等于恢复更真实？

119 深度学习去噪 (denoise_dl)

实验输入：image。用途：相机噪声恢复与传统去噪效果对比。

模型架构：M19 Restormer 真实去噪 | 多尺度通道注意力恢复。资源 ID：swin-denoise。详见前面的架构专题。

学习目标与直观理解

用学习到的图像规律去除相机噪声，并与均值、中值等传统方法比较。

Restormer 从带噪与干净图像的训练关系中学习恢复，结合邻域和较远区域的信息估计干净像素。

核心机制与推导

学习式去噪从成对其他监督中学习图像先验，把带噪输入映射为更可能的干净图。项目使用 Restormer 真实图像去噪权重，历史 ID swin-denoise 不能说明是 Swin 网络。Restormer 采用多尺度编码解码，MDTA 用通道间注意力避免全图空间二次复杂度，GDFN 用门控前馈选择信息，深度卷积补充局部关系。去噪权重与真实相机噪声分布有关，细小缺陷可能被误当噪声，需同时评估细节保留。

$y=x+n$ 的加性模型只是简化；恢复可写 $\hat{x}=y+R\theta(y)$ ，残差 $R\theta$ 学习噪声及误差修正。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：将平坦区域与细纹理分别评价，比较真实相机噪声和人工高斯噪声的恢复差异。

结果解读：同时检查平坦处颗粒减少和细纹理保留；留意图块边缘有没有接缝。

边界与误区：训练噪声与实际噪声不同可能导致残留或过度平滑。工业细小缺陷也可能被误当成噪声。

学习练习（答案见独立答案册）

Q119-1 Restormer 为什么适合高分辨率恢复？

Q119-2 MDTA 与 GDFN 分别负责什么？

Q119-3 本项目实际是 Swin 去噪吗？

Q119-4 干净平滑就代表去噪成功吗？

Q119-5 为什么噪声分布不同会退化？

Q119-6 分块处理应注意什么？

120 深度学习去模糊 (deblur)

实验输入：image。用途：轻中度运动模糊恢复和失败案例学习。

模型架构：M20 Restormer 运动去模糊 | 相同家族、不同任务权重。资源 ID：restormer。详见前面的架构专题。

学习目标与直观理解

尝试改善因运动产生的拖影和模糊，观察恢复算法在哪些情况下有效。

运动去模糊权重根据训练中的模糊与清晰对应关系预测清晰图像，而不是简单地把边缘锐化。

核心机制与推导

去模糊面对的是曝光时间内运动或光学散焦造成的信息混合，不是简单高频不足。项目使用 Restormer 运动去模糊权重，网络通过多尺度特征和通道注意力估计清晰结果，主干结构与去噪近似，但训练目标、权重和归一化配置不同。运动模糊可能空间不均匀，单一卷积核只是简化；强模糊使高频落入不可辨识范围，模型只能依先验猜测，尤其细字不能凭锐度判断正确。

均匀模糊示意 $y=k*x+n$ ；反演需要约束或先验，频率接近零的位置不能稳定直接除以 K 。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：分别测试运动拖影和散焦虚化，核对小字实际内容而非只比较边缘锐利程度。

结果解读：查看双边缘和拖影是否减少，再核对细小文字是否真的正确，而不只是看上去更锐。

边界与误区：强烈模糊丢失的信息无法保证恢复；本权重主要针对运动模糊，散焦模糊不一定适用。

学习练习（答案见独立答案册）

Q120-1 去模糊为何是病态逆问题？

Q120-2 本项目去模糊与去噪网络完全相同吗？

Q120-3 为什么不是用锐化替代即可？

Q120-4 运动权重一定适合散焦吗？

Q120-5 Restormer 的跳跃连接为何重要？

Q120-6 如何评估是否产生虚假细节？

121 前景抠图与背景替换 (matting)

实验输入：image。用途：主体提取、背景替换和透明 PNG 输出。

模型架构：M21 U2NetP | 嵌套 U 形显著前景网络。资源 ID：rmbg。详见前面的架构专题。

学习目标与直观理解

提取显著主体并换背景，同时理解前景与背景之间可以有软过渡。

U2NetP 估计前景强度，变成 0–1 的 α 。输出颜色是 $\alpha \times \text{前景} + (1-\alpha) \times \text{新背景}$ 。

核心机制与推导

严格抠图需估计混合像素中的前景颜色、背景颜色和透明度，单张图通常欠约束。项目使用 U2NetP 显著前景网络，其嵌套 U 形残差块在块内聚合多尺度，再通过外层编码解码与侧输出融合得到前景强度。平台将预测归一化为 α ，用原始图颜色与新背景混合；没有完整解混前景颜色，所以发丝、半透明边缘和旧背景污染可能残留。它应定位为显著主体提取。

真实成像 $I = \alpha F + (1 - \alpha)B$ ；项目替换近似 $O = \alpha I + (1 - \alpha)B$ 新，而非已知无污染 F 的精确合成。

参数、实验与结果解读

项目默认参数：background=#e8eef5。

建议实验：更换黑白两种背景，检查发丝边缘是否出现旧背景颜色与透明孔洞错误。

结果解读：在新背景下检查边缘是否漏出旧背景，透明 PNG 中 alpha 越小越透明。

边界与误区：这是显著前景估计，不是精确发丝抠图。细孔、透明玻璃和多主体可能需要手工修正。

学习练习（答案见独立答案册）

Q121-1 U2NetP 架构的“嵌套 U”是什么意思？

Q121-2 alpha 与二值掩膜区别是什么？

Q121-3 预测前景概率就等于真实 alpha 吗？

Q121-4 边缘为什么残留旧背景颜色？

Q121-5 为什么玻璃常不理想？

Q121-6 透明 PNG 应检查什么？

122 低光增强 Retinex (lowligh)

实验输入：image。用途：低照度图像预处理。

学习目标与直观理解

减弱缓慢变化的照明影响，让低照度区域的纹理更容易观察。

Retinex 把观测亮度想成物体反射与照明的组合。平台用高斯模糊估计照明，在对数空间相减突出反射细节。

核心机制与推导

Retinex 将图像看作照明与反射的乘积，假设照明空间变化较缓慢，用高斯平滑估计照明，在对数域相减提取反射相关成分。项目是单尺度传统 Retinex，不是神经网络。 σ 决定背景照明估计尺度，太小会过度提取局部细节，太大可能保留更多照明变化。加一避免 $\log(0)$ ，结果全局归一化用于显示，不能解释为绝对反射率；逐通道处理也可能引起色偏。

$I \approx R \cdot L$; $\log R \approx \log(I+1) - \log(G\sigma*(I+1))$ ，输出再做显示归一化。

参数、实验与结果解读

项目默认参数：sigma=40。

建议实验：对阴影图调整 sigma，比较细节、噪声与色偏，不只看整体是否变亮。

结果解读：调节光照尺度，观察阴影中的细节与大范围光照是否被区分。

边界与误区：这是传统 Retinex，不是深度学习模型；噪声和色偏也可能被增强，显示亮度不能当成真实反射率。

学习练习（答案见独立答案册）

Q122-1 Retinex 的基本假设是什么？

Q122-2 为什么在对数域相减？

Q122-3 sigma 控制什么？

Q122-4 为什么会增强噪声？

Q122-5 本项目使用深度学习增强吗？

Q122-6 输出值能当实际反射率吗？

123 图像修复 (inpaint)

实验输入：image。用途：去除小划痕、坏点和细小遮挡。

学习目标与直观理解

用周围可见内容补上小划痕或坏点，学习掩膜怎样指定需要修复的区域。

你涂过的位置形成掩膜，Telea 方法从掩膜边界向内部传播周围的颜色和结构线索。

核心机制与推导

Telea 修复将掩膜边界作为已知与未知区域的界面，按快速推进顺序由外向内填充。新像素由邻近已知像素及其梯度加权估计，权重考虑距离和传播方向。它适合小坏点、细划痕等缺失区域，不具备大型语义对象生成能力。radius 决定局部参考范围，太小信息不足，太大可能混入不相关结构。掩膜应覆盖完整缺陷但保留足够真实边界，不应把未遮蔽缺陷误认为算法自动检测失败。

修复域 Ω 由画笔掩膜定义；按到边界的推进次序估计 $I(p)$ ，仅在 Ω 内改写像素。

参数、实验与结果解读

项目默认参数：radius=3。

建议实验：用相同图分别遮住细划痕和大块物体，观察局部传播方法能力的边界。

结果解读：先检查 mask 是否只覆盖待修复部分，再看结果有没有明显接缝或重复拖痕。

边界与误区：没有涂到的缺陷不会自动修复。大面积遮挡缺少参考内容，算法无法可靠地重建原来物体。

学习练习（答案见独立答案册）

Q123-1 Telea 属于生成式大模型吗？

Q123-2 为什么从边界向内填？

Q123-3 掩膜不完整会怎样？

Q123-4 半径越大越好吗？

Q123-5 为什么大面积遮挡难恢复？

Q123-6 修复图能作为真实缺陷不存在的证据吗？

第 12 模块 视频与时序

124 视频动作识别 (action)

实验输入：video。用途：在支持类别与训练分布接近的图像上辅助学习和实验。

模型架构：M22 R3D18 | 三维残差视频分类。资源 ID：r3d。详见前面的架构专题。

学习目标与直观理解

根据一小段连续视频判断可能的动作，而不是只凭一张姿态照片猜测。

R3D18 用三维卷积一起处理空间和时间。平台每次使用连续 16 帧，输出 Kinetics-400 动作类别的排名。

核心机制与推导

动作识别使用连续片段而非单张图。R3D18 将二维卷积扩展到时间×高度×宽度，在残差 stage 中同时提取外观与短时运动，再做全局时空池化和类别预测。时间采样定义了网络看到的运动速度：同样 16 帧在不同 fps 下覆盖的真实时长不同。项目使用连续 16 帧窗口与 Kinetics-400 权重，输出属于该片段的通用动作类别，不是整段视频每个对象的动作定位。

输入形状 $B \times C \times T \times H \times W$ ， $T=16$ ；三维卷积对时间和空间邻域共同乘加。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：比较正常速度、加速视频和相似单帧不同动作片段，观察时序信息的重要性。

结果解读：结合事件中的 window_start 和 time 回看对应片段，再读 top5；不要把一个片段标签当作整段视频的结论。

边界与误区：通用动作类别不等于产线规范动作。镜头运动、多人混杂和视角差异都可能影响判断。

学习练习（答案见独立答案册）

Q124-1 R3D 与逐帧 ResNet 有何区别？

Q124-2 R3D18 的主要架构是什么？

Q124-3 16 帧是否总等于半秒？

Q124-4 片段标签能给出每人的动作吗？

Q124-5 Kinetics 权重能证明工序规范吗？

Q124-6 视频切分为何要避免数据泄漏？

125 帧差 (frame_diff)

实验输入：video。用途：运动分析、轨迹、产线事件。

学习目标与直观理解

找出相邻两帧中亮度发生变化的位置，是认识运动检测的简单起点。

每帧转灰度后与前一帧取绝对差。位置和亮度都不变时接近黑色，发生变化时变亮。

核心机制与推导

帧差比较相邻帧同位置亮度的变化，运算简单但依赖相机稳定与短时照明稳定。运动物体从旧位置离开、在新位置出现，常产生双轮廓而非完整目标实体；纹理均匀的大物体内部可能没有差异。第一帧没有历史参考，应定义为无变化或特殊状态。变化量可用于触发，但要定位完整移动对象常需背景模型或检测器。平台连续处理视频，不应把遗留 sample_every 字段理解为实际丢弃帧。

$D_t = |\text{gray}(I_t) - \text{gray}(I_{t-1})|$ ；位移与帧间时间共同决定差异形态。

参数、实验与结果解读

项目默认参数：sample_every=1。

建议实验：对静止物体、移动物体、开灯和相机抖动分别观察差图，区分运动与亮度变化。

结果解读：第一帧没有前一帧可比，因此为黑。运动物体常在前后位置产生亮边，静止物体可能消失。

边界与误区：亮区不一定是移动物体：相机抖动、开灯和阴影变化也会产生差异。

学习练习（答案见独立答案册）

Q125-1 为什么移动物体常只剩两侧亮边？

Q125-2 第一帧为什么通常全黑？

Q125-3 帧差能检测静止遗留物吗？

Q125-4 相机抖动为什么全图响应？

Q125-5 降帧率对帧差有何影响？

Q125-6 阈值差图就等于运动物体掩膜吗？

126 背景建模 MOG2 (mog2)

实验输入：video。用途：运动分析、轨迹、产线事件。

学习目标与直观理解

让程序逐渐学会固定镜头的背景，把暂时不符合背景外观的像素挑出来。

MOG2 为每个位置维护多个常见亮度或颜色状态，并随着视频更新。它能适应部分背景变化，但需要学习时间。

核心机制与推导

MOG2 为每个像素维护可自适应分量数的高斯混合模型，表示树叶摆动、屏幕闪动等多模态背景。新观测匹配已有分量则更新均值、方差和权重，不匹配则引入新状态；较稳定分量被视为背景。学习率决定适应速度，快则容易把停留物吸收为

背景，慢则难适应光照变化。阴影检测可能输出灰值 127，而前景为 255，简单把非零全当目标会混入阴影。

$p(I_t) = \sum_k w_k \cdot N(I_t; \mu_k, \Sigma_k)$; 权重和为 1, 参数随时间递推。

参数、实验与结果解读

项目默认参数: `sample_every=1`。

建议实验：在固定镜头中放入静止新物体，观察初始前景及逐渐被背景吸收的过程。

结果解读：掩膜中黑色通常是背景、白色是前景，灰色可能是阴影。开头几帧的大量前景应结合背景学习过程理解。

边界与误区：静止很久的物体可能逐渐被吸收进背景；相机移动会破坏背景假设。

学习练习（答案见独立答案册）

Q126-1 为什么每个像素需要多个高斯？

Q126-2 学习率高低有什么取舍？

Q126-3 灰色掩膜通常表示什么？

Q126-4 为什么开头前景很多？

Q126-5 相机移动后为什么容易失效？

Q126-6 MOG2 能判断前景是人还是车吗？

127 稀疏光流 (**flow_sparse**)

实验输入: `video`。用途: 运动分析、轨迹、产线事件。

学习目标与直观理解

跟踪少量容易辨认的角点，观察它们从上一帧移动到了哪里。

Lucas-Kanade 假设局部外观短时间内变化不大，在下一帧附近寻找最相似的位置；点不足时平台会补充新角点。

核心机制与推导

Lucas-Kanade 假设短时亮度恒定，对运动方程线性化，得到每像素一条约束；单像素未知二维速度无法唯一求解，所以在小窗口内假设共同运动，汇总多个梯度方程做最小二乘。结构张量可逆性决定结果稳定，角点优于平坦区与单边缘。金字塔从粗到细处理大位移，迭代细化。平台会补充角点，但新点不一定延续旧身份，光流箭头也只表示图像位移。

$I_x \cdot u + I_y \cdot v + I_t = 0$ ；窗口内解 $(A^T A)[u, v]^T = -A^T b$ 。

参数、实验与结果解读

项目默认参数：sample_every=1。

建议实验：对慢速、快速和局部遮挡视频观察跟踪点数、箭头方向及点重建。

结果解读：箭头由旧位置指向新位置，长度表示每帧位移。tracked_points 反映这次成功跟踪的点数。

边界与误区：箭头不是带单位的真实速度。快速运动、模糊或遮挡可能跟丢，镜头运动也会让整图箭头一起移动。

学习练习（答案见独立答案册）

Q127-1 一条光流方程为何不够？

Q127-2 为什么选择角点？

Q127-3 金字塔如何帮助大运动？

Q127-4 亮度恒定在什么情况下破坏？

Q127-5 像素位移如何换速度？

Q127-6 tracked_points 多就代表全都正确吗？

128 稠密光流 (flow_dense)

实验输入：video。用途：运动分析、轨迹、产线事件。

学习目标与直观理解

为几乎每个像素估计相邻帧间的位移，观察整片区域的运动方向和强度。

Farneback 用局部亮度模型估计位移场。平台将方向编码成色相，将位移大小编码成亮度。

核心机制与推导

Farneback 用局部二次多项式近似亮度分布，比较前后帧多项式系数变化来估计位移，并在邻域和金字塔中聚合优化。与稀疏方法不同，它给几乎每个像素一个运动向量，但无纹理处的结果更多依赖平滑和邻域传播，不代表同等可靠。平台以方向编码色相、幅值编码亮度，且按帧归一化，跨帧颜色亮度不能直接比较速度。

局部 $f(x) \approx x^T A x + b^T x + c$ ；若发生平移 d ，理想情况下系数关系可提供 $A \cdot d \approx -\Delta b / 2$ 。

参数、实验与结果解读

项目默认参数：sample_every=1。

建议实验：对相同运动改变背景纹理，再比较原始 flow 幅值与彩色可视化。

结果解读：同向移动的区域通常颜色接近；mean_motion_px 是平均每帧像素位移。

边界与误区：显示亮度按帧归一化，跨帧看起来一样亮不代表一样快。光照变化和无纹理区域也可能造成不可靠位移。

学习练习（答案见独立答案册）

Q128-1 稠密光流为什么能在无纹理处也输出值？

Q128-2 Farneback 的核心局部模型是什么？

Q128-3 颜色通常表示什么？

Q128-4 两帧热图一样亮说明速度一样吗？

Q128-5 光流等于物体三维运动吗？

Q128-6 为什么运动边界容易混合？

129 单目标跟踪 (single_track)

实验输入：video。用途：运动分析、轨迹、产线事件。

学习目标与直观理解

首帧框定一个目标后，在后续视频里继续寻找它的位置。

CSRT 从最初框内的外观学习相关滤波器，逐帧寻找最匹配区域并更新。它跟踪一个指定外观，而不识别目标类别。

核心机制与推导

CSRT 从首帧框内学习判别式相关滤波器，寻找后续局部区域中与目标外观最匹配的位置，并更新模型。它利用通道可靠性降低不可信特征贡献，空间可靠性约束滤波器更关注目标形状而非矩形背景。跟踪是局部时序搜索，不是每帧独立通用检测；一旦遮挡导致错误区域被用于更新，漂移可能自我强化。首帧框、搜索范围和尺度变化决定可跟踪条件。

相关滤波示意求 h 使 $h \cdot x$ 接近期望峰 y ；后续在搜索区域找响应最大位置，并更新外观模型。

参数、实验与结果解读

项目默认参数：sample_every=1。

建议实验：用紧框与含大量背景的初始框跟踪同一目标，观察遮挡后的漂移和重新出现结果。

结果解读：看框是否持续贴住同一个目标，结合 tracked 字段确认是否报告跟踪成功。

边界与误区：成功标志也可能伴随漂移；完全遮挡后不保证找回同一目标。框错首帧通常会影响整个后续过程。

学习练习（答案见独立答案册）

Q129-1 CSRT 为什么叫通道与空间可靠性？

Q129-2 跟踪器是否知道目标类别？

Q129-3 为什么首帧框很关键？

Q129-4 tracked=true 能保证没漂移吗？

Q129-5 完全遮挡后能保证找回吗？

Q129-6 为什么在线更新既有益又危险？

130 多目标跟踪与轨迹 (multi_track)

实验输入：video。用途：运动分析、轨迹、产线事件。

模型架构：M02 YOLOv8n | 单阶段多尺度检测。资源 ID：yolov8n。详见前面的架构专题。

学习目标与直观理解

给视频中多个检测目标分配临时编号，观察运动轨迹，而不只看每帧独立检测框。

平台每帧用 YOLO 检测，再按同类别框的重叠程度做一对一关联。相近的框延续旧编号，无法关联的目标获得新编号。

核心机制与推导

多目标跟踪先检测每帧对象，再将新框与已有轨迹做一对一关联。项目使用类别约束的 IoU 匹配，重叠足够且类别一致的框延续 ID，未匹配检测创建新轨迹，历史轨迹按状态维护。它没有完整的运动预测和外观重识别，因此快速运动、交叉和长遮挡容易断轨或换 ID。轨迹 ID 只代表当前系统的临时关联，不是人的真实身份。

$$\text{IoU}_{ij} = \text{面积}(B_{\text{旧}_i} \cap B_{\text{新}_j}) / \text{面积}(B_{\text{旧}_i} \cup B_{\text{新}_j})$$
；类别不一致的候选不建立匹配。

参数、实验与结果解读

项目默认参数：sample_every=1。

建议实验：在两人交叉和短时遮挡视频中记录 ID 切换，区分检测漏检与关联错误。

结果解读：观察同一物体的编号是否连续、轨迹是否平滑，再看遮挡后有没有换号。

边界与误区：这是简化的 IoU 关联，不含外观重识别。编号不是人的真实身份，计数前必须考虑 ID 切换和误检。

学习练习（答案见独立答案册）

Q130-1 本项目多目标跟踪架构是什么？

Q130-2 一对一关联为什么必要？

Q130-3 为什么快速运动容易换号？

Q130-4 类别约束有什么利弊？

Q130-5 如何改进长遮挡后的关联？

Q130-6 检测 mAP 高就代表跟踪好？

131 计数、越线、区域与停留 (events)

实验输入：video。用途：运动分析、轨迹、产线事件。

模型架构：M02 YOLOv8n | 单阶段多尺度检测。资源 ID：yolov8n。详见前面的架构专题。

学习目标与直观理解

把轨迹转成可检查的事件，例如进入区域、越过竖线、停留够久或离开区域。

平台用目标框中心判断是否在矩形 ROI 内，比较前后中心在线的哪一侧，并按视频时间累计连续停留。

核心机制与推导

事件检测将轨迹几何转为状态变化。平台用框中心判断 ROI 内外，用前后中心在线的两侧判断越线，再按视频时间累积连续停留。enter/exit 是状态跳变，dwell 是持续条件，不能仅凭当前帧位置判断。噪声使中心在边界附近抖动时可能重复触发，需要迟滞或防抖等工程策略；漏检和 ID 切换也会改变累计。计数口径必须区分事件次数与唯一轨迹数。

竖线越线示意 $(x_{t-1} - x_{line})(x_t - x_{line}) < 0$ ；停留时长用时间戳差，而非处理耗时。

参数、实验与结果解读

项目默认参数：sample_every=1；line_x=0.5；dwell=2。

建议实验：让目标沿边界徘徊、短暂漏检和反复越线，核对事件时间与唯一 ID 计数差别。

结果解读：点击时间轴事件回看触发帧，检查 track_id、time 和 evidence 中的中心、线、区域是否符合规则。

边界与误区：停留依赖连续检测，漏检会中断累计。唯一越线编号数不是越线总次数，ID 切换也可能影响计数。

学习练习（答案见独立答案册）

Q131-1 为什么要保存前一帧状态？

Q131-2 dwell 用系统处理时间合理吗？

Q131-3 框中心在 ROI 内等于目标全在内吗？

Q131-4 边界抖动怎样减少重复触发？

Q131-5 唯一越线人数等于越线次数吗？

Q131-6 事件为何要保存 evidence？

132 事件顺序规则 (sequence)

实验输入：video。用途：运动分析、轨迹、产线事件。

模型架构：M02 YOLOv8n | 单阶段多尺度检测。资源 ID：yolov8n。详见前面的架构专题。

学习目标与直观理解

验证同一个跟踪目标是否在限定时间内依次完成指定事件，例如进入、越线、停留。

为每个 ID 保存已经匹配到序列的哪一步；新事件符合下一步才前进，超时后重新开始。

核心机制与推导

顺序事件规则为每个轨迹维护有限状态机：状态 k 表示已完成前 k 个事件，下一事件匹配时推进，满足时间窗口后完成，否则按规则重置。它检查的是检测事件序列，不直接理解真实作业动作。窗口起点、超时、重复事件和无关事件处理方式决定语义，必须明确。若轨迹换 ID，同一物体的历史可能丢失；若不同目标共享状态又会错误拼接流程，所以状态应与目标关联。

状态 $0 \rightarrow 1 \rightarrow \dots \rightarrow m$ ；只在事件等于 $\text{order}[k]$ 时推进，要求 t 完成 $-t$ 起始 $\leq \text{window}$ 。

参数、实验与结果解读

项目默认参数：`sample_every=1`；`line_x=0.5`；`dwell=2`；`event_order=["enter","cross","dwell"]`；`window=10`。

建议实验：对正确顺序、缺一步、顺序颠倒及超时片段分别验证，回看每一步证据。

结果解读：找到 `sequence_complete`，再检查 `evidence` 中每个事件的时间和顺序是否合理。没有完成事件时，查看缺的是哪一步。

边界与误区：这是事件规则，不是对真实作业动作的完整理解；跟踪换号会打断序列，也不能只凭完成标记判定业务合规。

学习练习（答案见独立答案册）

Q132-1 为什么每个 ID 需要独立状态机？

Q132-2 状态机与动作识别网络有何不同？

Q132-3 事件齐全但顺序不对能通过吗？

Q132-4 超时为什么要重置？

Q132-5 ID 切换会造成什么？

Q132-6 `sequence_complete` 能证明实际作业合规吗？

133 视频分割 (video_segment)

实验输入：video。用途：运动分析、轨迹、产线事件。

模型架构：M08 SAM2 Hiera Tiny | 提示分割与视频记忆。资源 ID：sam2。详见前面的架构专题。

学习目标与直观理解

在视频首帧框选目标，让分割模型把这个目标的像素区域延续到后续帧。

SAM2 将首帧提示与历史帧特征保存在记忆中，逐帧更新目标掩膜。它利用连续时间信息，而不是每帧独立点选。

核心机制与推导

视频分割使用 SAM2 的时序记忆，将已分割目标的外观与掩膜状态编码到记忆中，当前帧特征通过记忆注意力读取历史信息，再由掩膜解码器输出新掩膜并更新记忆。它比每帧独立提示更能保持目标一致，但错误掩膜也可能写入记忆并传播。遮挡、出画再进入和相似目标交叉需要特别验证。项目使用首帧 ROI 提示与短视频传播，限制 150 帧以控制资源，不应声称无限时长稳定跟踪。

$F_t = \text{ImageEncoder}(I_t)$; $\tilde{F}_t = \text{MemoryAttention}(F_t, M_{<t})$;
 $\text{mask}_t = \text{Decoder}(\tilde{F}_t, \text{prompt}_t)$ ，再编码更新记忆。

参数、实验与结果解读

项目默认参数：sample_every=1。

建议实验：对目标转身、遮挡和出画片段逐帧检查掩膜，观察错误是否持续向后传播。

结果解读：检查遮挡、转身和出画附近的掩膜是否漂移；逐帧标签掩膜可在 masks.zip 中查看。

边界与误区：首帧框不准会向后传播误差。平台限制短视频以控制记忆开销，掩膜编号也不代表语义类别。

学习练习 (答案见独立答案册)

Q133-1 SAM2 视频版比单图版增加哪些模块？

Q133-2 历史记忆为什么能提高一致性？

Q133-3 为什么错误会向后传播？

Q133-4 首帧 ROI 不准有什么后果？

Q133-5 分割标签 ID 等于语义类别吗？

Q133-6 评估视频分割只看单帧 IoU 够吗？

第 13 模块 模型学习与评估

134 Grad-CAM 类激活图 (gradcam)

实验输入：image。用途：观察分类网络主要依赖哪些区域，发现背景偏差。

模型架构：M01 ResNet18 | 残差卷积分类骨干。资源 ID：resnet18。详见前面的架构专题。

学习目标与直观理解

观察分类模型这次主要依赖图中的哪些区域，帮助发现它是否关注了错误的背景。

先计算哪些内部特征最能影响这次类别得分，这种影响用“梯度”表示；再突出这些特征在图片上响应的位置，合成一张粗略热图。

核心机制与推导

Grad-CAM 解释指定类别得分与卷积特征的局部关系。对最后一层特征求类别 logit 的梯度，空间平均后得到各通道权重，再对特征图加权求和并取 ReLU，保留对该类别有正贡献的区域。它需要反向自动求导，不是仅取激活最大通道；网络仍应处于 eval 模式。平台选当前预测第一类，使用直接缩放到 224×224 的输入，和普通分类入口的中心裁剪不同，因而输出类别也可能不同。

$\alpha_k = (1/Z) \sum_{i,j} \partial y^c / \partial A_{ij}^k$ ； $L^c = \text{ReLU}(\sum_k \alpha_k A^k)$ ，再上采样显示。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：换背景保持主体不变，比较热图是否关注背景；同时记录目标类别和预处理差异。

结果解读：先核对输出 class，再看热图是否覆盖与该类别相关的区域。换一张背景不同的图片做比较很有帮助。

边界与误区：热图不是物体掩膜，也不能证明因果关系。上采样后的平滑颜色不代表网络真的有那么精细的定位能力。

学习练习（答案见独立答案册）

Q134-1 Grad-CAM 利用了模型哪两个量？

Q134-2 为什么不能全部放进 inference_mode？

Q134-3 为什么取 ReLU？

Q134-4 热图可以当精确分割掩膜吗？

Q134-5 热图集中在目标就证明因果正确吗？

Q134-6 为什么它与分类入口可能预测不同？

135 特征图可视化 (feature_maps)

实验输入：image。用途：理解卷积特征逐层抽象以及通道响应的差异。

模型架构：M01 ResNet18 | 残差卷积分类骨干。资源 ID：resnet18。详见前面的架构专题。

学习目标与直观理解

查看神经网络中间层对图像不同模式的响应，理解“特征”不是直接可读的物体标签。

ResNet18 的 layer4 输出 512 个通道，每个通道是某种学习到的响应。平台显示前 16 个，完整数组可下载。

核心机制与推导

特征图是网络在某层对输入的多通道空间响应。ResNet18 在 224×224 输入下，layer4 常为 $512 \times 7 \times 7$ ，每个位置对应较大感受野，每个通道是学习到的组合特

征。通道不一定能命名为眼睛、轮子等概念，表示可能分散在多个通道。平台可视化前 16 个通道，各自归一化，但保存完整数组；逐通道拉伸会让非常弱的噪声响应也看起来明亮，应读取原始统计再比较强度。

特征张量 $A \in \mathbb{R}^{(C \times H' \times W')}$ ；显示 $T_k = (A_k - \min A_k) / (\max A_k - \min A_k + \epsilon)$ 。

参数、实验与结果解读

本入口无普通数值参数；输入内容、交互提示和模型预处理仍会影响结果。

建议实验：对同图不同裁剪及不同对象比较特征图，同时记录各通道原始均值、标准差和最大值。

结果解读：看哪些通道对同一位置有强响应，哪些几乎不响应；结合另一张图片比较，而不要强行给每个通道起语义名字。

边界与误区：每张小图单独归一化，不能凭颜色亮暗比较不同通道的绝对激活强度。

学习练习（答案见独立答案册）

Q135-1 layer4 的 512 个通道代表 512 类吗？

Q135-2 为什么越深空间分辨率越低？

Q135-3 每张小图一样亮表示响应一样强吗？

Q135-4 hook 提取特征时应注意什么？

Q135-5 特征图与 Grad-CAM 有何区别？

Q135-6 一次可视化能解释完整模型吗？

136 推理后端对比 (benchmark)

实验输入：image。用途：观察后端执行差异和数值一致性。

模型架构：M01 ResNet18 | 残差卷积分类骨干。资源 ID：resnet18。详见前面的架构专题。

学习目标与直观理解

在相同输入与权重下比较两种推理后端的耗时和输出差异，学习怎样做公平的性能实验。

先预热，避开首次初始化影响，再重复计时取中位数。同时比较 PyTorch 和 ONNX Runtime 的输出数值差。

核心机制与推导

推理后端对比需要固定权重、输入、精度、设备与线程设置，分别测量稳定运行成本和端到端成本。预热减少首次加载、缓存和算子初始化影响，重复测量用中位数减弱偶发扰动。GPU 异步执行时若不同步，只会测到提交任务时间。项目 PyTorch 可使用所选设备，ORT 固定 CPU；当 PyTorch 用 GPU 时不是同设备公平对比。数值一致性检查 logits 最大绝对差，但无真值时不能得出准确率提升结论。

中位延迟= $\text{median}(t_i)$ ；最大绝对误差= $\max|z_{\text{PT}}-z_{\text{ORT}}|$ ；吞吐需按实际并发与批量另测。

参数、实验与结果解读

项目默认参数：repeats=5。

建议实验：在 CPU 同设备条件下预热并重复计时，分开记录模型前向与含预处理的总耗时。

结果解读：看中位毫秒数和 max_abs_error，确认后端设备、输入形状一致，再判断速度差异。

边界与误区：更快不代表更准确；没有真值就不能报告准确率。不同设备、线程数和后台负载也会改变耗时。

学习练习（答案见独立答案册）

Q136-1 ONNX Runtime 会改变模型架构吗？

Q136-2 为什么首次推理不宜混入稳定延迟？

Q136-3 GPU 计时为何要同步？

Q136-4 中位数能代表尾延迟吗？

Q136-5 PyTorch GPU 与 ORT CPU 谁快有何含义？

Q136-6 logits 接近能证明任务准确率相同吗？

137 预处理与数据增强 (augmentation)

实验输入：image。用途：学习训练输入分布。

学习目标与直观理解

模拟角度、亮度和噪声变化，思考训练数据怎样覆盖实际场景中的变化。

按固定随机种子施加旋转、翻转、亮度增益和随机噪声，让相同参数能重复得到同一结果。

核心机制与推导

数据增强对训练输入施加保持或可推导标签的变化，扩大模型见到的外观与几何分布。旋转、翻转改变空间坐标，检测框、掩膜和关键点必须同步变换；亮度和噪声改变外观，但不一定适合所有任务，例如颜色一致性检测中强色偏会改变标签语义。平台按旋转、翻转、亮度与固定随机噪声顺序生成演示图，并不是完整训练增强系统。随机种子有助复现，训练时也要保证足够多样性。

$I' = \text{clip}(b \cdot \text{Flip}(\text{Warp}(I)) + n, 0, 255)$ ；几何标签应应用同一变换，掩膜保持离散类别。

参数、实验与结果解读

项目默认参数：angle=10；brightness=1.1；noise=5；flip=none。

建议实验：对含边框目标的图做旋转翻转，手工核对标签同步规则，再观察增强是否符合真实成像变化。

结果解读：观察目标是否仍然可辨认，变换后的外观是否可能真实出现，并检查边缘裁切和黑边。

边界与误区：训练时框、掩膜等标注也必须同步变换。本图片演示不自动替你变换标注，过强增强还可能改变正确标签。

学习练习（答案见独立答案册）

Q137-1 数据增强与简单复制数据有什么差别？

Q137-2 检测增强只变图片不变框会怎样？

Q137-3 所有增强都必须保持类别吗？

Q137-4 为什么不能在划分训练测试前生成近重复增强？

Q137-5 固定种子有什么利弊？

Q137-6 增强越强越好吗？

138 分类指标 (`eval_classification`)

实验输入：image。用途：数据集验证和回归比较。

学习目标与直观理解

把分类预测与真实答案逐项对照，区分“总体答对多少”和“某类容易漏掉或误报多少”。

混淆矩阵的行是真实类别，列是预测类别。准确率看整体正确比例，精确率看报出的某类有多少是真的，召回率看真实某类找回了多少。

核心机制与推导

分类评估从混淆矩阵出发，项目行是真值、列是预测。准确率统计整体正确比例，precision 衡量预测为某类中有多少正确，recall 衡量该类真值中找回多少。F1 取二者调和平均，macro-F1 先算各类再等权平均，更关注小类；它不等于宏 precision 与宏 recall 再算 F1。类别不平衡时只报准确率会掩盖少数类失效，零分母处理规则也影响结果。

$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$, $\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$, $\text{F1} = 2\text{PR} / (\text{P} + \text{R})$; macro-F1=各类 F1 均值。

参数、实验与结果解读

项目默认参数：`annotations={}`。

建议实验：使用 95 个负类与 5 个正类的样本，比较全预测负类的准确率和正类召回。

结果解读：先看混淆矩阵哪些非对角格较大，再结合每类 precision、recall 与 macro_F1 判断错误偏向。

边界与误区：类别严重不平衡时，高 accuracy 也可能掩盖少数类全部漏检。truth 与 prediction 必须是对应的独立样本。

学习练习（答案见独立答案册）

Q138-1 混淆矩阵行列如何约定？

Q138-2 全预测多数类可能准确率很高吗？

Q138-3 precision 与 recall 分别关心什么？

Q138-4 macro-F1 如何计算？

Q138-5 无预测某类时 precision 怎么办？

Q138-6 为什么训练集准确率不能代表上线效果？

139 检测 AP / mAP (eval_detection)

实验输入：image。用途：数据集验证和回归比较。

学习目标与直观理解

同时评价目标检测的类别、位置和置信度排序，而不只看画出来的框是否好看。

先用 IoU 衡量两个框的重合程度：共同覆盖面积除以至少一方覆盖的面积。预测框与真实框一对一配对，再按分数从高到低统计查得准不准、漏了多少。AP 汇总这条曲线，mAP 再对类别等条件取平均。

核心机制与推导

检测 AP 同时评价类别、位置和置信排序。对每个类别将预测按分数降序，在同一图像中与未匹配真值按 IoU 一对一匹配；重复框即使覆盖正确目标也算 FP。

累积 TP/FP 得 precision-recall 曲线，以插值精度计算 AP。平台用 101 个召回点，并对 IoU 0.50 到 0.95 的十个阈值平均，属于 COCO 风格教学评估；没有 crowd、面积分组、maxDets 等完整协议，不应直接等同官方榜单。

$AP \approx (1/101) \sum_{r=0,0.01,\dots,1} \max_{\{r' \geq r\}} P(r')$ ；mAP 对类别及指定 IoU 阈值平均。

参数、实验与结果解读

项目默认参数：annotations={}。

建议实验：对同一真值增加重复高分框、调换预测分数及移动框位置，分别观察 AP 变化。

结果解读：AP50 使用较宽松的位置要求，mAP50_95 更关注定位精度。两者差距大时，可能是找到了物体但框不够准。

边界与误区：必须提供每个目标的真实标注。平台使用 101 点插值 AP，不含完整 COCO 的 crowd、面积和最大检测数规则。

学习练习（答案见独立答案册）

Q139-1 为什么必须按分数排序？

Q139-2 一个真值能匹配多个 TP 吗？

Q139-3 AP50 与 mAP50_95 有何差别？

Q139-4 无预测时 AP 是多少？

Q139-5 AP 与固定阈值 precision 相同吗？

Q139-6 本项目数值能直接声称官方 COCO AP 吗？

140 分割 IoU / Dice (eval_segmentation)

实验输入：image、truth_mask。用途：数据集验证和回归比较。

学习目标与直观理解

比较预测掩膜与真实掩膜的重合程度，判断区域分割得有多准。

IoU 是共同选中像素数除以至少一方选中的像素数；Dice 是两倍交集除以两者像素数之和。越接近 1，重合越好。

核心机制与推导

分割指标比较像素集合交并关系。IoU 的分母是并集，Dice 用预测和真值面积之和，两者在相同二值集合下存在固定换算关系。大面积背景会抬高 pixel accuracy，因此小缺陷任务应看前景指标。多类评估先按真值 ignore_label 排除无效像素，再计算各类与均值；平台均值包含背景，且有效区域中出现的预测类也参与类别集合。空掩膜约定需明确，否则不同实现的结果难比较。

$$\text{IoU} = \text{TP} / (\text{TP} + \text{FP} + \text{FN}), \text{Dice} = 2\text{TP} / (2\text{TP} + \text{FP} + \text{FN}) = 2\text{IoU} / (1 + \text{IoU}).$$

参数、实验与结果解读

项目默认参数：mode=binary；ignore_label=255。

建议实验：用小前景掩膜测试全背景预测，比较像素准确率、前景 IoU 和 Dice；再加入 ignore 区域。

结果解读：主图是预测掩膜，专用输入是真值。二值模式看 IoU、Dice；多类别模式看各类指标与包含背景的平均值。

边界与误区：pixel_accuracy 可能被大面积背景抬高。多类别模式的像素值应是类别编号，并按真值 ignore_label 排除不参与评估的像素。

学习练习（答案见独立答案册）

Q140-1 交集 40、并集 100 时 IoU 与 Dice？

Q140-2 为什么背景准确率很高仍分割很差？

Q140-3 ignore_label 应如何应用？

Q140-4 两个空二值掩膜本项目如何记分？

Q140-5 彩色可视化图能当多类标签输入吗？

Q140-6 macro mIoU 与全像素 IoU 一样吗？

资料来源与核对说明

本书范围由 docs/algorithm-catalog.json 的 140 个入口确定，编号按本书模块顺序排列，与算法 ID 一起作为两册定位键。通俗实验说明参考项目 frontend/src/learning/lessons.ts；深入讲解、问题和答案为本次新增编写。

项目行为依据

backend/app/algorithms/classical.py、common.py、special.py、teaching.py、backend/app/inference.py、models.py、video.py，以及 docs/MODELS.md、docs/EXPERIMENTS.md。模型维度优先核对本地 config.json / config.yml，避免把模型家族的其他版本误作当前实现。

下列为官方资料、论文与实现的延伸阅读入口（访问核对日期：2026-09-30）。架构专题中的 R 编号对应这里的链接。通用教学推导与本地实现说明应结合阅读；论文报告的实验性能不自动属于本项目。

- R01 [OpenCV 官方教程：传统视觉、几何与视频](#)
- R02 [Torchvision ResNet：架构与模型说明](#)
- R03 [Ultralytics YOLOv8：任务与模型说明](#)
- R04 [YOLOv8 v8.3.0 架构配置](#)
- R05 [DeepLabV3 MobileNetV3-Large 官方说明](#)
- R06 [DETR 官方实现](#)
- R07 [SAM 2 论文](#)
- R08 [SAM 2 官方实现](#)
- R09 [MediaPipe Face Landmarker 官方说明](#)
- R10 [MediaPipe Hand Landmarker 官方说明](#)
- R11 [PP-OCrv4 官方技术说明](#)
- R12 [DocLayout-YOLO 官方实现](#)
- R13 [CLIP 论文](#)
- R14 [OWL-ViT 论文](#)
- R15 [BLIP 论文](#)
- R16 [Depth Anything V2 论文](#)
- R17 [Swin2SR 论文](#)
- R18 [Swin2SR 官方实现](#)
- R19 [Restormer 论文](#)
- R20 [Restormer 官方实现](#)
- R21 [U2-Net 官方实现](#)
- R22 [Torchvision R3D18 官方说明](#)
- R23 [PatchCore 官方实现（用于对照教学版差异）](#)

符号采用可编辑的文本公式；图示为本次按模块关系绘制的教学示意，不是逐算子计算图。中文正文采用本机可用的思源宋体风格字体，标题采用思源黑体风格字体，以保持导出稳定。